AKADEMIA GÓRNICZO-HUTNICZA IM. STANISŁAWA STASZICA W KRAKOWIE
WYDZIAŁ ZARZĄDZANIA

KATEDRA ZASTOSOWAŃ MATEMATYKI W EKONOMII

Projekt dyplomowy

Analiza porównawcza architektur rekurencyjnych sieci neuronowych w prognozowaniu notowań indeksów giełdowych w zróżnicowanych warunkach rynkowych

A comparative analysis of recurrent neural network architectures in stock index price prediction under diverse market conditions

Autor: *Kinga Kołodziej*
Kierunek studiów: *Informatyka i Ekonometria*
Opiekun pracy: *dr hab. Łukasz Lach*

Kraków, *2025*

Spis treści

Wstęp 4

1. Przegląd literatury 5

2. Charakterystyka danych empirycznych oraz procedura przygotowania zbioru do modelowania prognostycznego 10

2.1. Charakterystyka danych empirycznych 10

2.1.1. Indeks MSCI World – reprezentant rynków rozwiniętych 10

2.1.2. Indeks MSCI Emerging Markets – reprezentant rynków wschodzących 11

2.2. Identyfikacja i podział okresów rynkowych 12

2.3. Przygotowanie danych empirycznych do modelowania predykcyjnego 14

3. Architektury rekurencyjnych sieci neuronowych oraz metody oceny ich skuteczności w prognozowaniu szeregów czasowych 15

3.1. Proste rekurencyjne sieci neuronowe 15

3.2. Sieć neuronowa z mechanizmem bramkowania w strukturze rekurencyjnej 19

3.3. Sieć neuronowa z mechanizmem długiej pamięci krótkotrwałej 21

3.4. Metryki oceny jakości prognoz 23

4. Badanie empiryczne 26

4.1. Dobór i konfiguracja hiperparametrów architektury sieci neuronowych 26

4.2. Prognoza indeksów giełdowych z wykorzystaniem prostych sieci rekurencyjnych 29

4.2.1. Prognoza indeksów giełdowych dla rynku rozwiniętego 29

4.2.2. Prognoza indeksów giełdowych dla rynku wschodzącego 32

4.3. Prognoza indeksów giełdowych z wykorzystaniem rekurencyjnych sieci neuronowych typu GRU 35

4.3.1. Prognoza indeksów giełdowych dla rynku rozwiniętego 35

4.3.2. Prognoza indeksów giełdowych dla rynku wschodzącego 38

4.4. Prognoza indeksów giełdowych z wykorzystaniem rekurencyjnych sieci neuronowych typu LSTM 42

4.4.1. Prognoza indeksów giełdowych dla rynku rozwiniętego 42
4.4.2. Prognoza indeksów giełdowych dla rynku wschodzącego..... 45
5. Komparatywna ocena skuteczności architektur sieci rekurencyjnych 49
5.1. Kryteria ewaluacji modeli prognostycznych 49
5.2. Selekcja optymalnych modeli dla indeksów rynków rozwiniętych i wschodzących w różnych warunkach rynkowych..... 50
5.3. Wnioski wynikające z analizy porównawczej modeli prognostycznych..... 54
Zakończenie 56
Literatura..... 58
Wykaz innych materiałów 61
Spis tabel..... 62
Spis rysunków..... 64
Spis załączników 66

Wstęp

Inwestycje na rynku giełdowym od lat stanowią jedną z najczęściej wybieranych form lokowania kapitału. Decyzja ta wiąże się jednak ze sporym ryzykiem, wynikającym z nieprzewidywalnej natury rynku finansowego, skutkiem czego, wraz z dynamicznym rozwojem sektora sztucznej inteligencji, coraz większego znaczenia nabierają narzędzia analityczne umożliwiające trafne prognozowanie przyszłych wartości aktywów finansowych.

W ostatnich latach nastąpił znaczny rozwój w badaniach nad sztucznymi sieciami neuronowymi, czyli modelami inspirowanymi funkcjonowaniem ludzkiego mózgu, które okazują się niezwykle skuteczne w predykcji szeregów czasowych. Na szczególne wyróżnienie zasługują rekurencyjne odmiany modeli przystosowane do przetwarzania danych sekwencyjnych. Do najczęściej wykorzystywanych należą: proste rekurencyjne sieci neuronowe (RNN), bramkowane jednostki rekurencyjne (GRU) oraz sieci neuronowe z długą pamięcią krótkotrwałą (LSTM).

Celem niniejszej pracy jest analiza porównawcza skuteczności modeli RNN, GRU oraz LSTM w kontekście predykcji szeregów czasowych na przykładzie notowań indeksów globalnych MSCI World oraz MSCI Emerging Markets wraz z uwzględnieniem zróżnicowanych warunków rynkowych: okresu względnej stabilizacji, pandemii oraz wojny. Przed rozpoczęciem właściwej analizy, przedstawiony zostanie przegląd literatury, stanowiący podsumowanie dotychczas przeprowadzonych badań w dziedzinie predykcji szeregów czasowych o charakterze finansowym z wykorzystaniem rekurencyjnych sieci neuronowych. Następnie zaprezentowane zostaną dane empiryczne oraz proces ich przygotowania do modelowania predykcyjnego. W dalszej kolejności omówione zostaną wybrane architektury rekurencyjnych sieci neuronowych oraz wskaźniki wykorzystywane do oceny jakości prognoz. Implementacja modeli oraz uzyskane wyniki zostaną szczegółowo zaprezentowane w części empirycznej. Końcowy rozdział pracy koncentruje się na analizie porównawczej, mającej na celu wskazanie, które z badanych architektur rekurencyjnych sieci neuronowych najlepiej sprawdzają się w prognozowaniu indeksów giełdowych dla rynków rozwiniętych i wschodzących, w zależności od panujących warunków rynkowych.

1. Przegląd literatury

Zastosowanie zaawansowanych modeli sztucznych sieci neuronowych w celu predykcji przyszłych wartości indeksów giełdowych jest tematem coraz częściej poruszanym w badaniach naukowych. Chociaż niniejsza praca poświęcona jest prognozie globalnych indeksów giełdowych z wykorzystaniem modeli głębokiego uczenia, to w przeglądzie literatury uwzględniono również badania dotyczące innych instrumentów finansowych, takich jak akcje pojedynczych spółek czy kryptowaluty. Wynika to z faktu, że wszystkie te rynki dzielą podobne cechy: są silnie nieliniowe, często niestacjonarne, podatne na szum. Ze względu na przeprowadzaną przez autora pracy analizę na jednowymiarowych szeregach czasowych, celem zachowania spójności metodologicznej, wspólnym mianownikiem przytoczonych badań jest predykcja oparta na historycznych notowaniach pojedynczej zmiennej czasowej.

Wśród badań porównujących skuteczność modeli sztucznych sieci neuronowych w problemach regresyjnych na uwagę zasługuję praca Dias Satria, który przeanalizował efektywność modeli RNN, GRU oraz LSTM, dodatkowo zestawiając złożone metody uczenia głębokiego z modelem ekonometrycznym ARIMA Box-Jenkins. Dane wejściowe stanowią szeregi czasowe dziennej skorygowanej ceny zamknięcia akcji czterech głównych banków indonezyjskich notowanych na giełdzie : BRI, BNI, BCA oraz Bank Mandiri, w przedziale czasowym od 1 czerwca 2013 roku do 28 września 2022 roku. Dane przekształcono z wykorzystaniem standaryzacji (Z-transformacji) oraz podzielono na zbiór treningowy i testowy w proporcji 70:30. Trening modeli sieci rekurencyjnych oparto na jednakowym zestawie hiperparametrów w postaci dwóch warstw ukrytych, odpowiednio o liczbie neuronów równej 128 i 64 oraz liczbie epok równej 20. Za funkcję aktywacji obrano tangens hiperboliczny (tanh). Jako miary oceny jakości predykcji przyjęto RMSE, MAE oraz MAPE. Wyniki wykazały, że najniższe błędy predykcji osiągnął model ARIMA Box-Jenkins, jednakże autor zwraca uwagę na jego ograniczenia w przypadku niestacjonarnych szeregów czasowych, stwierdzając niewiarygodność otrzymanych rezultatów i wykluczając z dalszej analizy. Spośród analizowanych sieci neuronowych najniższą skutecznością wykazał się model prostej rekurencyjnej sieci neuronowej (wartości MAPE : BRI - 33,99%, BNI - 28,97%, BCA - 58,64%, Mandiri - 38,77%), natomiast modele GRU (wartości MAPE : BRI - 31,76%,

BNI - 26,36%, BCA - 52,05%, Mandiri - 34,25%) oraz LSTM (wartości MAPE : BRI - 31,85%, BNI - 21,81%, BCA - 57,65%, Mandiri - 36,06%) uzyskały zbliżone wartości błędów predykcji. W ujęciu procentowym GRU przewyższył pozostałe modele sieci neuronowych w przypadku trzech z czterech analizowanych spółek. W związku z tym, biorąc pod uwagę wyniki metryk oraz prostotę implementacji wynikającą z mniejszej liczby parametrów, autor stwierdza, że bramkowane jednostki rekurencyjne - GRU - stanowią najbardziej efektywne narzędzie w omawianym badaniu.[1]

Z kolei w badaniu Hiranshy i współautorów dokonano analizy porównawczej w kontekście skuteczności prognozy czterech modeli uczenia głębokiego - MLP, RNN, LSTM i CNN - na przykładzie danych obejmujących dzienne ceny zamknięcia akcji spółek notowanych na giełdach NSE oraz NYSE. Modele trenowano na danych spółki Tata Motors z NSE obejmujących okres od 1 stycznia 1996 do 30 czerwca 2015, a następnie testowano na dwóch zestawach danych: pierwszym, obejmującym dzienne ceny zamknięcia akcji spółek Maruti, Axis Bank i Hcltech notowanych na NSE (okres: 5 października 2007 - 30 czerwca 2017), oraz drugim, zawierającym notowania spółek Bank of America i Chesapeak Energy z NYSE (3 stycznia 2011 - 30 grudnia 2016) . Dane zostały znormalizowane do zakresu [0,1], a następnie podzielone na sekwencje wejściowe o długości 200, przyjęto 400-dniowy horyzont prognozy. Proces treningu prowadzono przez 1000 epok. W dalszej analizie, celem wyłonienia najefektywniejszych architektur, posłużono się średnim bezwzględnym błędem procentowym. W przypadku danych z indyjskiej giełdy NSE najlepsze rezultaty osiągnął model CNN, uzyskując najniższe wartości błędu MAPE we wszystkich trzech przypadkach (wartości MAPE: Maruti - 4,05%, Hcltech - 4,40%, Axis Bank - 5,22%). Model LSTM również wykazał się wysoką skutecznością, osiągając minimalnie wyższe wartości błędu (wartości MAPE: Maruti - 6,03%, Hcltech - 5,52%, Axis Bank - 4,88%). Natomiast najsłabiej wypadła prosta sieć rekurencyjna (wartości MAPE: Maruti - 5,82%, Hcltech - 5,40%, Axis Bank - 11,64%). Co istotne, również dla danych z NYSE, pomimo że modele zostały wytrenowane wyłącznie na danych z NSE, uzyskano satysfakcjonujące wyniki predykcji. W tym przypadku najlepsze okazały się modele CNN (wartości MAPE: Bank of America - 5,31%, Chesapeak Energy - 9,18%) oraz RNN (wartości MAPE: Bank of America - 5,38%, Chesapeak Energy - 8,94%), co sugeruje, że dobór architektury powinien być

[1] D. Satria, Predicting Banking Stock Prices Using RNN, LSTM, and GRU Approach, „Applied Computer Science" 2023, t. 19, nr 1, s. 82 - 94, https://doi.org/10.35784/acs-2023-06.

dostosowany nie tylko do charakterystyki danych, ale również do czynników takich jak rodzaj rynku.[2]

W odróżnieniu od wcześniejszych prac, Mroua i Lamine w swoim badaniu przeprowadzili kompleksową analizę efektywności modelu rekurencyjnej sieci neuronowej LSTM, posługując się bogatym oraz zróżnicowanym zbiorem danych, obejmującym globalne indeksy giełdowe, indeksy obligacji, a także indeksy surowcowe. Zakres danych stanowił okres od 2 stycznia 1998 r. do 16 września 2020 r., co pozwoliło uwzględnić nie tylko pandemię COVID-19, lecz także wcześniejsze epizody kryzysowe, takie jak kryzysy giełdowe w 1998 czy 2008 roku. Dane wejściowe zostały ograniczone wyłącznie do cen zamknięcia, które następnie poddano normalizacji. Dokonano podziału wspomnianych szeregów czasowych na zbiór treningowy oraz testowy, odpowiednio w proporcjach 80:20. Struktura modelu obejmowała jedną warstwę LSTM z czterema neuronami, liczbę epok równą 100, zastosowano optymalizator Adam, a za funkcję straty przyjęto błąd średniokwadratowy. Modele oceniono przy użyciu klasycznych metryk: RMSE oraz MAE. Najlepsze wyniki otrzymano dla indeksów obligacji (wartości RMSE: US Benchmark 10Y: 1,32, S&P US 5-10Y - 0,37), co spowodowane jest ich stosunkowo niską zmiennością. Dobre wyniki uzyskano również dla indeksów surowcowych, potwierdzając ich stabilny charakter, nawet w czasie kryzysu giełdowego. Największą dokładność model LSTM osiągnął dla indeksów: S&P GSCI Cocoa (wartość RMSE: 0,52), Aluminum (wartość RMSE: 0,63) oraz Biofuel (wartość RMSE: 1,88). Wysoką jakość prognoz uzyskano również w przypadku zbóż, szczególnie dla indeksu Wheat CBOT (wartość RMSE: 1,63). Uzyskane wyniki potwierdzają, że model LSTM skutecznie prognozuje ceny w zróżnicowanych kategoriach surowców, takich jak produkty rolne, metale przemysłowe czy paliwa. Natomiast największym wyzwaniem okazała się predykcja indeksów globalnych, podatnych na wstrząsy rynkowe, charakteryzujących się nagłymi, nieprzewidywalnymi zmianami. Wśród indeksów tych najlepiej prognozowane były MSCI Emerging Markets (wartość RMSE: 9,90) oraz MSCI EAFE (wartość RMSE: 17,88) i MSCI Europe (wartość RMSE: 18,51), natomiast dla MSCI World model osiągnął umiarkowaną dokładność (wartość RMSE: 54,31). Największe trudności pojawiły się przy indeksie MSCI USA (wartość RMSE: 139,22), co było efektem silnej i spekulacyjnej zwyżki cen w okresie pandemii COVID-19.

[2] M. Hiransha, E.A. Gopalakrishnan, V.K. Menon, K.P. Soman, NSE Stock Market Prediction Using Deep-Learning Models, „Procedia Computer Science" 2018, t. 132, s. 1351 - 1362, https://doi.org/10.1016/j.procs.2018.05.050.

Niemniej jednak, pomimo warunków skrajnej niepewności rynkowej, model rekurencyjnej sieci neuronowej okazał się przydatnym narzędziem prognostycznym, znacznie przewyższając pod względem uzyskanych metryk klasyczny model ekonometryczny ARIMA.[3]

W nurcie badań koncentrujących się na zastosowaniu rekurencyjnych sieci neuronowych do prognozowania danych finansowych mieści się również praca Seabe, Moutsingi i Pindzy, w której przeprowadzono porównanie trzech architektur - LSTM, GRU oraz BI-LSTM. Autorzy wykorzystali dzienne ceny zamknięcia wybranych kryptowalut : Bitcoina, Ethereum oraz Litecoina, obejmujące okres od 1 stycznia 2018 roku do 1 stycznia 2023 roku. Przed rozpoczęciem procesu trenowania modeli, dane zostały poddane procesowi normalizacji oraz ustalono podział na zbiór treningowy i testowy w proporcji 80:20. Każdy z modeli zbudowano w oparciu o trójwarstwową architekturę ze 100 neuronami w każdej warstwie, a optymalny rezultat uzyskano przy zastosowaniu rozmiaru partii równego 120. Proces trenowania przeprowadzono osobno dla każdego aktywa, a do oceny skuteczności zastosowano metryki RMSE i MAPE. Wyniki oceny skuteczności predykcji przy użyciu RMSE i MAPE wykazały wyraźną przewagę modelu Bi-LSTM, jednak porównanie LSTM i GRU również przyniosło interesujące obserwacje. Dla Bitcoina model GRU osiągnął wyraźnie wyższy błąd MAPE (5,72%) niż LSTM (3,94%). W przypadku Ethereum i Litecoina sytuacja wyglądała odwrotnie - GRU uzyskał niższe wartości MAPE w porównaniu do LSTM: odpowiednio 14,79% względem 29,71% dla Ethereum oraz 4,58% względem 6,36% dla Litecoina. Sugeruje to, że architektura GRU może lepiej sprawdzać się w prognozowaniu kursów walut cechujących się większą zmiennością cen.[4]

Idąc w kierunku szerszego porównania architektur, Chahuán-Jiménez przeprowadziła empiryczne badanie skuteczności pięciu typów sieci neuronowych: klasycznej sieci neuronowej (ANN), rekurencyjnej sieci neuronowej (RNN), długiej pamięci krótkotrwałej (LSTM), jednostki GRU oraz konwolucyjnej sieci neuronowej (CNN). Dane wejściowe obejmowały wartości cen zamknięcia indeksu S&P 500, obejmującego okres od 1 stycznia 2018 do 29 grudnia 2023. Szeregi czasowe zostały

[3] M. Mroua, A. Lamine, Financial time series prediction under COVID-19 pandemic crisis with Long Short-Term Memory (LSTM) network, „Humanities and Social Sciences Communications" 2023, t. 10, art. 530, s. 1 – 16, https://doi.org/10.1057/s41599-023-02042-w.

[4] P. L. Seabe, C. R. B. Moutsinga, E. Pindza, Forecasting cryptocurrency prices using LSTM, GRU, and Bi-Directional LSTM: A deep learning approach, „Fractal and Fractional" 2023, t. 7, nr 2, art. 203, s. 1 - 18, https://doi.org/10.3390/fractalfract7020203.

poddane procesowi normalizacji. Każdy z analizowanych modeli sieci neuronowych został wytrenowany przy użyciu jednolitego zestawu hiperparametrów, co zapewniło porównywalność wyników. Zastosowano 500 epok z aktywnym mechanizmem wczesnego zatrzymania, optymalizator Adam, funkcję kosztu MSE, a długość sekwencji danych wejściowych wynosiła 3 kolejne obserwacje. Liczba neuronów i warstw w poszczególnych modelach była zgodna z zaleceniami literaturowymi: dla modeli ANN, RNN, LSTM i GRU zastosowano po jednej warstwie z 50 jednostkami, dla CNN wykorzystano warstwę konwolucyjną z 64 filtrami i oknem o rozmiarze 2. Ocena skuteczności prognoz została przeprowadzona przy użyciu trzech metryk: błędu średniokwadratowego (RMSE), średniego absolutnego błędu procentowego (MAPE) oraz trafności kierunkowej. Modele testowano w trzech wariantach: na danych z okresu 2018–2023 (rynek stabilny), 2008–2023 (rynek rozszerzony) oraz podczas pandemii COVID-19 (luty - czerwiec 2020). Najniższymi wartościami błędów w przypadku wszystkich podokresów wykazał się model bramkowanych jednostek rekurencyjnych (wartości MAPE odpowiednio: 2,20%, 1,50%, 10,62%). Na drugim miejscu uplasował się model LSTM, który choć nieco mniej dokładny niż GRU, nadal oferował stabilne wyniki i dobrze radził sobie z dłuższymi zależnościami czasowymi. Model RNN osiągał wyższe wartości błędów niż GRU i LSTM, co wynika z ograniczeń prostej rekurencyjnej architektury, takich jak podatność na problem zanikania gradientu i trudności z modelowaniem długoterminowych zależności. Najsłabsze wyniki osiągnął model ANN, co wynika z faktu, iż nie jest to architektura zaliczana do kategorii modeli sekwencyjnych. [5]

Przytoczone badania jednoznacznie wskazują na wysoką skuteczność modeli rekurencyjnych sieci neuronowych w prognozie notowań instrumentów finansowych. W szczególności modele rekurencyjne typu LSTM oraz GRU wykazują przewagę w dokładnym modelowaniu nieliniowych i sekwencyjnych zależności czasowych. Ponadto, różnice w metrykach oceny skuteczności sugerują, że wybór optymalnej architektury modelu powinien być dostosowany do konkretnej charakterystyki danych, co stanowi jedno z założeń niniejszej pracy.

[5] K. Chahuán-Jiménez, Neural Network-Based Predictive Models for Stock Market Index Forecasting, „Journal of Risk and Financial Management" 2024, t. 17, nr 6, art. 242, s. 1 - 18, https://doi.org/10.3390/jrfm17060242.

2. Charakterystyka danych empirycznych oraz procedura przygotowania zbioru do modelowania prognostycznego

Celem niniejszego rozdziału jest przedstawienie podstaw empirycznych przeprowadzonego badania. Uwzględniono w nim charakterystykę danych wejściowych, specyfikę analizowanych indeksów giełdowych, wyodrębnienie istotnych okresów rynkowych oraz sposób przygotowania danych do procesu modelowania predykcyjnego. Przedstawione elementy stanowią fundament dla dalszej analizy porównawczej skuteczności wybranych architektur rekurencyjnych sieci neuronowych.

2.1. Charakterystyka danych empirycznych

Podstawowym założeniem, jakie należy zdefiniować jest zbiór oraz zakres danych wejściowych. W celu zdywersyfikowania analizy zdecydowano się na zestawienie dwóch kluczowych indeksów globalnych: MSCI World, reprezentującego rynki rozwinięte oraz MSCI Emerging Markets, odzwierciedlającego rynki wschodzące. Charakterystyczna budowa indeksów sprawia, że stanowią one punkt odniesienia, obrazując kondycję wspomnianych gospodarek.

Na potrzeby niniejszej analizy posłużono się dziennymi wartościami cen zamknięcia, wyrażonymi w dolarach amerykańskich, dla wskazanych wcześniej indeksów giełdowych. Dane te zostały pobrane z serwisu finansowego Investing.com (https://pl.investing.com).

2.1.1. Indeks MSCI World – reprezentant rynków rozwiniętych

Indeks MSCI World stanowi szeroką miarę koniunktury rynków rozwiniętych w ujęciu globalnym, obejmując spółki o dużej i średniej kapitalizacji z 23 krajów rozwiniętych. Na dzień 30 maja 2025 r. indeks liczył 1 352 spółki, reprezentując ok. 85% kapitalizacji rynkowej w każdym z uwzględnionych krajów. Konstrukcja indeksu opiera

się na metodzie ważenia według wartości rynkowej, skorygowanej o udział akcji znajdujących się w wolnym obrocie, przy zastosowaniu klasyfikacji sektorowej.

Pod względem geograficznym indeks jest silnie skoncentrowany na rynku amerykańskim, który odpowiada za 71,04% jego wartości. Kolejne znaczące udziały przypadają na Japonię (5,65%), Wielką Brytanię (3,84%), Kanadę (3,20%) i Francję (2,94%), natomiast pozostałe kraje rozwinięte łącznie stanowią 13,32%. Struktura sektorowa MSCI World wskazuje na dominację spółek z branży technologii informacyjnych (23,86%), finansów (17,25%), przemysłu (11,25%), ochrony zdrowia (10,82%) oraz dóbr konsumpcyjnych trwałych (10,22%).

W strukturze indeksu MSCI World dominują największe globalne przedsiębiorstwa technologiczne i konsumenckie. Do grona spółek o najwyższym udziale należą: Apple (4,66%), Microsoft (4,07%), NVIDIA (3,89%) oraz Amazon (2,54%). Znaczący udział wykazują również Meta Platforms (1,74%), Alphabet - z łącznym udziałem przekraczającym 2,5% - a także Broadcom, Tesla i Eli Lilly. Łącznie dziesięć największych podmiotów stanowi blisko 23% kapitalizacji indeksu, co świadczy o jego umiarkowanym poziomie koncentracji i wskazuje na wyraźne znaczenie liderów rynkowych w kształtowaniu ogólnej dynamiki indeksu. [6]

W niniejszym badaniu wykorzystano wariant cenowy indeksu MSCI World, który uwzględnia wyłącznie zmiany cen rynkowych akcji wchodzących w skład indeksu, bez uwzględniania dochodów z tytułu dywidend.

2.1.2. Indeks MSCI Emerging Markets – reprezentant rynków wschodzących

Indeks MSCI Emerging Markets został skonstruowany jako syntetyczny miernik koniunktury na rynkach wschodzących, obejmując spółki o dużej i średniej kapitalizacji z 24 rozwijających się gospodarek. Na dzień 30 maja 2025 r. w jego skład wchodziło 1 206 spółek, odzwierciedlających około 85% kapitalizacji rynkowej poszczególnych rynków źródłowych. Konstrukcja indeksu opiera się na metodzie ważenia według skorygowanej kapitalizacji rynkowej, natomiast podział sektorowy uwzględnia

[6] MSCI Inc., MSCI World Index (USD) – Index Factsheet, Nowy Jork 2025, s. 1 - 2, https://www.msci.com/documents/10199/178e6643-6ae6-47b9-82be-e1fc565ededb [dostęp: 6.06.2025].

ujednoliconą klasyfikację branżową, zapewniając spójność i porównywalność danych w skali globalnej.

Pod względem alokacji geograficznej, indeks MSCI Emerging Markets charakteryzuje się znaczną koncentracją w kilku głównych gospodarkach wschodzących. Największy udział przypada na Chiny (29,57%), Indie (19,21%), Tajwan (17,08%) i Koreę Południową (9,32%). Udział pozostałych państw - w tym Brazylii, Arabii Saudyjskiej, RPA oraz Polski - wynosi łącznie 20,27%. Z punktu widzenia alokacji sektorowej, dominujące są: sektor finansowy (24,72%), technologie informatyczne (21,74%) oraz dobra konsumpcyjne uznaniowe (13,83%). Znaczącą rolę odgrywają również komunikacja (10,18%) i przemysł (6,47%).

Tak wyodrębniona struktura geograficzna i sektorowa znajduje swoje odzwierciedlenie w składzie indeksu pod względem poszczególnych spółek. Dominują w nim globalnie rozpoznawalne przedsiębiorstwa technologiczne i przemysłowe, takie jak Taiwan Semiconductor Manufacturing (8,81%), Tencent Holdings (5,01%), Alibaba Group (3,09%) czy Samsung Electronics (2,35%). Łącznie dziesięć największych spółek tworzy 26,66% całkowitej kapitalizacji indeksu, co potwierdza jego umiarkowaną, ale zauważalną koncentrację rynkową.[7]

W niniejszej pracy przyjęto do analizy wariant indeksu obliczanego w ujęciu cenowym, który uwzględnia wyłącznie zmiany kursów akcji wchodzących w jego skład, z pominięciem wpływu dochodów z dywidend oraz ich reinwestycji, co pozwala skupić się na czystej dynamice cenowej instrumentów uczestniczących w indeksie.

2.2. Identyfikacja i podział okresów rynkowych

W celu zwiększenia trafności i wiarygodności prognoz, przedmiotowe badanie uwzględnia zróżnicowanie warunków rynkowych w analizowanym horyzoncie czasowym. Kluczowym etapem było zatem wyodrębnienie okresów o odmiennym charakterze makroekonomicznym i rynkowym, których specyfika mogła wpływać na dynamikę indeksów giełdowych oraz efektywność zastosowanych metod predykcji.

[7] MSCI Inc., MSCI Emerging Markets Index – Index Factsheet, Nowy Jork 2025, s. 1 - 2, https://www.msci.com/documents/10199/c0db0a48-01f2-4ba9-ad01-226fd5678111 [dostęp: 06.06.2025].

Na wybór zakresu czasowego zbioru danych znaczący wpływ miały wydarzenia gospodarcze, które drastycznie odbiły się na notowaniach cen akcji większości spółek. Celem przeprowadzenia rzetelnej analizy skuteczności poszczególnych wariantów rekurencyjnych sieci neuronowych, zdecydowano się na wybór trzech podokresów, charakteryzujących się odmiennymi warunkami makroekonomicznymi. Zakresy dat wyznaczających dany okres zostały dostosowane tak, aby szeregi czasowe charakteryzowały się jednakową ilością obserwacji, aby wyeliminować wpływ długości danych wejściowych na otrzymywane wyniki prognoz.

Za okres stabilny gospodarczo uznano zakres 05.03.2018 r. - 27.12.2019 r., cechujący się niską inflacją oraz zmiennością, a także przewidywalnymi trendami rynkowymi. Tego rodzaju warunki sprzyjają testowaniu skuteczności modeli prognostycznych, ponieważ pozwalają na ocenę ich działania w środowisku o ograniczonej liczbie zakłóceń i bez nagłych zmian strukturalnych, które mogłyby zaburzyć proces uczenia się wzorców z danych historycznych. W związku z tym okres ten stanowi wartościowy punkt odniesienia w analizie porównawczej efektywności modeli uczenia maszynowego.

Za początek kolejnego okresu, nazywanego dalej okresem pandemii uznano 06.01.2020 r., czyli moment, w którym zaczęły pojawiać się pierwsze informacje o rozprzestrzenieniu się epidemii COVID-19 poza Chiny. Jest to czas paniki oraz nieprzewidywalnych zmian na rynkach finansowych. Koniec tego okresu przypada na 29.10.2021 r., czyli bezpośrednio przed rozpoczęciem podwyżek stóp procentowych przez Rezerwę Federalną Stanów Zjednoczonych, co jest celowym zabiegiem, gdyż zgodnie z założeniem jest to przedział czasowy obrazujący konsekwencje wybuchu pandemii. Takie ograniczenie czasowe pozwala uchwycić specyfikę rynku w okresie bezpośrednio odzwierciedlającym skutki globalnego kryzysu zdrowotnego.

Ostatnia wyróżniona faza rynkowa została zamknięta w ramach czasowych 28.02.2022 r. - 22.12.2023 r., obejmując tym sposobem okres wojny w Ukrainie, co wpłynęło na gwałtowny wzrost zmienności i paniki surowcowej. Wzrost niepewności geopolitycznej oraz napięcia makroekonomiczne skutkowały dynamiczną reakcją inwestorów, co przełożyło się na zwiększoną niestabilność notowań. Ta faza stanowi zatem przykład środowiska skrajnie zdezorganizowanego, w którym modele prognostyczne poddawane są szczególnie wymagającym warunkom testowym.

2.3. Przygotowanie danych empirycznych do modelowania predykcyjnego

Każdy z wyszczególnionych zestawów danych obejmuje dokładnie 475 dni notowań giełdowych. W przypadku indeksów MSCI World oraz MSCI Emerging Markets, zachowana jest ciągłość notowań niezależnie od tego, czy wszystkie rynki składowe są aktywne danego dnia. Zgodnie z oficjalną metodologią MSCI, w przypadku, gdy dane aktywo lub cała giełda nie prowadzą notowań w danym dniu np. z powodu święta, awarii technicznej, sytuacji nadzwyczajnej, wykorzystywane są ostatnio dostępne ceny zamknięcia do wyznaczenia wartości indeksu. Praktyka ta eliminuje obecność braków danych w analizowanych szeregach czasowych.[8]

W kolejnym kroku, ze względu na wrażliwość modeli opartych na rekurencyjnych sieciach neuronowych na różnice skali, wartości cen zamknięcia indeksów zostały poddane procesowi normalizacji metodą *Min-Max* do przedziału [0, 1]. Technika ta ogranicza ryzyko nadmiernego wpływu zmiennych o dużych wartościach liczbowych na proces uczenia, zwiększając tym samym efektywność modelowania i trafność prognozowania.[9] Wyniki uzyskane z modelu zostały poddane odwrotnej transformacji przed obliczeniem metryk oceny jakości oraz wizualizacją prognoz.

Ustalono także, że dla każdego z wyszczególnionych okresów zbiór testowy obejmować będzie 20 ostatnich obserwacji, co odpowiada 4 tygodniom w kontekście rynkowym. Natomiast pozostałe 455 wartości notowań stanowić będą zbiór treningowy i walidacyjny, odpowiednio w stosunku 80:20. Takie podejście uwzględnia specyfikę rynków i pozwala na ocenę modeli w perspektywie krótkoterminowej, istotnej z punktu widzenia praktyki inwestycyjnej.

---

[8] MSCI Inc., Q&A: Treatment of Intraday, Expected and Unexpected Market Closures in the MSCI Equity Indexes, Nowy Jork 2020, s. 4 - 6, https://www.msci.com/eqb/methodology/meth_docs/QA_Market_Closure_March_2020.pdf [dostęp: 6.06.2025].

[9] L. Zhang, et al., Time-Series Neural Network: A High-Accuracy Time-Series Forecasting Method Based on Kernel Filter and Time Attention, „Information" 2023, t. 14, nr 9, art. 500, s. 5 - 6, https://doi.org/10.3390/info14090500.

3. Architektury rekurencyjnych sieci neuronowych oraz metody oceny ich skuteczności w prognozowaniu szeregów czasowych

Tematyka niniejszej pracy koncentruje się na zastosowaniu sieci neuronowych jako kluczowego narzędzia w modelowaniu i prognozowaniu danych finansowych, ze szczególnym uwzględnieniem szeregów czasowych reprezentujących indeksy giełdowe. Zakres analizy obejmuje trzy wybrane architektury neuronowe: prostą sieć rekurencyjną (RNN – Recurrent Neural Network) oraz jej dwie rozwinięte formy: LSTM (Long Short-Term Memory) i GRU (Gated Recurrent Unit), które zostały zaprojektowane w celu przezwyciężenia ograniczeń związanych z długoterminową zależnością danych. W ramach rozdziału omówione zostaną nie tylko mechanizmy działania poszczególnych architektur, lecz również przyjęte metryki oceny skuteczności prognoz, umożliwiające porównanie efektywności modeli.

3.1. Proste rekurencyjne sieci neuronowe

Podstawowy model RNN składa się z jednowarstwowej struktury neuronów, w której każdy neuron przetwarza dane sekwencyjnie. W każdej jednostce czasowej neuron otrzymuje nie tylko bieżący sygnał wejściowy, oznaczany jako $x_{(t)}$, lecz także sygnał wygenerowany przez siebie w poprzednim takcie $y_{(t-1)}$, który odzwierciedla wpływ wcześniejszych wartości w sekwencji. Każdy neuron rekurencyjny wykorzystuje dwa zestawy wag: jeden służy do przetwarzania danych wejściowych z aktualnego kroku czasowego, natomiast drugi obsługuje informację pochodzącą z kroku poprzedniego. Przetwarzanie danych w warstwie RNN można opisać matematycznie jako funkcję nieliniową przyjmującą sumę dwóch składników: przekształconych wejść bieżących oraz przekształconych wyjść z poprzedniego kroku czasowego. Zapis ten przyjmuje postać:

$$y_{(t)} = \emptyset(W_x^T x_{(t)} + W_y^T y_{(t-1)} + b), \tag{3.1}$$

gdzie:

W_x - macierz wag dla danych wejściowych w bieżącym takcie,

W_y - macierz wag dla danych wyjściowych z poprzedniego taktu,

b - wektor obciążeń (bias),

$\emptyset$ - funkcja aktywacji.

W przypadku analizy wielu przykładów jednocześnie, dane wejściowe z kroku *t* tworzą macierz $X_{(t)}$, natomiast wyjścia z poprzedniego kroku czasowego są reprezentowane jako $Y_{(t-1)}$. Obliczenia można zrealizować za pomocą połączonej macierzy wag W:

$$Y_{(t)} = \emptyset([X_{(t)} \quad Y_{(t-1)}]\, W + b). \tag{3.2}$$

Dzięki temu każda warstwa RNN może być traktowana jako przekształcenie nieliniowe nad sekwencją wektorów, z wewnętrznym mechanizmem pamięci stanu. W przypadku głębokich sieci rekurencyjnych stosuje się kaskadowo wiele takich warstw.[10]

W kontekście modeli uczenia maszynowego parametr bias pełni funkcję przesunięcia w transformacji afinicznej, umożliwiając modelowi generowanie wyjścia różnego od zera, nawet przy braku sygnału wejściowego. Bias stanowi dodatkowy neuron w architekturze sieci neuronowej, charakteryzujący się stałą wartością równą 1. Jego obecność pozwala sieci na zwiększenie elastyczności odwzorowania funkcji celu, a tym samym - lepsze dopasowanie do danych. [11]

Funkcje aktywacji stanowią podstawowy mechanizm wprowadzający nieliniowość do sieci neuronowej, co umożliwia modelowi przekształcanie danych w sposób znacznie bardziej złożony niż proste kombinacje liniowe. W klasycznych sieciach neuronowych powszechnie stosuje się funkcje aktywacji o charakterze sigmoidalnym, takie jak funkcja logistyczna (*sigmoid*) oraz tangens hiperboliczny *(tanh*). Obie te funkcje wykazują właściwość saturacji - ich wartości dążą do stałego maksimum

[10] A. Géron, Uczenie maszynowe z użyciem Scikit-Learn i TensorFlow, Helion, Gliwice 2020, s. 488 - 490.
[11] I. Goodfellow, Y. Bengio, A. Courville, Deep Learning, MIT Press, Cambridge 2016, s. 110.

lub minimum przy dużych wartościach argumentu, co skutkuje niewielkimi gradientami i może znacząco utrudniać efektywne uczenie sieci. Tangens hiperboliczny, przyjmujący wartości w zakresie od –1 do 1, charakteryzuje się korzystniejszymi właściwościami niż funkcja sigmoidalna, ponieważ w punkcie zerowym jego wartość również wynosi 0, co pozwala lepiej zachować informację o kierunku zmian danych wejściowych. Z tego względu *tanh* jest preferowaną funkcją aktywacji w sytuacjach, w których stosowanie jednostek sigmoidalnych jest konieczne mimo ich ograniczeń.[12]

W klasycznych rekurencyjnych sieciach neuronowych każda jednostka obliczeniowa przetwarza dane wejściowe sekwencyjnie, uwzględniając nie tylko aktualne wartości, lecz także informacje z poprzednich kroków czasowych. Kluczowym elementem tej architektury jest tzw. komórka pamięci, która odpowiada za przechowywanie i aktualizowanie stanu ukrytego przy każdej iteracji czasowej. Dzięki temu sieć może modelować zależności o charakterze dynamicznym i długoterminowym. W podstawowej wersji architektury, zwanej komórką podstawową, stan ukryty oznaczany jako $h_{(t)}$ jest funkcją danych wejściowych z bieżącego kroku $x_{(t)}$oraz stanu ukrytego z poprzedniego kroku $h_{(t-1)}$. W przypadku prostych rekurencyjnych sieci neuronowych wyjście komórki $y_{(t)}$ utożsamiane jest z jej stanem $h_{(t)}$. W bardziej zaawansowanych architekturach, takich jak LSTM czy GRU obie te wartości mogą się różnić w zależności od użytych mechanizmów bramek. Proces ten można zapisać formalnie jako:

$$h_t = f\left(h_{(t-1)},\, x_t\right).^{13} \tag{3.3}$$

Proces uczenia rekurencyjnych sieci neuronowych opiera się na algorytmie propagacji wstecznej w czasie. Aby możliwe było nauczenie rekurencyjnej sieci neuronowej, należy najpierw rozwinąć ją w czasie, co oznacza, że dla każdego kroku czasowego zostaje utworzona osobna instancja obliczeniowa, zachowująca wspólne parametry wagowe. Następnie, na podstawie ciągu wejść $X_{(0)}, X_{(1)},\ldots, X_{(T)}$, sieć generuje odpowiadające im wyjścia $Y_{(0)}$, $Y_{(1)},\ldots,$ $Y_{(T)}$. Uzyskana sekwencja wyników podlega

[12] Ibidem, s.195.
[13] A. Géron, op.cit., 490.

ocenie za pomocą funkcji kosztu $C(Y_{(0)}, Y_{(1)},\ldots, Y_{(T)})$, która może zarówno uwzględniać wszystkie wyjścia, jak i ignorować niektóre z nich. [14]

W problemach regresyjnych często stosuje się funkcję kosztu w postaci błędu średniokwadratowego, który mierzy różnicę między wartością przewidywaną a rzeczywistą. Minimalizacja tej funkcji prowadzi do uzyskania funkcji regresji będącej średnią warunkową zmiennej docelowej. Taki wybór gwarantuje optymalną predykcję w sensie minimalnego błędu.[15]

Po obliczeniu wartości funkcji kosztu, gradienty są propagowane wstecznie przez wszystkie kroki czasowe zgodnie z zasadami metody propagacji wstecznej w czasie. Metoda ta umożliwia uaktualnienie parametrów całej sieci na podstawie zbiorczego błędu obliczonego dla wszystkich pozycji czasowych. Gradienty wyliczane w trakcie tego procesu nie są ograniczone jedynie do ostatniego wyjścia, lecz rozpowszechniane są przez wszystkie ramki czasowe. Ten sposób aktualizacji prowadzi do korekty współdzielonych wag W oraz biasów b, które są wykorzystywane w każdym kroku czasowym. Dzięki temu model może uczyć się ogólnych wzorców sekwencyjnych bez potrzeby zwiększania liczby parametrów wraz z długością sekwencji.[16]

Pomimo zdolności rekurencyjnych sieci neuronowych do uwzględniania informacji z poprzednich kroków czasowych, w praktyce ich skuteczność w modelowaniu długich sekwencji bywa ograniczona. W trakcie propagacji wstecznej gradient odpowiadający odległym w czasie sygnałom może stopniowo zanikać lub ulegać nadmiernej amplifikacji, co skutkuje tzw. „zanikiem" lub „eksplozją" gradientu. Konsekwencją tych problemów jest znaczący spadek efektywności w zapamiętywaniu informacji z dalszych części sekwencji, co określa się często jako ograniczoną pamięć krótkotrwałą RNN. Na potrzeby rozwiązania tego ograniczenia wprowadzono mechanizmy bramek kontrolujących przepływ informacji, takie jak komórki LSTM i GRU, które umożliwiają efektywne zachowanie istotnych wzorców w długich sekwencjach.[17]

---

[14] Ibidem, s. 492.
[15] C. M. Bishop, Pattern Recognition and Machine Learning, Springer, New York 2006, s. 46 - 48.
[16] A. Géron, op.cit., s. 492.
[17] S.-H. Noh, Analysis of Gradient Vanishing of RNNs and Performance Comparison, „Information" 2021, t. 12, nr 11, art. 442, s. 1 - 11, https://doi.org/10.3390/info12110442.

3.2. Sieć neuronowa z mechanizmem bramkowania w strukturze rekurencyjnej

Gated Recurrent Unit (GRU) to typ rekurencyjnej sieci neuronowej, który po raz pierwszy został zaprezentowany w 2014 roku przez zespół badaczy pod kierunkiem Kyunghyuna Cho jako uproszczona wersja architektury LSTM. Celem opracowania GRU było stworzenie modelu zdolnego do przetwarzania danych sekwencyjnych z zachowaniem kluczowych informacji z przeszłości, przy jednoczesnym ograniczeniu złożoności obliczeniowej. [18]

Jednostki GRU stanowią szczególną odmianę rekurencyjnych sieci neuronowych, w której przepływ informacji wewnątrz modelu kontrolowany jest za pomocą dwóch mechanizmów bramkujących: bramki aktualizacji $z_{(t)}$ oraz bramki resetującej $r_{(t)}$ (Rysunek 3.1). Pierwsza z nich odpowiada za kontrolę nad tym, w jakim stopniu informacja z poprzedniego stanu ukrytego $h_{(t-1)}$ powinna zostać zachowana, natomiast druga określa, która część stanu poprzedniego zostanie ukazana w warstwie głównej $g_{(t)}$. Formalnie działanie GRU opisują następujące równania:

$$z_{(t)} = \sigma(W_{xz}^T x_{(t)} + W_{hz}^T h_{(t-1)} + b_z, \tag{3.4}$$

$$r_{(t)} = \sigma(W_{xr}^T x_{(t)} + W_{hr}^T h_{(t-1)} + b_r,, \tag{3.5}$$

$$\mathrm{g}_{(t)} = tanh(W_{x\mathrm{g}}^T x_{(t)} + W_{h\mathrm{g}}^T (r_{(t)} \otimes h_{(t-1)}) + b_{\mathrm{g}}), \tag{3.6}$$

$$h_{(t)} = z_{(t)} \otimes h_{(t-1)} + (1 - z_{(t)}) \otimes g_{(t)}. \tag{3.7}$$

gdzie W_{xz}^T, W_{hz}^T, W_{xr}^T, W_{hr}^T, W_{xg}^T, $W_{h\mathrm{g}}^T$, b_z, b_r, b_{g} są parametrami modelu, natomiast $\otimes$ oznacza iloczyn elementów odpowiadających sobie wektorów. Funkcja aktywacji σ to klasyczna funkcja sigmoidalna, gwarantująca, że wartości bramek mieszczą się

[18] K. Cho, B. van Merriënboer, D. Bahdanau, Y. Bengio, Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation, „Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing" 2014, s. 1724 - 1734, https://doi.org/10.48550/arXiv.1406.1078.

w przedziale (0, 1). Dzięki nieliniowościom o charakterze saturacyjnym (funkcje σ i *tanh*), wartości stanu ukrytego pozostają ograniczone do przedziału [-1, 1], nawet jeśli początkowo znajdowały się poza tym zakresem. Taki mechanizm prowadzi do ich asymptotycznej stabilizacji wewnątrz tej przestrzeni.[19]

Szczególną rolę odgrywa bramka aktualizacji $z_{(t)}$ która umożliwia jednostce GRU dynamiczne dopasowanie „stałej czasowej" procesu zapamiętywania. W skrajnym przypadku, gdy $z_{(t)} \rightarrow 1$, model dąży do pełnego zachowania poprzedniego stanu, ignorując nowe dane wejściowe, co odpowiada mechanizmowi pamięci trwałej. Z tego względu GRU mogą zachowywać informacje przez dłuższy czas, co czyni je szczególnie efektywnymi w modelowaniu długoterminowych zależności czasowych.[20]

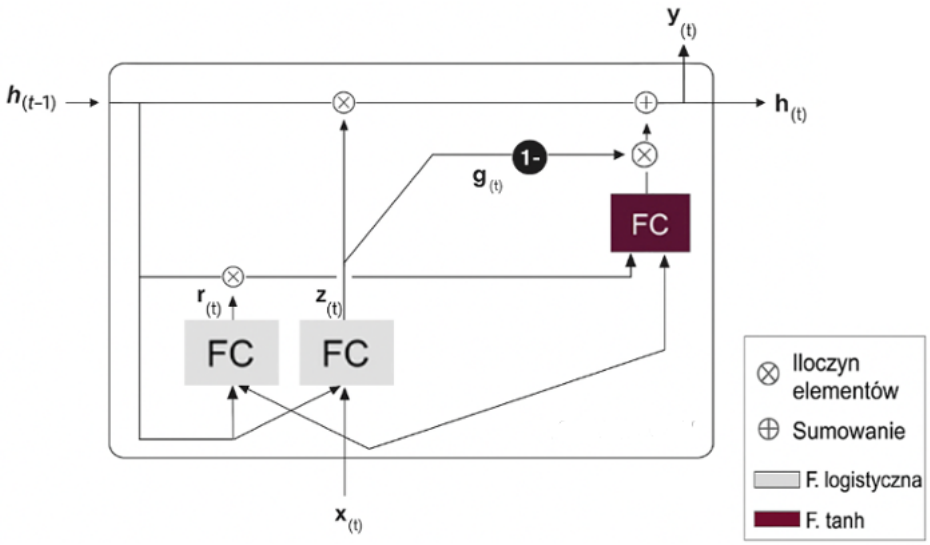

Rysunek 3.1. Komórka GRU

Źródło: A. Géron, Uczenie maszynowe z użyciem Scikit-Learn i TensorFlow, Helion, Gliwice 2020, s. 507. Modyfikacja własna

[19] I. D. Jordan, P. A. Sokół, I. M. Park, Gated Recurrent Units Viewed Through the Lens of Continuous Time Dynamical Systems, „Frontiers in Computational Neuroscience" 2021, t. 15, s. 2 - 3, https://doi.org/10.3389/fncom.2021.678158.
[20] Ibidem.

3.3. Sieć neuronowa z mechanizmem długiej pamięci krótkotrwałej

Architektura Long Short-Term Memory (LSTM) została zaproponowana przez Seppa Hochreitera i Jürgena Schmidhubera w 1997 roku jako rozwiązanie umożliwiające modelowanie długoterminowych zależności w sekwencjach danych.[21]

Kluczowym elementem tej struktury jest specjalna jednostka - komórka LSTM (Rysunek 3.2) - której zadaniem jest regulacja przepływu informacji przez sieć w kolejnych krokach. Komórka ta wyposażona jest w mechanizmy bramek sterujących, które umożliwiają selektywne zapamiętywanie, zapominanie oraz przekazywanie informacji dalej w czasie. Z zewnątrz jej działanie przypomina klasyczną komórkę rekurencyjną, jednak wewnętrzna struktura została rozszerzona o dwa wektory reprezentujące różne typy pamięci: stan krótkotrwały oznaczany jako $h_{(t)}$ oraz stan długotrwały $c_{(t)}$.[22]

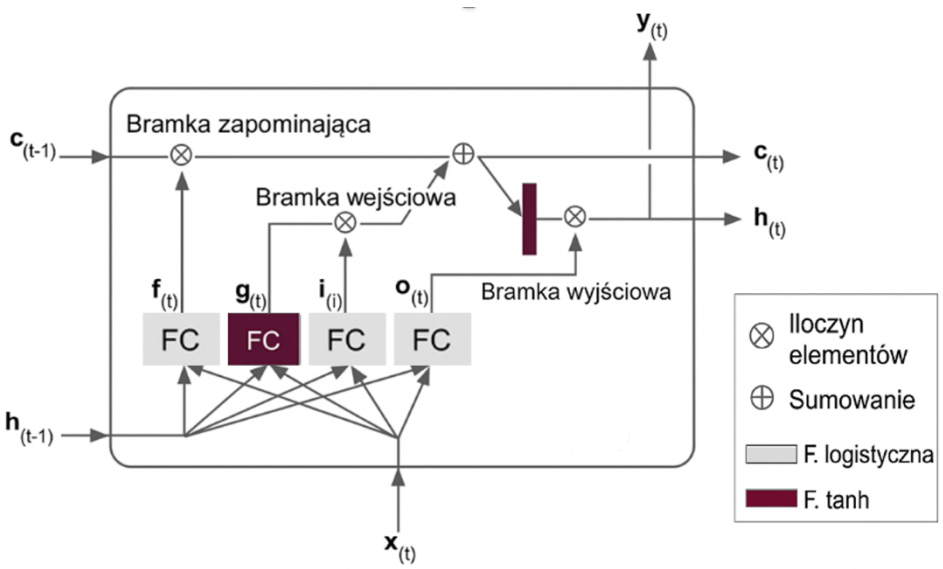

Rysunek 3.2. Komórka LSTM

Źródło: A. Géron, Uczenie maszynowe z użyciem Scikit-Learn i TensorFlow, Helion, Gliwice 2020, s. 504. Modyfikacja własna

[21] S. Hochreiter, J. Schmidhuber, Long Short-Term Memory, „Neural Computation" 1997, t. 9, nr 8, s. 1735 - 1780, https://doi.org/10.1162/neco.1997.9.8.1735.
[22] I. Malashin, V. Tynchenko, A. Gantimurov, V. Nelyub, A. Borodulin, Applications of Long Short-Term Memory (LSTM) Networks in Polymeric Sciences: A Review, „Polymers" 2024, t. 16, nr 18, art. 2607, s. 2 – 4, https://doi.org/10.3390/polym16182607.

Główna zasada działania komórki LSTM polega na tym, że sieć uczy się, które informacje należy przechowywać w pamięci długotrwałej, które usunąć, a które wykorzystać przy generowaniu wyjścia. Przesyłany między kolejnymi krokami czasowymi wektor $c_{(t-1)}$ najpierw trafia do bramki zapominającej, która redukuje zawartość nieistotnych danych. Następnie, poprzez bramkę wejściową, do wektora dodawane są nowe informacje – tylko te, które uzyskały pozytywną selekcję. W ten sposób powstaje zaktualizowany stan komórki $c_{(t)}$, który przesyłany jest dalej bez przekształceń. W kolejnym kroku stan długotrwały jest duplikowany i przekształcany nieliniowo przez funkcję tangens hiperboliczny. Następnie wynik tej operacji przechodzi przez bramkę wyjściową, co pozwala uzyskać nowy stan krótkotrwały $h_{(t)}$, będący równocześnie sygnałem wyjściowym komórki dla danego kroku czasowego $y_{(t)}$.[23]

Wejściowy wektor $x_{(t)}$ oraz poprzedni stan krótkotrwały $h_{(t-1)}$ są jednocześnie przekazywane do czterech niezależnych warstw połączeń pełnych, z których każda pełni odrębną funkcję. Jedna z tych warstw generuje wektor $g_{(t)}$, odpowiadający za analizę bieżących danych oraz poprzedniego stanu. W odróżnieniu od podstawowej komórki RNN, która wypuszcza tę wartość jako wyjście, w LSTM wartość $g_{(t)}$ nie trafia bezpośrednio na zewnątrz, lecz podlega selekcji - tylko niektóre jej składowe trafiają do pamięci, reszta jest odrzucana. Pozostałe trzy warstwy pełnią funkcję sterującą działaniem bramek. Ich aktywacje obliczane są za pomocą funkcji logistycznej, co oznacza, że przyjmują wartości z przedziału od 0 do 1. Są one następnie mnożone element po elemencie z innymi wektorami - co powoduje, że wartości bliskie zeru dezaktywują dane ścieżki, a wartości bliskie jedności je aktywują. Bramka zapominająca, kontrolowana przez wektor $f_{(t)}$, decyduje, które dane należy usunąć ze stanu długoterminowego. Bramka wejściowa, sterowana przez $i_{(t)}$, wskazuje, które wartości z $g_{(t)}$ należy dodać do pamięci. Z kolei bramka wyjściowa, zależna od $o_{(t)}$, ustala, które przekształcone składniki stanu długoterminowego należy udostępnić na wyjściu, zarówno do $h_{(t)}$ jak i do $y_{(t)}$. Opis działania komórki LSTM przedstawiają poniższe równania:

$$i_{(t)} = \sigma(W_{xi}^{T} x_{(t)} + W_{hi}^{T} h_{(t-1)} + b_i, \tag{3.8}$$

[23] A. Géron, op.cit., s. 503 - 504.

$$f_{(t)} = \sigma(W_{xf}^T x_{(t)} + W_{hf}^T h_{(t-1)} + b_f, \tag{3.9}$$

$$o_{(t)} = \sigma(W_{xo}^T x_{(t)} + W_{ho}^T h_{(t-1)} + b_o, \tag{3.10}$$

$$g_{(t)} = tanh(W_{xg}^T x_{(t)} + W_{hg}^T h_{(t-1)} + b_g, \tag{3.11}$$

$$c_{(t)} = f_{(t)} \otimes c_{(t-1)} + i_{(t)} \otimes g_{(t)}, \tag{3.12}$$

$$y_{(t)} = h_{(t)} = o_{(t)} \otimes tanh(c_{(t)}), \tag{3.13}$$

gdzie:

W_{x*} - macierz wag dla połączeń z wektorem wejściowym $x_{(t)}$,

W_{h*} - macierz wag dla połączeń z poprzednim stanem krótkotrwałym $h_{(t-1)}$,

b_{x*} - odpowiednie wektory obciążenia.[24]

3.4. Metryki oceny jakości prognoz

W celu oceny skuteczności modeli prognostycznych istotne jest zastosowanie odpowiednich miar błędu, które umożliwiają ilościową analizę rozbieżności między wartościami prognozowanymi a rzeczywistymi. W omawianym badaniu wykorzystano metryki badające dokładność prognozowania *ex post*.

Pierwiastek błędu średniokwadratowego – RMSE – jest metryką mierzącą średnią różnicę między przewidywanymi a rzeczywistymi wartościami. Stanowi miarę wielkości błędów i jest szczególnie wrażliwy na duże odchylenia, przez co silniej karze pojedyncze błędy o dużej wartości. Wyznaczany jest zgodnie ze wzorem:

$$RMSE = \sqrt{\frac{1}{n}\sum_{t=1}^{n}(Y_t - Y_t^P)^2}, \tag{3.14}$$

[24] Ibidem, s. 505 - 506.

gdzie:

n - liczba wartości prognozowanych zmiennej objaśnianej,

t - indeks wartości prognozowanej, *t = 1, 2, ..., n*,

Y_t - rzeczywista wartość zmiennej objaśnianej,

Y_t^P - prognozowana wartość zmiennej objaśnianej.

Wartość średniego błędu absolutnego - MAE - wskazuje na średnią wielkość bezwzględnych różnic pomiędzy prognozami a wartościami rzeczywistymi. Wyznaczana jest ze wzoru:

$$MAE = \frac{1}{n}\sum_{t=1}^{n} | Y_t - Y_t^P |, \tag{3.15}$$

gdzie:

n - liczba wartości prognozowanych zmiennej objaśnianej,

t - indeks wartości prognozowanej, *t = 1, 2, ..., n*,

Y_t - rzeczywista wartość zmiennej objaśnianej,

Y_t^P - prognozowana wartość zmiennej objaśnianej.[25]

Ciekawą własnością wyżej opisanych metryk jest interpretacja, zgodnie z którą znacząca różnica pomiędzy RMSE i MAE świadczy o występowaniu błędów predykcji o bardzo dużych wartościach.

Średni bezwzględny błąd procentowy - MAPE - pozwala na określenie średniej wielkości błędów prognoz wyrażonych w procentach. Metryka ta jest szczególnie przydatna, gdy celem jest wyrażenie błędu względnie do skali danych i dostarcza istotnych informacji w przypadku zmiennych o zróżnicowanej wielkości. Tym samym w przeprowadzanym badaniu pozwala na porównanie modeli dla różnych okresów. Wyrażony jest wzorem:

$$MAPE = \frac{\sum_{t=1}^{n}\left|\frac{Y_t - Y_t^P}{Y_t}\right|}{n} \times 100\%, \tag{3.16}$$

[25] M. Gruszczyński, T. Kuszewski, M. Podgórska (red.), Ekonometria i badania operacyjne, Wydawnictwo Naukowe PWN, Warszawa 2013, s. 111 - 112.

gdzie:

n - liczba wartości prognozowanych zmiennej objaśnianej,

t - indeks wartości prognozowanej, t = 1, 2, …, n,

Y_t - rzeczywista wartość zmiennej objaśnianej,

Y_t^P - prognozowana wartość zmiennej objaśnianej .[26]

Współczynnik determinacji - R^2 - stanowi miarę dopasowania modelu do danych empirycznych, określa on jaka część zmienności zmiennej objaśnianej jest wyjaśniona przez model. Można go przedstawić za pomocą wzoru:

$$R^2 = \frac{\sum_{t=1}^{n}(Y_t^P - \bar{Y})^2}{\sum_{t=1}^{n}(Y_t - \bar{Y})^2}, \tag{3.17}$$

gdzie:

n - liczba wartości prognozowanych zmiennej objaśnianej,

t - indeks wartości prognozowanej, *t = 1, 2, ..., n*,

Y_t - rzeczywista wartość zmiennej objaśnianej,

Y_t^P - prognozowana wartość zmiennej objaśnianej,

$\bar{Y}$ - średnia wartość zmiennej objaśnianej.[27]

[26] R. J. Hyndman, G. Athanasopoulos, Forecasting: Principles and Practice, wyd. 3, OTexts, Melbourne 2021, https://otexts.com/fpp3/accuracy.html [dostęp: 2.06.2025].
[27] M. Gruszczyński, T. Kuszewski, M. Podgórska (red.), op. cit., s. 51 - 52.

4. Badanie empiryczne

Rozdział czwarty poświęcony jest części empirycznej badania, w której w pierwszej kolejności dokonano doboru odpowiednich konfiguracji hiperparametrów dla każdej z implementowanych architektur rekurencyjnych sieci neuronowych. Implementacja modeli została zrealizowana w języku Python z użyciem bibliotek TensorFlow, Keras, NumPy oraz Pandas, przy czym do wizualizacji wyników wykorzystano bibliotekę Matplotlib. Dodatkowo zastosowano funkcje z biblioteki Scikit-learn w celu obliczenia metryk oceny jakości prognoz. Przedstawiono wyniki uzyskane dla modeli RNN, GRU oraz LSTM w odniesieniu do rynków rozwiniętych i wschodzących, z uwzględnieniem zróżnicowanych warunków rynkowych: okresu stabilizacji, pandemii COVID-19 oraz wojny w Ukrainie. Uzyskane rezultaty stanowią podstawę do analizy porównawczej efektywności poszczególnych modeli, zawartej w kolejnym rozdziale.

4.1. Dobór i konfiguracja hiperparametrów architektury sieci neuronowych

Niniejszy rozdział poświęcony jest budowie odpowiednich struktur rekurencyjnych sieci neuronowych dla wyszczególnionych szeregów czasowych. Celem zapewnienia porównywalności wyników, dla każdego z trzech analizowanych wariantów sieci, zastosowano identyczny zakres hiperparametrów w ramach procedury symulacyjnej. Przeszukiwanie siatki polega na dyskretyzacji dopuszczalnych zakresów każdego hiperparametru na skończone zbiory wartości (rozdzielczość siatki) oraz wyczerpującej ewaluacji każdej możliwej kombinacji.[28] Zabieg ten umożliwia obiektywną ocenę poszczególnych architektur w tych samych warunkach. Ze względu na brak występowania wzorca, według którego możliwa byłaby budowa optymalnej struktury sieci, w celu znalezienia najlepszego zestawu hiperparametrów dla danego zestawu

[28] B. Bischl i in., Hyperparameter Optimization: Foundations, Algorithms, Best Practices, and Open Challenges, „WIREs Data Mining and Knowledge Discovery" 2023, t. 13, nr 2, s. 7 - 8, https://doi.org/10.1002/widm.1484.

danych, przeprowadzono badania symulacyjne, testując różne kombinacje hiperparametrów:

- długość okna sekwencji wejściowej: [10; 20; 60],
- liczba neuronów w pierwszej warstwie ukrytej: [32; 64; 96],
- liczba warstw ukrytych: [1; 2; 3],
- architektura sieci: [równomierna: jednakowa liczba neuronów w każdej z warstw, degresywna: zmniejszanie liczby warstw o połowę względem warstwy poprzedzającej],
- rozmiar partii: [8; 16; 32],
- liczba epok: [10; 30; 50],
- współczynnik dropout: [0,0; 0,2].

W doborze hiperparametrów oraz ich wartości kierowano się zarówno eksperymentami zaobserwowanymi w literaturze, jak i własnymi obserwacjami powstałymi w procesie eksploracyjnej analizy danych na poszczególnych szeregach czasowych. Dobór wartości liczbowych do badania symulacyjnego był w dużej mierze determinowany przez ograniczenia ilościowe danych, wynikające z podziału na okresy, co z kolei jest uzasadnione merytorycznie.

W przypadku długości okna sekwencji wejściowej, czyli liczby kolejnych obserwacji, na podstawie których model tworzy prognozę na dzień następny, zdecydowano się odpowiednio na wartości 10, 20, 60, co pozwala na zbadanie zależności od krótkoterminowych po długoterminowe (dwutygodniowe, miesięczne, kwartalne). Krótsze sekwencje wysoce korelują z szybszymi reakcjami modelu na bieżące zmiany, dzięki czemu wykazują się skutecznością w warunkach o wysokiej zmienności. Natomiast sekwencje dłuższe przydatne są w wykrywaniu trendów długoterminowych. Z kolei liczba neuronów w pierwszej warstwie została dobrana w taki sposób, aby zapewnić przekrojową analizę pod względem złożoności modelu, począwszy od 32 neuronów, sprzyjających prostocie oraz szybkości treningu, po 96 neuronów, umożliwiających uchwycenie bardziej złożonych zależności czasowych. Analogiczne podejście zastosowano w przypadku wyboru liczby warstw ukrytych, kierując się wartościami najczęściej spotykanymi w badaniach eksperymentalnych, czyli zakres od 1 do 3. Za jeden z hiperparametrów przyjęto również typ architektury sieci - równomierna oraz degresywna. Najczęściej spotykanym wariantem jest stała pojemność warstw,

jednakże w badaniach zauważono, że zmniejszanie liczby neuronów może mieć pozytywny wpływ na stabilność procesu uczenia. Uczenie modelu oparte będzie także na analizie znaczenia wielkości partii, co determinuje liczbę próbek danych oraz ich długość przetwarzanych w pojedynczej epoce. Mniejsze wartości skutkują częstszymi aktualizacjami wag połączeń pomiędzy neuronami, co może mieć pozytywny wpływ na zdolności generalizacji modelu. Natomiast wartości wyższe stabilizują proces, zwiększając jednak ryzyko przeuczenia modelu. Tym samym, w opisywanej procedurze analizie poddano partie o wielkości równej 8, 16 oraz 32. Testowane wartości hiperparametru zostały dobrane zgodnie z najczęściej spotykanymi praktykami. Analogiczne podejście determinowało wybór liczby epok, czyli pełnych przejść przez zbiór treningowy. Trening krótszy wiąże się z ryzykiem niedouczenia, natomiast dłuższy pozwala na lepsze dopasowanie danych, lecz może prowadzić do przeuczenia modelu. Celem uniknięcia ostatniego ze wspomnianych zjawisk, zastosowano mechanizm wczesnego zatrzymania treningu w przypadku braku poprawy błędu walidacyjnego w kolejnych pięciu epokach oraz uwzględnienie wpływu współczynnika dropout z prawdopodobieństwem równym 0,2, czyli losowym wyłączaniu 20% neuronów przy każdej aktualizacji. Wartość prawdopodobieństwa została dobrana zgodnie z zaleceniami dla małych zbiorów danych.[29]

Do optymalizacji wag sieci wykorzystano optymalizator Adam z domyślną wartością współczynnika uczenia równą 0,001, będący najczęściej wykorzystywaną metodą w problemach regresyjnych ze względu na wysoką skuteczność i stabilność uczenia, spowodowaną jego zdolnością do automatycznego dostosowywania tempa uczenia dla każdego parametru indywidualnie.[30] Natomiast za funkcję straty przyjęto średni błąd kwadratowy, który bardzo dobrze odzwierciedla różnice pomiędzy wartościami rzeczywistymi a prognozowanymi, penalizując duże błędy prognoz.[31] W warstwach rekurencyjnych zastosowano domyślne dla frameworka Keras funkcje aktywacji, czyli *tanh* do przekształcania informacji wyjściowej oraz *sigmoid* dla bramek kontrolujących w przypadku modeli GRU i LSTM.

---

[29] H. Hewamalage, C. Bergmeir, K. Bandara, Recurrent Neural Networks for Time Series Forecasting: Current status and future directions, „International Journal of Forecasting" 2021, t. 37, nr 1, s. 388 - 427, https://doi.org/10.1016/j.ijforecast.2020.06.008.

[30] D. P. Kingma, J. Ba, Adam: A Method for Stochastic Optimization., „Proceedings of the International Conference on Learning Representations" 2015, s. 1 - 15, https://arxiv.org/abs/1412.6980.

[31] J. Terven, D.-M. Cordova-Esparza, J.-A. Romero-González, A. Ramírez-Pedraza, E. A. Chávez-Urbiola, A comprehensive survey of loss functions and metrics in deep learning, „Artificial Intelligence Review" 2025, t. 58, art. 195, s. 9 - 12, https://doi.org/10.1007/s10462-025-11198-7.

Spośród wygenerowanych tym sposobem modeli, w kolejnym kroku wybrano najefektywniejszą strukturę sieci dla danego szeregu czasowego, kierując się przy tym poszukiwaniem minimalnej wartości błędu średniokwadratowego oraz weryfikacją modelu w kontekście przeuczenia przy pomocy odpowiednich wykresów strat.

4.2. Prognoza indeksów giełdowych z wykorzystaniem prostych sieci rekurencyjnych

W niniejszym etapie analizy przedstawiono zastosowanie prostych rekurencyjnych sieci neuronowych w prognozie wartości wspominanych wcześniej indeksów globalnych MSCI World oraz MSCI Emerging Markets podzielonych tematycznie względem okresów historycznych. Dla każdej z instancji danych, w kolejnych podrozdziałach zaprezentowano szczegółowe wyniki dla najlepszego modelu, a dokładniej zestaw hiperparametrów, metryki oceny jakości predykcji oraz graficzną prezentację prognozy.

4.2.1. Prognoza indeksów giełdowych dla rynku rozwiniętego

W wyniku symulacji przeprowadzonych dla zestawów danych reprezentujących rynek rozwinięty wyłoniono najlepsze konfiguracje modeli odpowiednio dla okresu względnej stabilizacji, pandemii oraz wojny (Tabela 4.1). Analizując metryki oceny jakości predykcji (Tabela 4.2) można stwierdzić, iż otrzymane modele charakteryzują się wysoką jakością prognozy, przyjmując w każdym z badanych okresów wartość MAPE na wyjątkowo niskim poziomie - poniżej 0,5%. We wszystkich instancjach otrzymano również bardzo wysokie wartości współczynnika determinacji R^2 (powyżej 90%), a pomiędzy RMSE i MAE nie występują znaczące różnice, co świadczy o silnej zgodności wartości prognozowanych z rzeczywistymi danymi (Rysunek 4.1, Rysunek 4.2, Rysunek 4.3).

Tabela 4.1. Struktura poszczególnych prostych rekurencyjnych sieci neuronowych dla notowań indeksu MSCI World

Parametr	Okres		
	Stabilny	**Pandemii**	**Wojny**
Długość okna sekwencji wejściowej	10	20	60
Liczba neuronów w pierwszej warstwie ukrytej	64	64	96
Liczba warstw ukrytych	1	1	1
Architektura	równomierna	równomierna	równomierna
Rozmiar partii	16	8	16
Liczba epok	50	50	30
Współczynnik dropout	0,0	0,0	0,2

Źródło: Opracowanie własne

Tabela 4.2. Metryki błędu i dopasowania dla prognozy cen zamknięcia indeksu MSCI World w okresie stabilnym, pandemii i wojny (prosta sieć rekurencyjna)

Metryka	Okres		
	Stabilny	**Pandemii**	**Wojny**
RMSE	9,54	17,91	13,98
MAE	7,84	13,24	10,93
MAPE(%)	0,34	0,43	0,35
R^2	0,91	0,92	0,93

Źródło: Opracowanie własne

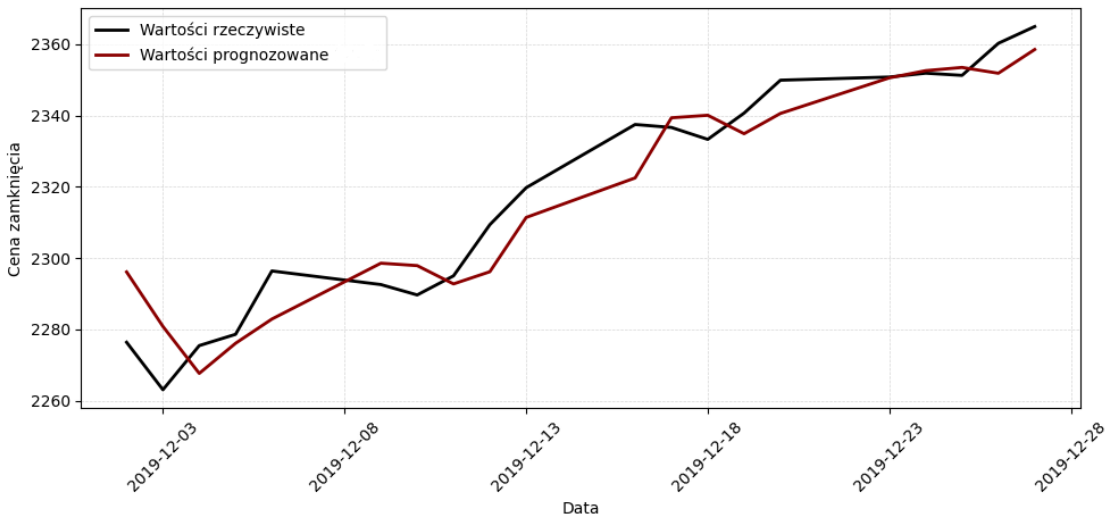

Rysunek 4.1. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI World w okresie stabilnymi (prosta sieć rekurencyjna)

Źródło: Opracowanie własne

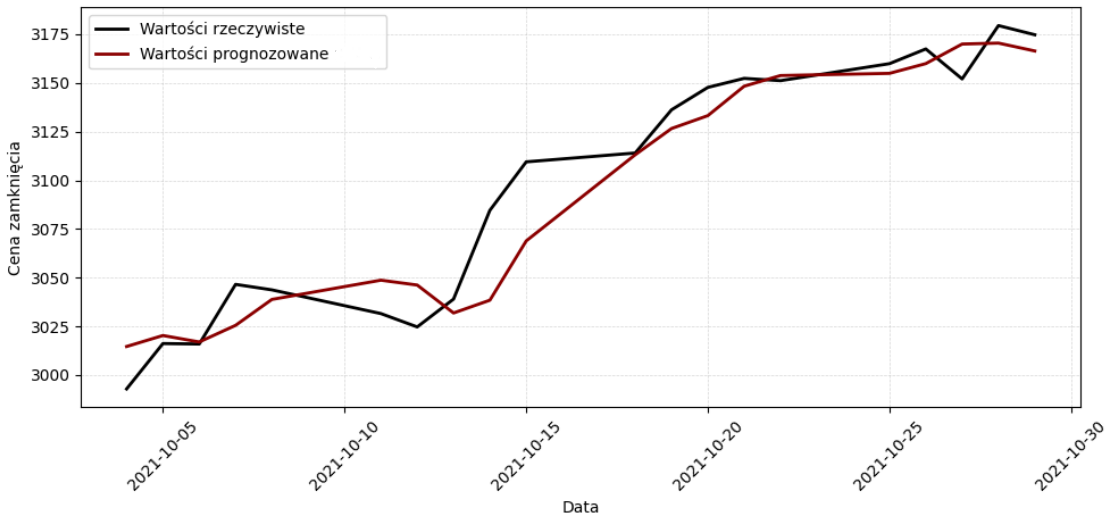

Rysunek 4.2. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI World w okresie pandemii (prosta sieć rekurencyjna)

Źródło: Opracowanie własne

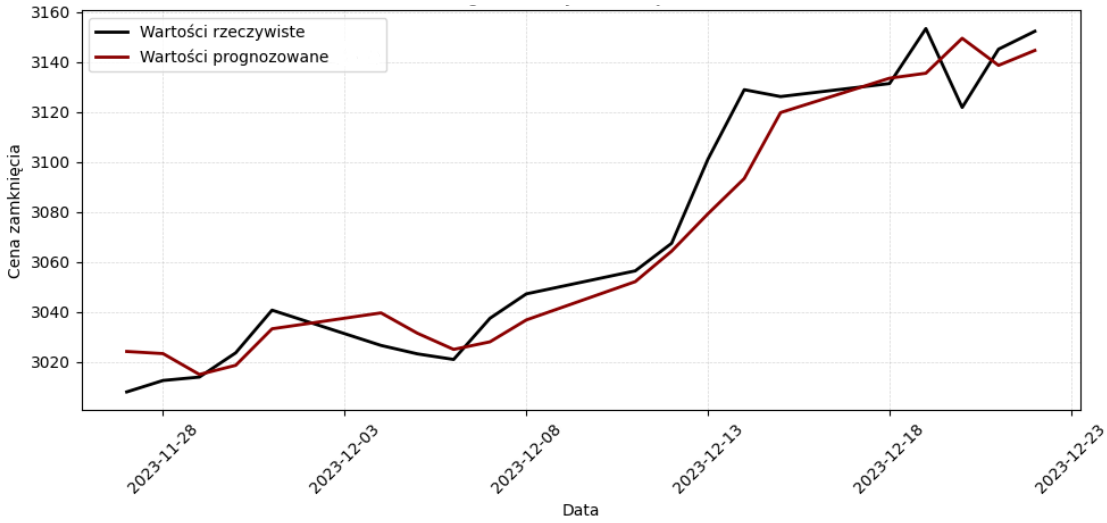

Rysunek 4.3. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI World w okresie wojny (prosta sieć rekurencyjna)

Źródło: Opracowanie własne

4.2.2. Prognoza indeksów giełdowych dla rynku wschodzącego

W procesie symulacji dla zestawów danych opisujących zachowanie indeksu MSCI Emerging Markets w wyodrębnionych fazach rynkowych, dobrano najlepsze kombinacje hiperparametrów (Tabela 4.3). Podczas analizy metryk oceniających jakość prognozy (Tabela 4.4), zauważono znaczne zróżnicowanie wśród modeli reprezentujących poszczególne fazy kondycji gospodarek. Bardzo niskim MAPE, gdyż wynoszącym zaledwie 0,42%, przy 97% wartości współczynnika R^2, wyróżnia się model prognozy indeksu dla rynku wschodzącego w okresie stabilnym. Wartości prognozowane pozostają w większości zgodne z rzeczywistym przebiegiem indeksu (Rysunek 4.4). W przypadku okresu szoku pandemicznego również osiągnięto zadowalające wyniki, MAPE na poziomie 0,67% oraz R^2 wynoszący 79%, co świadczy o dobrym dopasowaniu do danych rzeczywistych, mimo wysokiej zmienności danych (Rysunek 4.5). Jednakże, dla okresu wojennego, pomimo uzyskania niskiej wartości MAPE - 0,48%, wartość współczynnika determinacji wynosi zaledwie 64%, co jest widoczne na wykresie w postaci występujących opóźnień prognozy (Rysunek 4.6).

Tabela 4.3. Struktura poszczególnych prostych rekurencyjnych sieci neuronowych dla notowań indeksu MSCI Emerging Markets

Parametr	Okres		
	Stabilny	**Pandemii**	**Wojny**
Długość okna sekwencji wejściowej	10	10	10
Liczba neuronów w pierwszej warstwie ukrytej	64	96	64
Liczba warstw ukrytych	1	2	2
Architektura	równomierna	równomierna	degresywna
Rozmiar partii	8	8	8
Liczba epok	50	30	50
Współczynnik dropout	0,0	0,2	0,2

Źródło: Opracowanie własne

Tabela 4.4. Metryki błędu i dopasowania dla prognozy cen zamknięcia indeksu MSCI Emerging Markets w okresie stabilnym, pandemii i wojny (prosta sieć rekurencyjna)

Metryka	Okres		
	Stabilny	**Pandemii**	**Wojny**
RMSE	5,40	10,03	6,13
MAE	4,53	8,54	4,68
MAPE(%)	0,42	0,67	0,48
R^2	0,97	0,79	0,64

Źródło: Opracowanie własne

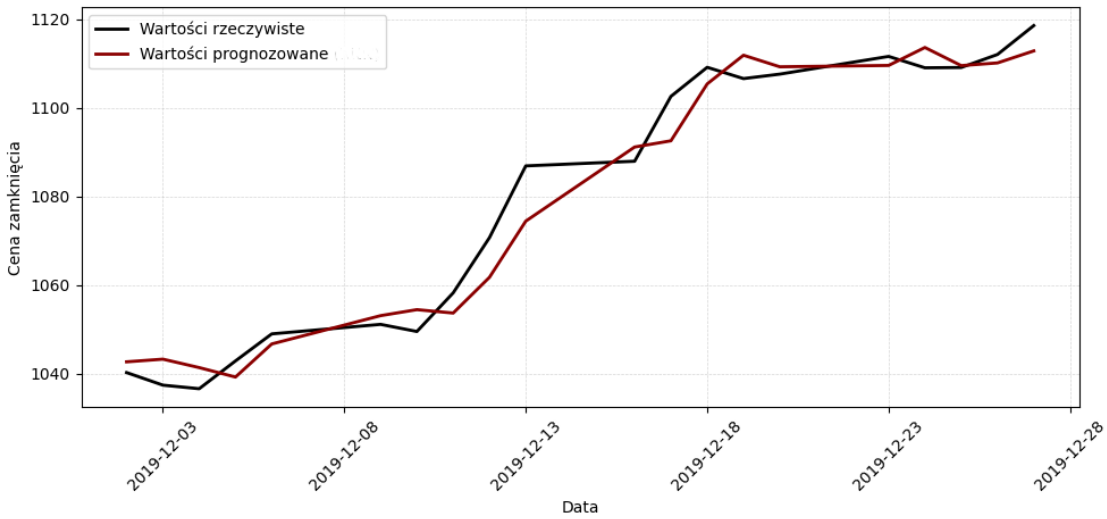

Rysunek 4.4. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI Emerging Markets w okresie stabilnym (prosta sieć rekurencyjna)

Źródło: Opracowanie własne

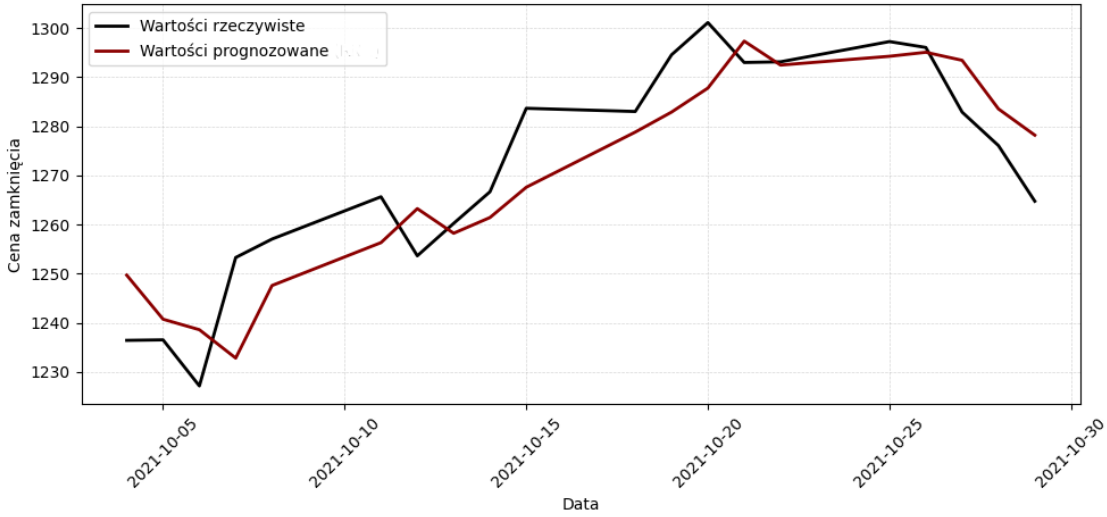

Rysunek 4.5. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI Emerging Markets w okresie pandemii (prosta sieć rekurencyjna)

Źródło: Opracowanie własne

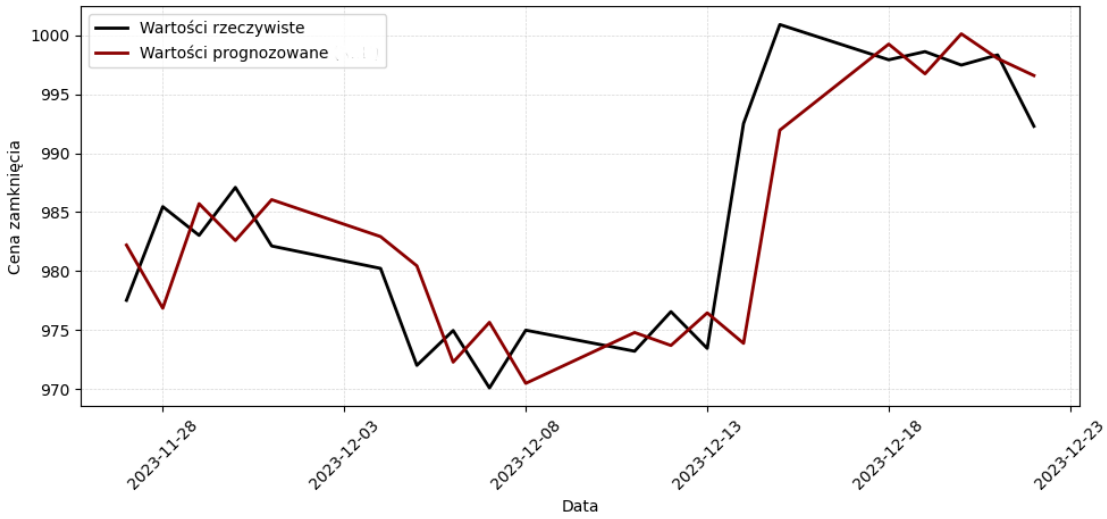

Rysunek 4.6. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI Emerging Markets w okresie wojny (prosta sieć rekurencyjna)

Źródło: Opracowanie własne

4.3. Prognoza indeksów giełdowych z wykorzystaniem rekurencyjnych sieci neuronowych typu GRU

W niniejszym podrozdziale zaprezentowano rezultaty przeprowadzonych symulacji dla szeregów czasowych opisujących zachowanie indeksów reprezentujących rynek rozwinięty oraz wschodzący z wykorzystaniem bramkowanych jednostek rekurencyjnych (GRU), przedstawiając szczegółowe konfiguracje hiperparametrów modelu, metryki oceny jakości predykcji, a także wizualizacje przebiegu prognoz.

4.3.1. Prognoza indeksów giełdowych dla rynku rozwiniętego

Wziąwszy pod uwagę kryterium minimalizacji RMSE oraz weryfikację modeli w kontekście przeuczenia sieci podczas treningu, dokonano wyboru najlepszych konfiguracji zestawu hiperparametrów dla notowań indeksu MSCI World w poszczególnych okresach (Tabela 4.5). Wyróżnione architektury sieci, w każdej z instancji umożliwiły stworzenie modelu cechującego się niską wartością MAPE - poniżej 0,5%, co wskazuje na bardzo wysoką dokładność prognozy w ujęciu względnym.

Jednocześnie, wysokie wartości współczynnika determinacji R^2, potwierdzają, że modele te skutecznie odwzorowują strukturę zmienności analizowanych notowań giełdowych (Tabela 4.6). Na rysunkach 4.7 – 4.9 przedstawiono przebieg wartości prognozowanych i rzeczywistych w każdym z trzech analizowanych okresów. Ryciny te stanowią wizualne potwierdzenie otrzymanych metryk.

Tabela 4.5. Struktura poszczególnych rekurencyjnych sieci neuronowych typu GRU dla notowań indeksu MSCI World

Parametr	**Okres**		
	Stabilny	**Pandemii**	**Wojny**
Długość okna sekwencji wejściowej	10	20	10
Liczba neuronów w pierwszej warstwie ukrytej	64	64	96
Liczba warstw ukrytych	1	1	1
Architektura	równomierna	równomierna	równomierna
Rozmiar partii	8	8	16
Liczba epok	50	10	50
Współczynnik dropout	0,0	0,2	0,0

Źródło: Opracowanie własne

Tabela 4.6. Metryki błędu i dopasowania dla prognozy cen zamknięcia indeksu MSCI World w okresie stabilnym, pandemii i wojny (model GRU)

Metryka	Okres		
	Stabilny	**Pandemii**	**Wojny**
RMSE	9,39	19,06	14,70
MAE	7,83	14,58	12,05
MAPE(%)	0,34	0,47	0,39
R^2	0,91	0,91	0,92

Źródło: Opracowanie własne

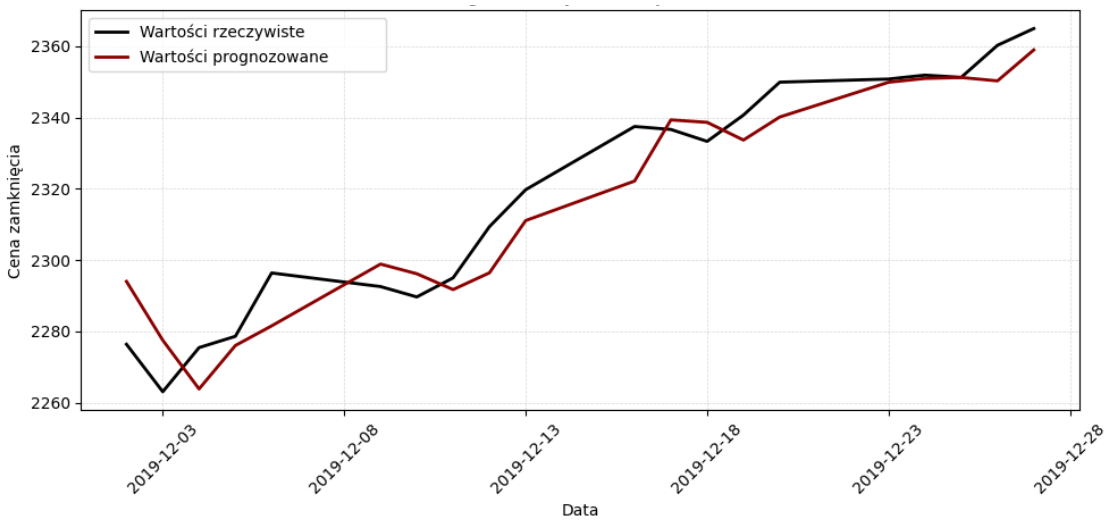

Rysunek 4.7. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI World w okresie stabilnym (model GRU)

Źródło: Opracowanie własne

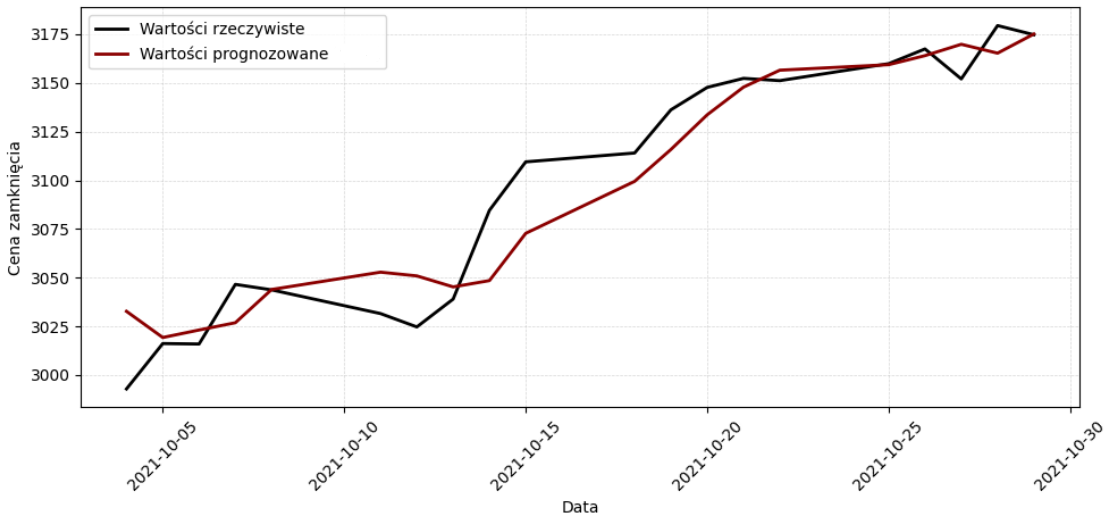

Rysunek 4.8. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI World w okresie pandemii (model GRU)

Źródło: Opracowanie własne

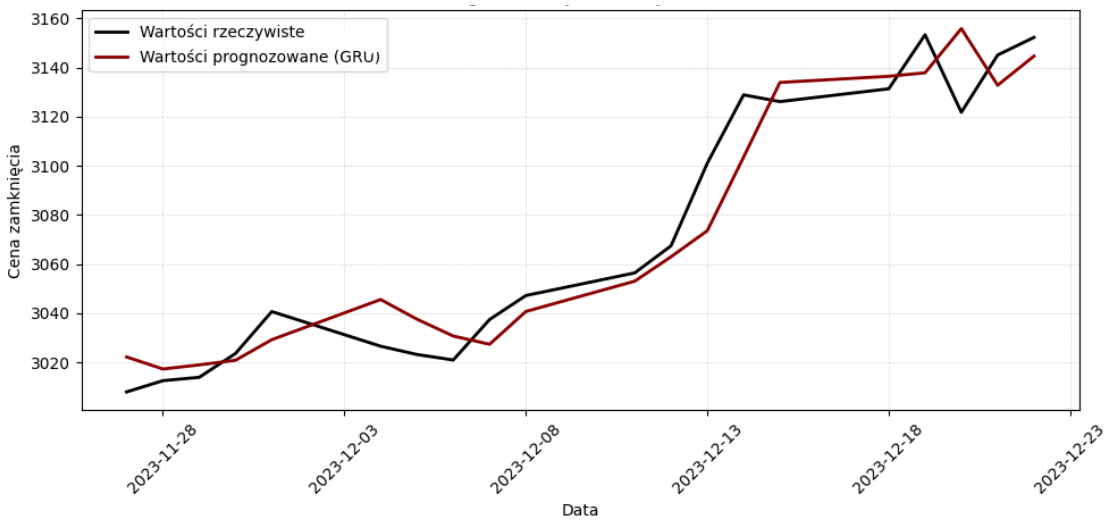

Rysunek 4.9. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI World w okresie wojny (model GRU)

Źródło: Opracowanie własne

4.3.2. Prognoza indeksów giełdowych dla rynku wschodzącego

Analiza modeli GRU dla rynku wschodzącego pozwoliła wyłonić optymalne zestawy hiperparametrów dla poszczególnych okresów historycznych (Tabela 4.7). Na podstawie

wartości względnego błędu predykcji oraz współczynnika dopasowania modelu do danych zaobserwowano zróżnicowaną skuteczność architektury w zależności od badanej fazy rynkowej (Tabela 4.8). Model opisujący zachowanie indeksu w okresie stabilnym wykazał się zaskakującą efektywnością w postaci MAPE na poziomie 0,42% oraz bardzo wysokiej wartości współczynnika determinacji R^2 wynoszącego 97%, co świadczy o silnej zgodności prognozowanych notowań z ich rzeczywistymi odpowiednikami (Rysunek 4.10). Architektura GRU osiągnęła również zadowalające wyniki dla okresu pandemicznego, gdzie otrzymano wartość R^2 równą 80% przy niskim błędzie względnym predykcji. Model ten, pomimo złożoności danych wejściowych, wykrył systematyczne wzorce występujące w czasie (Rysunek 4.11). Najgorzej sieć sprawdziła się w modelowaniu okresu o charakterze wojennym, osiągając R^2 na poziomie 60%, odwzorowując trend, jednakże z opóźnieniem (Rysunek 4.12).

Tabela 4.7. Struktura poszczególnych rekurencyjnych sieci neuronowych typu GRU dla notowań indeksu MSCI Emerging Markets

Parametr	**Okres**		
	Stabilny	**Pandemii**	**Wojny**
Długość okna sekwencji wejściowej	20	10	10
Liczba neuronów w pierwszej warstwie ukrytej	96	64	96
Liczba warstw ukrytych	3	2	3
Architektura	degresywna	równomierna	równomierna
Rozmiar partii	16	8	8
Liczba epok	50	50	50
Współczynnik dropout	0,0	0,0	0,2

Źródło: Opracowanie własne

Tabela 4.8. Metryki błędu i dopasowania dla prognozy cen zamknięcia indeksu MSCI Emerging Markets w okresie stabilnym, pandemii i wojny (model GRU)

Metryka	Okres		
	Stabilny	**Pandemii**	**Wojny**
RMSE	5,38	9,82	5,92
MAE	4,49	7,83	4,47
MAPE(%)	0,42	0,62	0,45
R^2	0,97	0,80	0,66

Źródło: Opracowanie własne

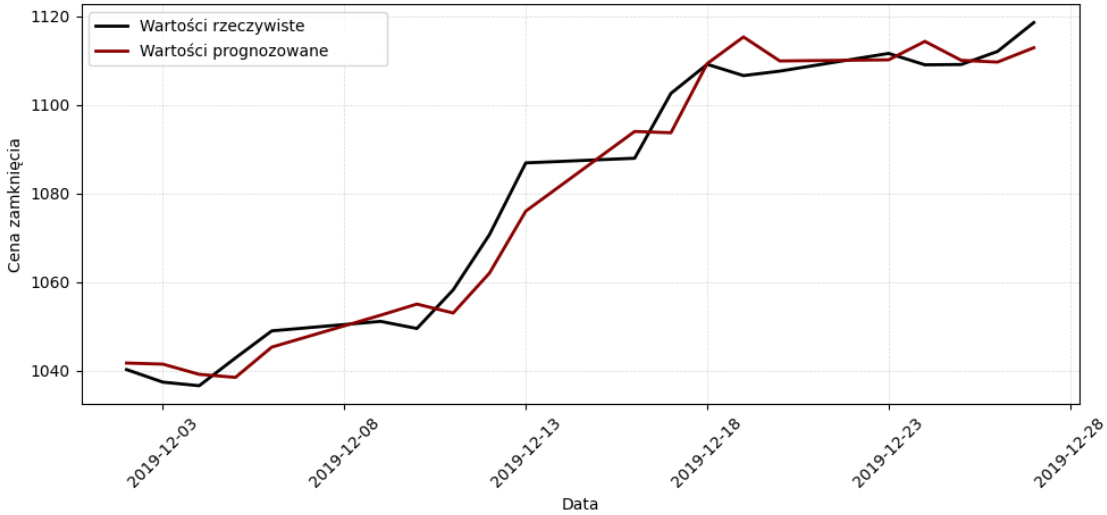

Rysunek 4.10. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI Emerging Markets w okresie stabilnym (model GRU)

Źródło: Opracowanie własne

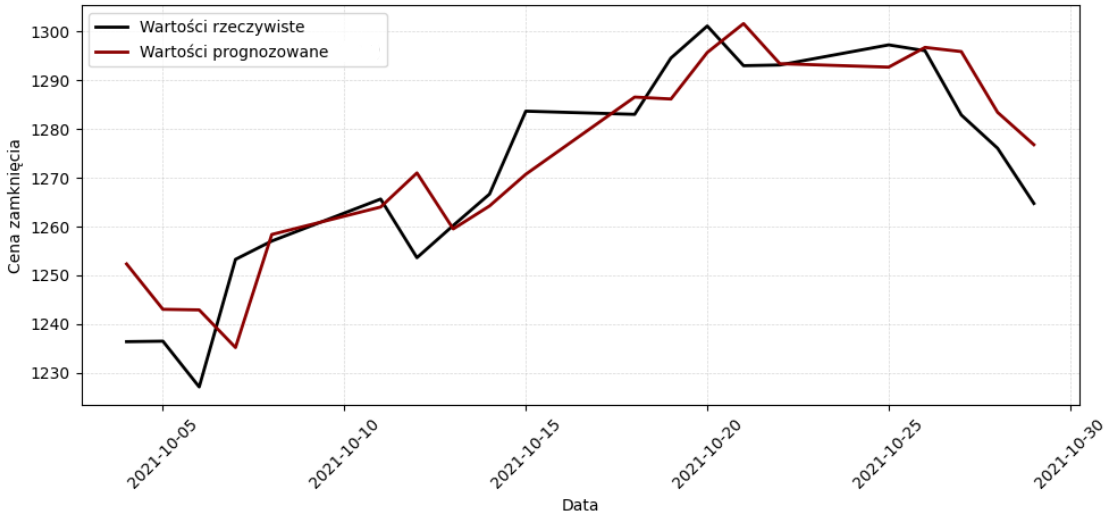

Rysunek 4.11. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI Emerging Markets w okresie pandemii (model GRU)

Źródło: Opracowanie własne

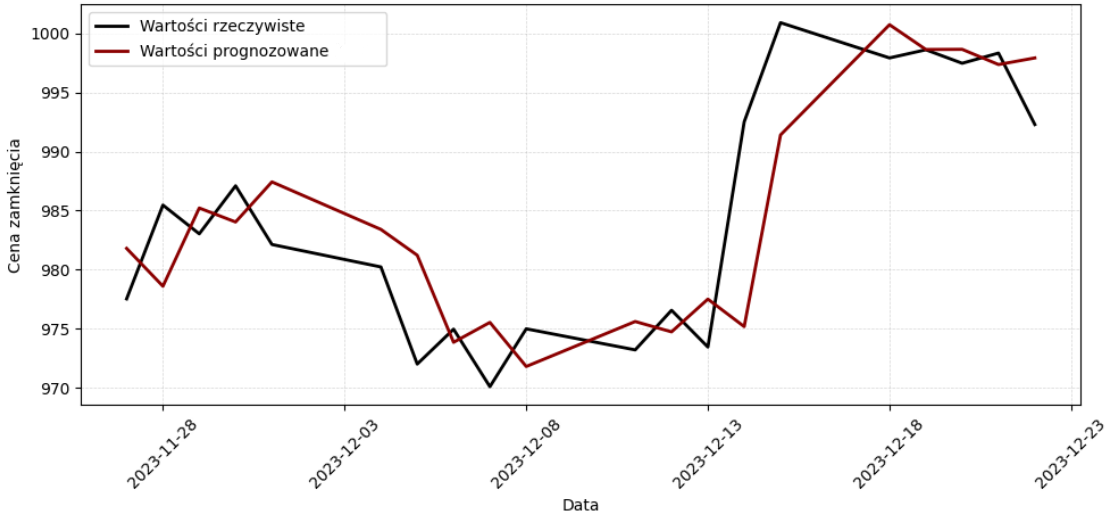

Rysunek 4.12. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI Emerging Markets w okresie wojny (model GRU)

Źródło: Opracowanie własne

4.4. Prognoza indeksów giełdowych z wykorzystaniem rekurencyjnych sieci neuronowych typu LSTM

Niniejszy rozdział poświęcony został analizie wyników prognoz otrzymanych za pomocą najbardziej złożonego z omawianych w pracy modeli, czyli rekurencyjnych sieci neuronowych typu LSTM. Celem porównania skuteczności modelu w zróżnicowanych warunkach rynkowych, w kolejnym kroku przedstawiono konfiguracje hiperparametrów, które pozwoliły na otrzymanie predykcji o najwyższej jakości zgodnie z ustalonym wcześniej podziałem tematycznym szeregów czasowych, odpowiadające im metryki oceny efektywności prognoz wraz z graficzną prezentacją.

4.4.1. Prognoza indeksów giełdowych dla rynku rozwiniętego

W oparciu o najlepiej sprawdzające się zestawy hiperparametrów dla danych, stanowiących punkt odniesienia w analizie rynku rozwiniętego (Tabela 4.9) oraz odpowiadające im metryki błędu i dopasowania modelu do danych (Tabela 4.10), stwierdzono, że model ten uzyskał najlepsze rezultaty w okresie względnej stabilizacji oraz wojny, skutkując MAPE w zakresie 0,39% - 0,41% oraz współczynnikiem determinacji R^2 odpowiednio na poziomie 86% i 91%. Bardzo dobre dopasowanie modelu do danych potwierdzają wykresy porównujące wartości rzeczywiste z prognozowanymi (Rysunek 4.13, Rysunek 4.15). Natomiast w przypadku okresu pandemii, sieć nie była w stanie uchwycić dynamicznego wzrostu notowań (Rysunek 4.14), co przekłada się na wyższą wartość MAPE - 0,90% oraz na dopasowanie modelu w 70%. Delikatna rozbieżność wartości RMSE i MAE dodatkowo potwierdza występowanie większych błędów predykcji.

Tabela 4.9. Struktura poszczególnych rekurencyjnych sieci neuronowych typu LSTM dla notowań indeksu MSCI World

Parametr	Okres		
	Stabilny	**Pandemii**	**Wojny**
Długość okna sekwencji wejściowej	20	60	60
Liczba neuronów w pierwszej warstwie ukrytej	64	96	96
Liczba warstw ukrytych	1	2	1
Architektura	równomierna	równomierna	równomierna
Rozmiar partii	8	16	16
Liczba epok	50	50	50
Współczynnik dropout	0,0	0,0	0,0

Źródło: Opracowanie własne

Tabela 4.10. Metryki błędu i dopasowania dla prognozy cen zamknięcia indeksu MSCI World w okresie stabilnym, pandemii i wojny (model LSTM)

Metryka	Okres		
	Stabilny	**Pandemii**	**Wojny**
RMSE	11,94	34,33	16,05
MAE	8,89	28,02	12,63
MAPE(%)	0,39	0,90	0,41
R^2	0,86	0,70	0,91

Źródło: Opracowanie własne

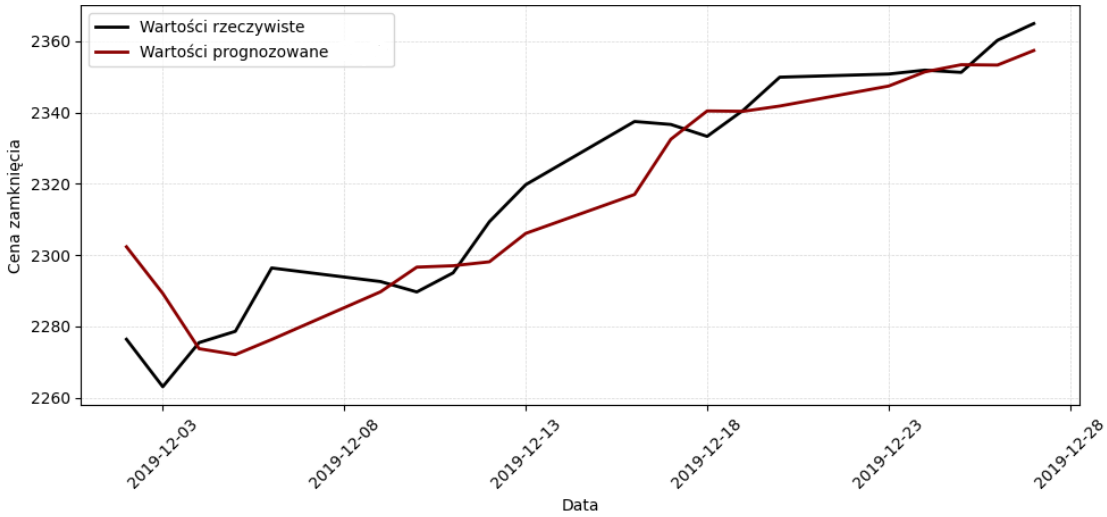

Rysunek 4.13. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI World w okresie stabilnym (model LSTM)

Źródło: Opracowanie własne

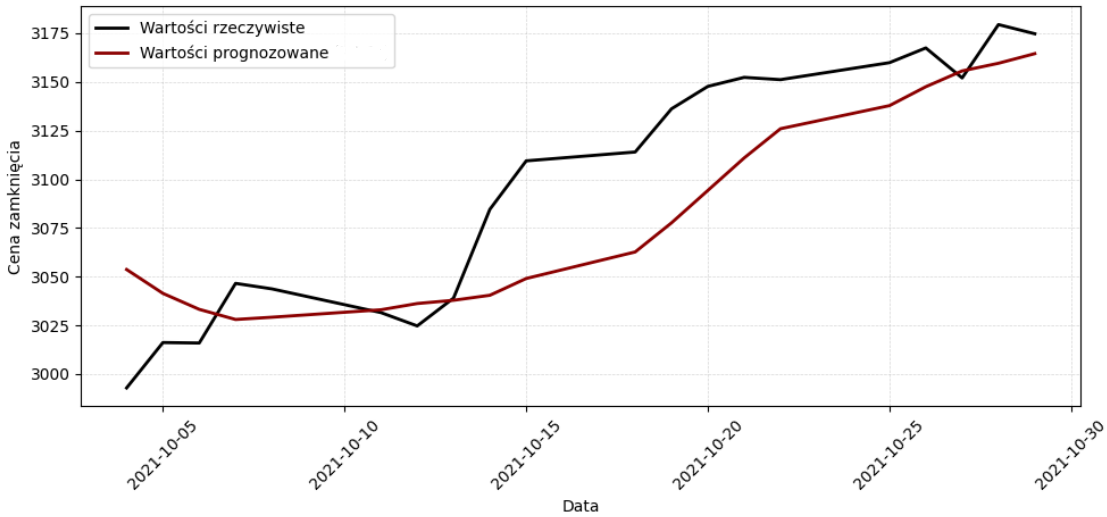

Rysunek 4.14. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI World w okresie pandemii (model LSTM)

Źródło: Opracowanie własne

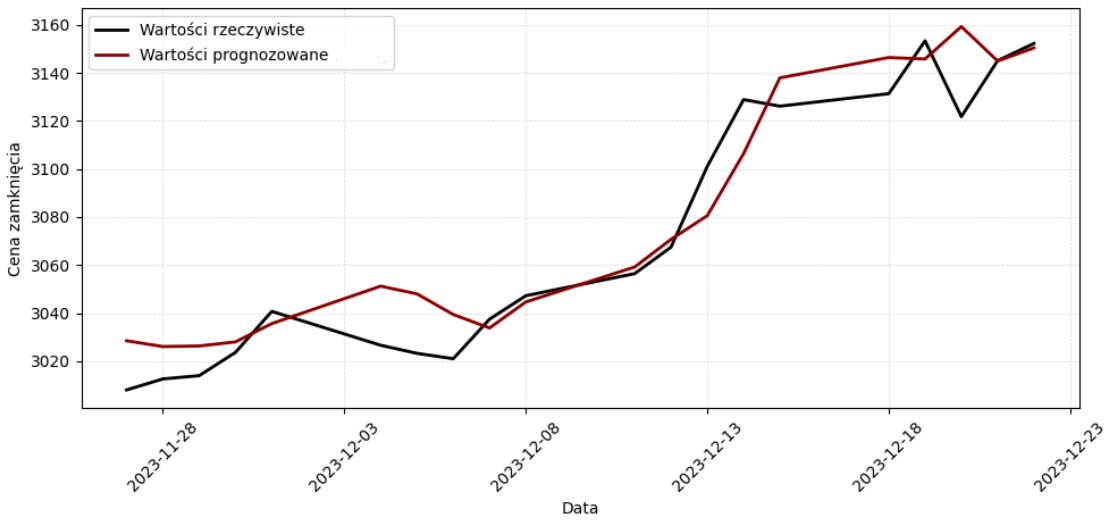

Rysunek 4.15. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI World w okresie wojny (model LSTM)

Źródło: Opracowanie własne

4.4.2. Prognoza indeksów giełdowych dla rynku wschodzącego

W wyniku symulacji przeprowadzonych dla zestawów danych reprezentujących rynek wschodzący wyłoniono najlepsze konfiguracje modeli odpowiednio dla okresu względnej stabilizacji, pandemii oraz wojny (Tabela 4.11). Analizując metryki oceny jakości predykcji (Tabela 4.12) można stwierdzić, iż otrzymane modele cechują się sporym zróżnicowaniem efektywności w zależności od analizowanego okresu. Model LSTM zdecydowanie najlepiej sprawdził się w warunkach stabilnych, przyjmując wartość MAPE równą 0,5% oraz dopasowaniem wartości prognozowanych do rzeczywistych na poziomie 95% (Rysunek 4.16). Zastosowanie omawianej architektury sieci dla szeregu czasowego będącego obrazem szoku pandemicznego pozwoliło na uchwycenie trendu, jednakże struktura sieci nie poradziła sobie z wykryciem dynamicznych wzrostów (Rysunek 4.17), co bardzo dobrze obrazuje wartość MAPE równa 0,89% oraz R^2 na poziomie 63%. Natomiast model na danych z okresu wojny wykazuje oznaki delikatnego opóźnienia predykcji (Rysunek 4.18), charakteryzując się niską wartością błędu względnego - 0,45%, lecz stosunkowo niskim poziomem miary dopasowania - 62%.

Tabela 4.11. Struktura poszczególnych rekurencyjnych sieci neuronowych typu LSTM dla notowań indeksu MSCI Emerging Markets

Parametr	Okres		
	Stabilny	**Pandemii**	**Wojny**
Długość okna sekwencji wejściowej	20	20	10
Liczba neuronów w pierwszej warstwie ukrytej	96	96	96
Liczba warstw ukrytych	1	1	2
Architektura	równomierna	równomierna	równomierna
Rozmiar partii	8	8	8
Liczba epok	50	30	50
Współczynnik dropout	0,0	0,0	0,0

Źródło: Opracowanie własne

Tabela 4.12. Metryki błędu i dopasowania dla prognozy cen zamknięcia indeksu MSCI Emerging Markets w okresie stabilnym, pandemii i wojny (model LSTM)

Metryka	Okres		
	Stabilny	**Pandemii**	**Wojny**
RMSE	6,61	13,31	6,24
MAE	5,37	11,29	4,46
MAPE(%)	0,50	0,89	0,45
R^2	0,95	0,63	0,62

Źródło: Opracowanie własne

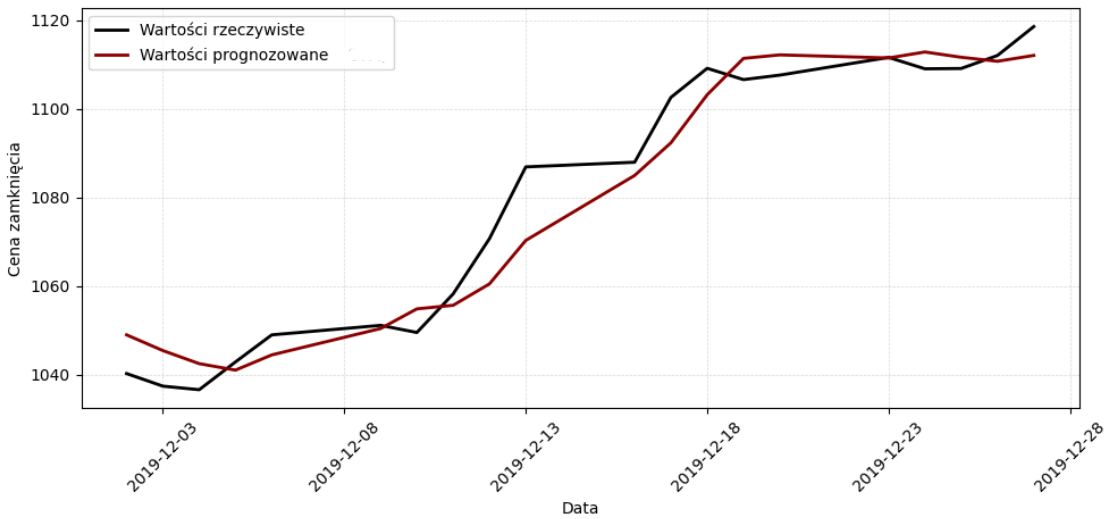

Rysunek 4.16. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI Emerging Markets w okresie stabilnym (model LSTM)

Źródło: Opracowanie własne

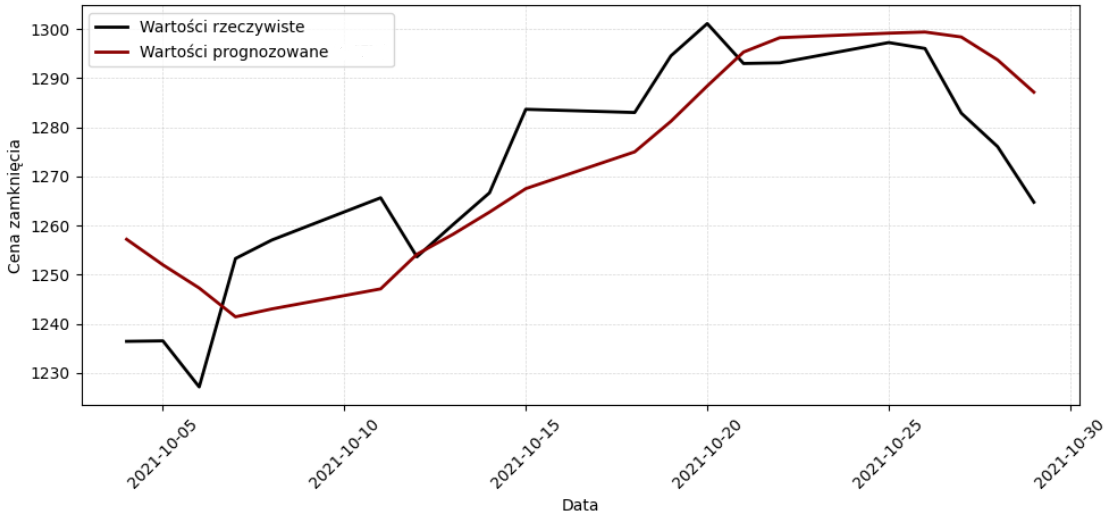

Rysunek 4.17. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI Emerging Markets w okresie pandemii (model LSTM)

Źródło: Opracowanie własne

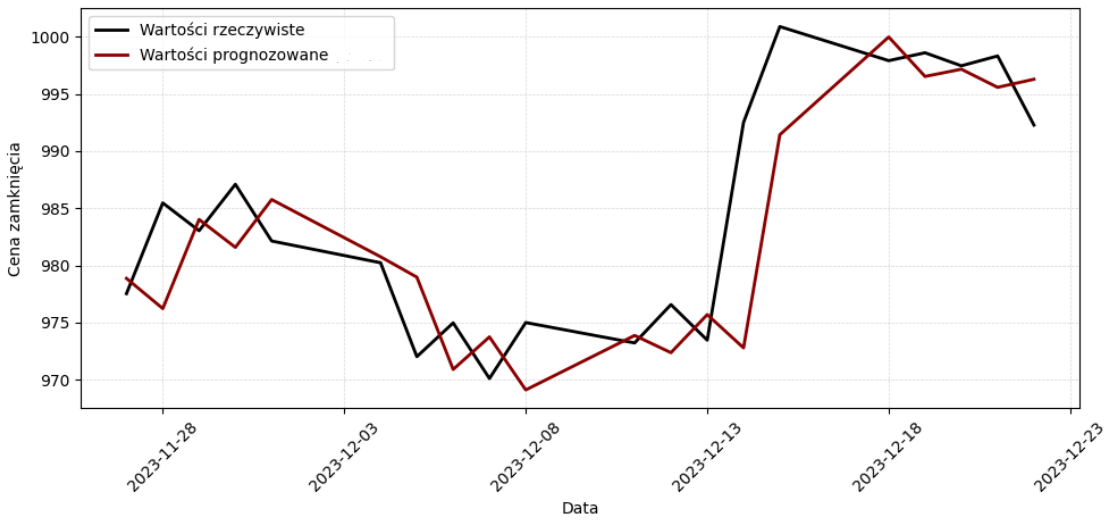

Rysunek 4.18. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI Emerging Markets w okresie wojny (model LSTM)

Źródło: Opracowanie własne

5. Komparatywna ocena skuteczności architektur sieci rekurencyjnych

Niniejszy rozdział poświęcono porównaniu architektur sieci rekurencyjnych celem określenia wariantów sieci neuronowych osiągających najlepsze rezultaty predykcji wartości indeksów reprezentujących rynek rozwinięty oraz wschodzący, których szeregi czasowe zostały odpowiednio podzielone, aby zachować odrębność zróżnicowanych warunków makroekonomicznych. Dla każdego z analizowanych zestawów danych, czyli odpowiednio : notowań cen zamknięcia indeksu MSCI World w okresie stabilnym, pandemii, wojny oraz MSCI Emerging Markets w analogicznych przedziałach czasowych, posługując się odpowiednimi metrykami, podjęto próbę wyłonienia najskuteczniejszej architektury sieci rekurencyjnej.

5.1. Kryteria ewaluacji modeli prognostycznych

Celem rzetelnej analizy porównawczej wybranych architektur sieci neuronowych, w poprzednich krokach podejmowano czynności, minimalizujące wpływ innych czynników zewnętrznych na efektywność wybranego modelu tj. przygotowano zestawy danych o jednakowej liczebności i identycznym podziałem na zbiór treningowy, walidacyjny i testowy, zastosowano jednolitą optymalną siatkę hiperparametrów, ten sam wariant funkcji straty, funkcji aktywacji oraz optymalizatora. Zabiegi te miały na celu umożliwienie obiektywnej weryfikacji, która z omawianych architektur wykazuje najwyższą skuteczność w określonych warunkach rynkowych.

W procesie identyfikacji najlepszej architektury sieci w każdym z wyszczególnionych okresów jako główne kryterium przyjęto wartość RMSE, ze względu na jego właściwości uwzględniające skalę błędów oraz wrażliwość na duże odchylenia. Metryki MAPE i R^2 zostały wykorzystane pomocniczo, w celu uzupełniającej oceny dokładności względnej oraz ogólnego dopasowania modelu do danych.

5.2. Selekcja optymalnych modeli dla indeksów rynków rozwiniętych i wschodzących w różnych warunkach rynkowych

W przypadku rynku rozwiniętego w okresie stabilnym, na podstawie wartości RMSE, najlepszy wynik osiągnął model GRU, nieznacznie przewyższając model RNN. Oba modele charakteryzowały się taką samą wartością względnego błędu prognostycznego oraz identycznym współczynnikiem determinacji, co wskazuje na ich zbliżoną skuteczność. Z kolei model LSTM wykazał się wyraźnie gorszym dopasowaniem, osiągając wyższe wartości RMSE i MAPE oraz niższe R^2, co świadczy o jego niższej efektywności w warunkach stabilnego rynku rozwiniętego (Tabela 5.1).

Tabela 5.1. Porównanie metryk oceny jakości prognoz dla indeksu MSCI World w okresie stabilnym oraz modeli RNN, GRU, LSTM

Model	RMSE	MAPE(%)	R^2
RNN	9,54	0,34	0,91
GRU	9,39	0,34	0,91
LSTM	11,94	0,39	0,86

Źródło: Opracowanie własne

Z kolei w okresie pandemii, na rynku rozwiniętym, najniższą wartość RMSE osiągnął model RNN, co wskazuje na jego najwyższą dokładność prognozy spośród porównywanych architektur. Model ten uzyskał również korzystniejszy wynik pod względem błędu względnego oraz współczynnika determinacji w porównaniu do modelu GRU. Z kolei model LSTM znacząco odstawał pod względem wszystkich metryk, co świadczy o jego znacznie niższej efektywności prognostycznej w warunkach silnych zaburzeń rynkowych (Tabela 5.2).

Tabela 5.2. Porównanie metryk oceny jakości prognoz dla indeksu MSCI World w okresie pandemii oraz modeli RNN, GRU, LSTM

Model	RMSE	MAPE(%)	R^2
RNN	17,92	0,43	0,92
GRU	19,06	0,47	0,91
LSTM	34,33	0,90	0,70

Źródło: Opracowanie własne

W okresie wojny, na rynku rozwiniętym, najwyższą skutecznością prognostyczną wykazał się model RNN, który osiągnął najniższe wartości RMSE i MAPE oraz najwyższy współczynnik determinacji R^2. Model GRU uzyskał nieco słabsze, choć nadal zbliżone wyniki, natomiast architektura LSTM wypadła najsłabiej pod względem wszystkich zastosowanych metryk, co wskazuje na jej ograniczoną efektywność w warunkach zwiększonej zmienności rynkowej (Tabela 5.3).

Tabela 5.3. Porównanie metryk oceny jakości prognoz dla indeksu MSCI World w okresie wojny oraz modeli RNN, GRU, LSTM

Model	RMSE	MAPE(%)	R^2
RNN	13,98	0,35	0,93
GRU	14,70	0,39	0,92
LSTM	16,05	0,41	0,91

Źródło: Opracowanie własne

W stabilnym okresie funkcjonowania rynku wschodzącego, najwyższą dokładność prognozy osiągnął model GRU, który uzyskał najniższą wartość RMSE oraz identyczny jak model RNN błąd względny MAPE i współczynnik determinacji R^2. Model RNN zanotował niemal równoważne wyniki, co wskazuje na porównywalną skuteczność obu architektur. Z kolei model LSTM wypadł słabiej na tle konkurencyjnych rozwiązań - uzyskał wyraźnie wyższe wartości RMSE oraz MAPE i nieco niższe R^2, co świadczy o mniejszej precyzji predykcji w analizowanym okresie (Tabela 5.4).

Tabela 5.4. Porównanie metryk oceny jakości prognoz dla indeksu MSCI Emerging Markets w okresie stabilnym oraz modeli RNN, GRU, LSTM

Model	RMSE	MAPE(%)	R^2
RNN	5,40	0,42	0,97
GRU	5,38	0,42	0,97
LSTM	6,61	0,50	0,95

Źródło: Opracowanie własne

W okresie pandemii, dla rynku wschodzącego, najwyższą skutecznością prognostyczną wykazał się model GRU. Uzyskał on najlepsze rezultaty spośród analizowanych architektur we wszystkich zastosowanych metrykach, osiągając najniższy poziom błędu bezwzględnego oraz względnego, a także najwyższy współczynnik determinacji. Model RNN również zaprezentował zadowalającą jakość predykcji, przy tylko nieznacznie słabszych wynikach, co świadczy o jego wysokiej przydatności prognostycznej w warunkach umiarkowanego zaburzenia danych. Z kolei model LSTM okazał się najmniej skuteczny - uzyskał najwyższe wartości błędów prognozy oraz najniższy stopień dopasowania do rzeczywistego przebiegu indeksu (Tabela 5.5).

Tabela 5.5. Porównanie metryk oceny jakości prognoz dla indeksu MSCI Emerging Markets w okresie pandemii oraz modeli RNN, GRU, LSTM

Model	RMSE	MAPE(%)	R^2
RNN	10,03	0,67	0,79
GRU	9,82	0,62	0,80
LSTM	13,31	0,89	0,63

Źródło: Opracowanie własne

W okresie wojny, w odniesieniu do rynku wschodzącego, najwyższą skutecznością prognozowania wykazał się model GRU. Architektura ta uzyskała najniższy poziom błędu bezwzględnego oraz względnego, a także najwyższy współczynnik determinacji, co wskazuje na jej największą zdolność do uchwycenia wzorców zachowań indeksu w warunkach podwyższonej niestabilności rynkowej. Model RNN osiągnął nieco słabsze wyniki - jego dokładność prognozy była nieco niższa, zarówno pod względem błędów predykcji, jak i dopasowania do danych rzeczywistych, ale nadal zbliżona do wyników GRU. Z kolei model LSTM, mimo identycznego poziomu błędu względnego jak GRU, charakteryzował się wyższym błędem bezwzględnym oraz najniższym współczynnikiem determinacji, co czyni go najmniej skutecznym rozwiązaniem spośród analizowanych architektur (Tabela 5.6).

Tabela 5.6. Porównanie metryk oceny jakości prognoz dla indeksu MSCI Emerging Markets w okresie wojny oraz modeli RNN, GRU, LSTM

Model	RMSE	MAPE(%)	R^2
RNN	6,13	0,48	0,64
GRU	5,92	0,45	0,66
LSTM	6,24	0,45	0,62

Źródło: Opracowanie własne

5.3. Wnioski wynikające z analizy porównawczej modeli prognostycznych

Przeprowadzona analiza umożliwiła ocenę skuteczności wybranych architektur rekurencyjnych sieci neuronowych - RNN, GRU oraz LSTM - w prognozowaniu wartości indeksów giełdowych reprezentujących rynki rozwinięte i wschodzące. Badanie objęło trzy okresy o zróżnicowanych warunkach makroekonomicznych: stabilny, pandemii oraz wojny, co pozwoliło na identyfikację zachowań modeli w odmiennych warunkach rynkowych.

Wyniki jednoznacznie wskazują, że modele GRU i RNN charakteryzowały się najwyższą skutecznością prognostyczną, przewyższając model LSTM we wszystkich analizowanych kontekstach. Model GRU okazał się najbardziej efektywnym rozwiązaniem w przypadku indeksu rynku wschodzącego, uzyskując najniższe wartości RMSE i MAPE przy jednocześnie wysokim współczynniku determinacji R^2. W przypadku indeksu rynku rozwiniętego, w okresach charakteryzujących się zwiększoną zmiennością - pandemii oraz wojny - nieznaczną przewagę uzyskał model RNN. Model LSTM, będący najbardziej zaawansowaną spośród omawianych architektur, wykazał się najmniejszą skutecznością, co najprawdopodobniej spowodowane jest jego większą złożonością, niekoniecznie będącą zaletą w sytuacji ograniczonej liczby danych.

Wyniki te sugerują, że w problemie predykcji wartości notowań indeksów giełdowych, gdzie dostępność danych jest ograniczona, a dynamika rynku zmienna, prostsze architektury rekurencyjnych sieci neuronowych mogą okazać się bardziej skutecznym narzędziem. Podobne wnioski dotyczące skuteczności poszczególnych wariantów sieci neuronowych przedstawiają Buslim oraz współautorzy, którzy porównali modele GRU, RNN i LSTM w prognozowaniu cen Bitcoina przy użyciu zbioru danych zawierającego 1356 obserwacji. Po przeprowadzeniu optymalizacji hiperparametrów za pomocą przeszukiwania siatki metodą *Grid Search* stwierdzono, że zarówno model RNN, jak i GRU osiągnęły zbliżony poziom dokładności prognoz, natomiast model LSTM wyraźnie odbiegał jakością wyników od pozostałych architektur. Autorzy zaobserwowali, że zależność ta może wynikać z jego większej podatności na nadmierne dopasowanie lub wymagań względem większej ilości danych treningowych. Zbieżność

wyników sugeruje, iż przy ograniczonej liczności danych czasowych, architektury GRU oraz klasyczne RNN mogą stanowić bardziej efektywne rozwiązania w kontekście krótkoterminowego prognozowania szeregów czasowych niż LSTM.[32]

Podobne tendencje odnotowano również w innych badaniach porównujących architektury rekurencyjne pod kątem efektywności przy ograniczonym rozmiarze danych. Przykładowo, w analizie przeprowadzonej przez Shudonga Yanga i współautorów, porównano modele LSTM i GRU w kontekście klasyfikacji tekstów na zbiorze recenzji Yelp. Autorzy wskazali, że w warunkach ograniczonych danych uczących, to właśnie GRU osiągał wyższą dokładność przy jednocześnie krótszym czasie treningu. Co istotne, przewaga GRU była wyraźniejsza przy mniejszych próbkach danych, podczas gdy LSTM zyskiwał dopiero przy większych zbiorach.[33]

Wnioski z niniejszej analizy potwierdzają, że wszystkie testowane architektury - RNN, LSTM i GRU - są przydatne w prognozowaniu indeksów giełdowych, jednak skuteczność każdej z nich zależy od charakterystyki danych. W świetle uzyskanych rezultatów rekomenduje się stosowanie architektury GRU jako modelu pierwszego wyboru w prognozowaniu indeksów giełdowych na podstawie krótkich szeregów czasowych. GRU cechuje się najlepszym dopasowaniem oraz stabilnością predykcji, przy umiarkowanych wymaganiach obliczeniowych. Jednocześnie warto zaznaczyć, że klasyczny RNN osiągnął wyniki zbliżone pod względem jakości prognozy, co czyni go godną uwagi alternatywą w środowiskach o ograniczonych zasobach. Architektura LSTM w warunkach ograniczonej liczby obserwacji wykazała się niższą skutecznością, co sugeruje ostrożność przy jej implementacji w podobnych zastosowaniach.

[32] N. Buslim, I. L. Rahmatullah, B. A. Setyawan, A. Alamsyah, Comparing Bitcoin's Prediction Model Using GRU, RNN, and LSTM by Hyperparameter Optimization Grid Search and Random Search, „The 9th International Conference on Cyber and IT Service Management" 2021, s. 1 - 7, https://doi.org/10.1109/CITSM52892.2021.9588947.

[33] S. Yang, X. Yu, Y. Zhou, LSTM and GRU Neural Network Performance Comparison Study: Taking Yelp Review Dataset as an Example, „International Workshop on Electronic Communication and Artificial Intelligence" 2020, s. 98 - 101, http://doi.org/10.1109/IWECAI50956.2020.00027.

Zakończenie

Celem niniejszej pracy była ocena skuteczności wybranych architektur rekurencyjnych sieci neuronowych - RNN, GRU oraz LSTM - w prognozowaniu notowań indeksów giełdowych MSCI World oraz MSCI Emerging Markets w zróżnicowanych warunkach rynkowych: stabilizacji, pandemii oraz wojny. Przeprowadzone analizy empiryczne potwierdziły zasadność wykorzystania modeli sekwencyjnych w prognozowaniu danych finansowych, szczególnie w warunkach wysokiej zmienności i ograniczonej dostępności danych.

Uzyskane wyniki wykazały przewagę modelu GRU, który w większości przypadków osiągał najwyższą dokładność prognoz. Model RNN również wykazywał satysfakcjonujące rezultaty, zbliżone do GRU, co wskazuje na jego potencjał w zastosowaniach opartych na krótkich sekwencjach danych. Natomiast model LSTM - mimo że w licznych badaniach prezentowany jest jako jedna z najskuteczniejszych architektur do modelowania danych sekwencyjnych - w niniejszym eksperymencie charakteryzował się niższą skutecznością predykcji, co należy wiązać przede wszystkim z charakterystyką analizowanego zbioru danych, w tym ograniczoną długością danych wejściowych.

Warto podkreślić, że skuteczność modeli predykcyjnych była zróżnicowana w zależności od charakterystyki rynku oraz analizowanego okresu. W przypadku rynku rozwiniętego (MSCI World) wszystkie zastosowane architektury wykazywały relatywnie wysoką trafność prognoz niezależnie od warunków rynkowych. Odmienną tendencję zaobserwowano na rynku wschodzącym (MSCI Emerging Markets), gdzie dokładność predykcji istotnie obniżała się w okresach wzmożonej zmienności, takich jak pandemia COVID-19 oraz wojna w Ukrainie. Wyniki te mogą wskazywać na większą wrażliwość rynków wschodzących na czynniki destabilizujące oraz na ograniczoną zdolność modeli sekwencyjnych do odwzorowywania nieregularnych wzorców zachowań w warunkach kryzysowych.

Podsumowując, skuteczność modeli rekurencyjnych w prognozowaniu indeksów giełdowych zależy od wielu wzajemnie powiązanych czynników. Istotną rolę odgrywa charakterystyka analizowanego rynku - w szczególności rozróżnienie między rynkami rozwiniętymi a wschodzącymi - jak również rodzaj okresu, obejmujący zarówno fazy

stabilizacji, jak i epizody silnej zmienności, takie jak kryzysy gospodarcze czy geopolityczne. Kluczowe znaczenie ma także zakres dostępnych danych, co determinuje zdolność modeli do uchwycenia złożonych zależności. W związku z tym, wybór odpowiedniej architektury rekurencyjnych sieci neuronowych powinien być zawsze dostosowany do specyfiki danych finansowych oraz konkretnego kontekstu rynkowego, w jakim mają zostać zastosowane.

Wyniki przeprowadzonych analiz mogą stanowić wartościowy punkt wyjścia dla przyszłych badań ukierunkowanych na rozwój bardziej odpornych i elastycznych modeli prognostycznych, lepiej przystosowanych do zmiennych warunków rynkowych, takich jak okresy niestabilności makroekonomicznej, oraz do ograniczeń wynikających z niewielkiej ilości dostępnych danych. Takie podejście może przyczynić się do zwiększenia trafności prognoz w zastosowaniach praktycznych, szczególnie w kontekście mniej przewidywalnych segmentów rynków finansowych.

Literatura

[1] Bischl B., et al., Hyperparameter Optimization: Foundations, Algorithms, Best Practices, and Open Challenges, „WIREs Data Mining and Knowledge Discovery" 2023, t. 13, nr 2, https://doi.org/10.1002/widm.1484.

[2] Bishop C. M., Pattern Recognition and Machine Learning, Springer, New York 2006.

[3] Buslim N., Rahmatullah I. L., Setyawan B. A., Alamsyah A., Comparing Bitcoin's Prediction Model Using GRU, RNN, and LSTM by Hyperparameter Optimization Grid Search and Random Search, „The 9th International Conference on Cyber and IT Service Management" 2021, https://doi.org/10.1109/CITSM52892.2021.9588947.

[4] Chahuán-Jiménez K., Neural Network-Based Predictive Models for Stock Market Index Forecasting, „Journal of Risk and Financial Management" 2024, t. 17, nr 6, https://doi.org/10.3390/jrfm17060242.

[5] Cho K., van Merriënboer B., Bahdanau D., Bengio Y., Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation, „Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing" 2014, s. 1724 - 1734, https://doi.org/10.48550/arXiv.1406.1078.

[6] Géron A., Uczenie maszynowe z użyciem Scikit-Learn i TensorFlow, Helion, Gliwice 2020.

[7] Goodfellow I., Bengio Y., Courville A., Deep Learning, MIT Press, Cambridge 2016.

[8] Gruszczyński M., Kuszewski T., Podgórska M. (red.), Ekonometria i badania operacyjne, Wydawnictwo Naukowe PWN, Warszawa 2013.

[9] Hewamalage H., Bergmeir C., Bandara K., Recurrent Neural Networks for Time Series Forecasting: Current status and future directions, „International Journal of Forecasting" 2021, t. 37, nr 1, s. 388 - 427, https://doi.org/10.1016/j.ijforecast.2020.06.008.

[10] Hiransha M., Gopalakrishnan E.A., Menon V.K., Soman K.P., NSE Stock Market Prediction Using Deep-Learning Models, „Procedia Computer Science" 2018, t. 132, s. 1351 - 1362, https://doi.org/10.1016/j.procs.2018.05.050.

[11] Hochreiter S., Schmidhuber J., Long Short-Term Memory, „Neural Computation” 1997, t. 9, nr 8, s. 1735 - 1780, https://doi.org/10.1162/neco.1997.9.8.1735.

[12] Hyndman R. J., Athanasopoulos G., Forecasting: Principles and Practice, wyd. 3, OTexts, Melbourne 2021, https://otexts.com/fpp3/accuracy.html [dostęp: 2.06.2025].

[13] Jordan I. D., Sokół P. A., Park I. M., Gated Recurrent Units Viewed Through the Lens of Continuous Time Dynamical Systems, „Frontiers in Computational Neuroscience” 2021, t. 15, https://doi.org/10.3389/fncom.2021.678158.

[14] Kingma D. P., Ba J., Adam: A Method for Stochastic Optimization, „Proceedings of the International Conference on Learning Representations” 2015, https://arxiv.org/abs/1412.6980.

[15] Malashin I., Tynchenko V., Gantimurov A., Nelyub V., Borodulin A., Applications of Long Short-Term Memory (LSTM) Networks in Polymeric Sciences: A Review, „Polymers” 2024, t. 16, nr 18, art. 2607, https://doi.org/10.3390/polym16182607.

[16] Mroua M., Lamine A., Financial time series prediction under COVID-19 pandemic crisis with Long Short-Term Memory (LSTM) network, „Humanities and Social Sciences Communications” 2023, t. 10, https://doi.org/10.1057/s41599-023-02042-w.

[17] Noh S.-H., Analysis of Gradient Vanishing of RNNs and Performance Comparison, „Information” 2021, t. 12, nr 11, art. 442, https://doi.org/10.3390/info12110442.

[18] Satria D., Predicting Banking Stock Prices Using RNN, LSTM, and GRU Approach, „Applied Computer Science” 2023, t. 19, nr 1, , s. 82 - 94, https://doi.org/10.35784/acs-2023-06.

[19] Seabe P.L., Moutsinga C.R.B., Pindza E., Forecasting cryptocurrency prices using LSTM, GRU, and Bi-Directional LSTM: A deep learning approach, „Fractal and Fractional” 2023, t. 7, nr 2, https://doi.org/10.3390/fractalfract7020203.

[20] Terven J., Cordova-Esparza D.-M., Romero-González J.-A., Ramírez-Pedraza A., Chávez-Urbiola E. A., A Comprehensive Survey of Loss Functions and Metrics in Deep Learning, „Artificial Intelligence Review” 2025, t. 58, art. 195, https://doi.org/10.1007/s10462-025-11198-7.

[21] Yang S., Yu X., Zhou Y., LSTM and GRU Neural Network Performance Comparison Study: Taking Yelp Review Dataset as an Example, „International Workshop on Electronic Communication and Artificial Intelligence" 2020, s. 98 - 101, http://doi.org/10.1109/IWECAI50956.2020.00027.

[22] Zhang L., et al., Time-Series Neural Network: A High-Accuracy Time-Series Forecasting Method Based on Kernel Filter and Time Attention, „Information" 2023, t. 14, nr 9, art. 500, https://doi.org/10.3390/info14090500.

Wykaz innych materiałów

[1] MSCI Inc., MSCI Emerging Markets Index – Index Factsheet, Nowy Jork 2025, https://www.msci.com/documents/10199/c0db0a48-01f2-4ba9-ad01-226fd5678111 [dostęp: 06.06.2025].

[2] MSCI Inc., MSCI World Index (USD) – Index Factsheet, Nowy Jork 2025, https://www.msci.com/documents/10199/178e6643-6ae6-47b9-82be-e1fc565ededb [dostęp: 6.06.2025].

[3] MSCI Inc., Q&A: Treatment of Intraday, Expected and Unexpected Market Closures in the MSCI Equity Indexes, Nowy Jork 2020, https://www.msci.com/eqb/methodology/meth_docs/QA_Market_Closure_March_2020.pdf [dostęp: 6.06.2025].

Spis tabel

Tabela 4.1. Struktura poszczególnych prostych rekurencyjnych sieci neuronowych dla notowań indeksu MSCI World 30
Tabela 4.2. Metryki błędu i dopasowania dla prognozy cen zamknięcia indeksu MSCI World w okresie stabilnym, pandemii i wojny (prosta sieć rekurencyjna) 30
Tabela 4.3. Struktura poszczególnych prostych rekurencyjnych sieci neuronowych dla notowań indeksu MSCI Emerging Markets 33
Tabela 4.4. Metryki błędu i dopasowania dla prognozy cen zamknięcia indeksu MSCI Emerging Markets w okresie stabilnym, pandemii i wojny (prosta sieć rekurencyjna). 33
Tabela 4.5. Struktura poszczególnych rekurencyjnych sieci neuronowych typu GRU dla notowań indeksu MSCI World 36
Tabela 4.6. Metryki błędu i dopasowania dla prognozy cen zamknięcia indeksu MSCI World w okresie stabilnym, pandemii i wojny (model GRU)..... 37
Tabela 4.7. Struktura poszczególnych rekurencyjnych sieci neuronowych typu GRU dla notowań indeksu MSCI Emerging Markets 39
Tabela 4.8. Metryki błędu i dopasowania dla prognozy cen zamknięcia indeksu MSCI Emerging Markets w okresie stabilnym, pandemii i wojny (model GRU) 40
Tabela 4.9. Struktura poszczególnych rekurencyjnych sieci neuronowych typu LSTM dla notowań indeksu MSCI World 43
Tabela 4.10. Metryki błędu i dopasowania dla prognozy cen zamknięcia indeksu MSCI World w okresie stabilnym, pandemii i wojny (model LSTM)..... 43
Tabela 4.11. Struktura poszczególnych rekurencyjnych sieci neuronowych typu LSTM dla notowań indeksu MSCI Emerging Markets..... 46
Tabela 4.12. Metryki błędu i dopasowania dla prognozy cen zamknięcia indeksu MSCI Emerging Markets w okresie stabilnym, pandemii i wojny (model LSTM)..... 46
Tabela 5.1. Porównanie metryk oceny jakości prognoz dla indeksu MSCI World w okresie stabilnym oraz modeli RNN, GRU, LSTM..... 50
Tabela 5.2. Porównanie metryk oceny jakości prognoz dla indeksu MSCI World w okresie pandemii oraz modeli RNN, GRU, LSTM 51
Tabela 5.3. Porównanie metryk oceny jakości prognoz dla indeksu MSCI World w okresie wojny oraz modeli RNN, GRU, LSTM 51

Tabela 5.4. Porównanie metryk oceny jakości prognoz dla indeksu MSCI Emerging Markets w okresie stabilnym oraz modeli RNN, GRU, LSTM..... 52
Tabela 5.5. Porównanie metryk oceny jakości prognoz dla indeksu MSCI Emerging Markets w okresie pandemii oraz modeli RNN, GRU, LSTM 53
Tabela 5.6. Porównanie metryk oceny jakości prognoz dla indeksu MSCI Emerging Markets w okresie wojny oraz modeli RNN, GRU, LSTM 53

Spis rysunków

Rysunek 3.1. Komórka GRU 20
Rysunek 3.2. Komórka LSTM 21
Rysunek 4.1. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI World w okresie stabilnymi (prosta sieć rekurencyjna) 31
Rysunek 4.2. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI World w okresie pandemii (prosta sieć rekurencyjna) 31
Rysunek 4.3. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI World w okresie wojny (prosta sieć rekurencyjna) 32
Rysunek 4.4. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI Emerging Markets w okresie stabilnym (prosta sieć rekurencyjna) 34
Rysunek 4.5. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI Emerging Markets w okresie pandemii (prosta sieć rekurencyjna) 34
Rysunek 4.6. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI Emerging Markets w okresie wojny (prosta sieć rekurencyjna) 35
Rysunek 4.7. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI World w okresie stabilnym (model GRU) 37
Rysunek 4.8. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI World w okresie pandemii (model GRU) 38
Rysunek 4.9. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI World w okresie wojny (model GRU) 38
Rysunek 4.10. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI Emerging Markets w okresie stabilnym (model GRU) 40
Rysunek 4.11. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI Emerging Markets w okresie pandemii (model GRU) 41
Rysunek 4.12. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI Emerging Markets w okresie wojny (model GRU) 41
Rysunek 4.13. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI World w okresie stabilnym (model LSTM) 44
Rysunek 4.14. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI World w okresie pandemii (model LSTM) 44

Rysunek 4.15. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI World w okresie wojny (model LSTM) 45
Rysunek 4.16. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI Emerging Markets w okresie stabilnym (model LSTM) 47
Rysunek 4.17. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI Emerging Markets w okresie pandemii (model LSTM) 47
Rysunek 4.18. Porównanie rzeczywistych i prognozowanych cen zamknięcia indeksu MSCI Emerging Markets w okresie wojny (model LSTM) 48

Spis załączników

https://github.com/kinqak/COMPARATIVE_ANALYSIS_RNN_STOCK_INDEX_PRICE_PREDICTION