AKADEMIA GÓRNICZO-HUTNICZA
IM. STANISŁAWA STASZICA W KRAKOWIE

WYDZIAŁ ZARZĄDZANIA

Projekt zaliczeniowy

Ekonometria danych panelowych

Kierunek: Informatyka i Ekonometria

Rok: I rok

Autorzy: Julia Matyja, Kinga Kołodziej

Kraków, 2025

Spis treści

1. WPROWADZENIE 4

2. CEL PROJEKTU 5

3. PREZENTACJA I OPIS DANYCH 6

3.1. OPIS DANYCH I ICH ŹRÓDŁO 6
3.2. PREZENTACJA DANYCH 7
3.3. STATYSTYKI OPISOWE 9
3.4. ANALIZA ZALEŻNOŚCI POMIĘDZY ZMIENNYMI 10

4. BUDOWA MODELI 12

4.1. MODEL REGRESJI ŁĄCZNEJ 12
4.2. MODEL Z EFEKTAMI USTALONYMI (FE) JEDNOKIERUNKOWY 13
4.3. MODEL Z EFEKTAMI USTALONYMI (FE) DWUKIERUNKOWY 14
4.4. MODEL Z EFEKTAMI LOSOWYMI (RE) JEDNOKIERUNKOWY 16
4.5. MODEL Z EFEKTAMI LOSOWYMI (RE) DWUKIERUNKOWY 17

5. WYBÓR NAJLEPSZEGO MODELU POPRZEZ ZASTOSOWANIE TESTÓW 20

5.1. PORÓWNANIE REGRESJI ŁĄCZNEJ I MODELU FE (JEDNOKIERUNKOWEGO) 20
5.2. PORÓWNANIE REGRESJI ŁĄCZNEJ I MODELU RE (JEDNOKIERUNKOWEGO) 21
5.3. PORÓWNANIE MODELU FE JEDNOKIERUNKOWEGO I MODELU FE DWUKIERUNKOWEGO 22
5.4. PORÓWNANIE MODELU FE (JEDNOKIERUNKOWEGO) I MODELU RE (JEDNOKIERUNKOWEGO) 23
5.5. PORÓWNANIE MODELU FE (DWUKIERUNKOWEGO) I MODELU RE (DWUKIERUNKOWEGO) 23

6. OSTATECZNY WYBÓR MODELU I DOBÓR ZMIENNYCH 25

6.1. USUNIĘCIE ZMIENNEJ PKB_PC 26
6.2. USUNIĘCIE ZMIENNEJ DZIETNOSC 27
6.3. USUNIĘCIE ZMIENNYCH PKB_PC ORAZ DZIETNOSC 28
6.4. OSTATECZNY DOBÓR ZMIENNYCH 28

7. WERYFIKACJA MODELU 29

7.1. TESTOWANIE AUTOKORELACJI SKŁADNIKA LOSOWEGO 29
7.1.1. Autokorelacja czasowa w obrębie jednostki 29
7.1.2. Zależność przekrojowa 31
7.2. BADANIE HETEROSKEDASTYCZNOŚCI SKŁADNIKA LOSOWEGO 32
7.3. BADANIE NORMALNOŚCI ROZKŁADU RESZT 33

8. PREZENTACJA OSTATECZNEJ POSTACI MODELU I JEGO OCENA 35

8.1. ODPORNE BŁĘDY STANDARDOWE 35
8.2. OCENA ISTOTNOŚCI ZMIENNYCH 36
8.3. OCENA WSPÓŁCZYNNIKA DETERMINACJI 36

8.4. INTERPRETACJA PARAMETRÓW MODELU 37

9. BUDOWA I OCENA MODELU DYNAMICZNEGO 38

9.1. ESTYMATOR FE 39

9.2. ESTYMATOR UOGÓLNIONEJ METODY MOMENTÓW - ARELLANO, BOND(1991) 40

10. PODSUMOWANIE 42

SPIS RYSUNKÓW 44

SPIS TABEL 45

1. Wprowadzenie

Rynek pracy w krajach Unii Europejskiej podlega dynamicznym zmianom, które wynikają zarówno z procesów gospodarczych, jak i zmian społecznych zachodzących w poszczególnych państwach. W szczególności istotnym zagadnieniem jest poziom stopy bezrobocia, stanowiący jedną z głównych miar koniunktury gospodarczej, sytuacji na rynku pracy oraz poziomu dobrobytu społecznego. W literaturze ekonomicznej wskazuje się, że na stopę bezrobocia wpływ mają zarówno czynniki strukturalne, takie jak poziom wykształcenia i zatrudnienia, jak i czynniki makroekonomiczne, m.in. inflacja czy wydatki publiczne. Metody analizy danych panelowych umożliwiają jednoczesne ujęcie zróżnicowania pomiędzy krajami oraz zmian w czasie, dzięki czemu są szczególnie przydatne do badania mechanizmów kształtujących stopę bezrobocia w państwach UE.

2. Cel projektu

Celem projektu jest analiza zależności pomiędzy stopą bezrobocia a wybranymi czynnikami społeczno - ekonomicznymi w krajach Unii Europejskiej z wykorzystaniem metod ekonometrii danych panelowych. Projekt zakłada estymację i porównanie różnych specyfikacji modeli panelowych, w tym regresji łącznej, modelu z efektami ustalonymi i losowymi, w układzie jednokierunkowym i dwukierunkowym, a następnie wybór postaci najlepiej dopasowanej do danych na podstawie testów statystycznych. Dodatkowym założeniem jest oszacowanie modelu dynamicznego, który pozwala ocenić, w jakim stopniu kształtowanie stopy bezrobocia wynika z jej historycznych wartości.

3. Prezentacja i opis danych

3.1. Opis danych i ich źródło

Do analizy wykorzystano dane panelowe obejmujące 26 państw członkowskich Unii Europejskiej w latach 2015 - 2023. Wszystkie zmienne pozyskano z oficjalnej bazy statystycznej Eurostat (https://ec.europa.eu/eurostat). Zestaw danych obejmuje jedną zmienną objaśnianą:

- **stopa_bezrobocia** - zmienna określająca stopę bezrobocia mierzoną jako odsetek osób bezrobotnych w populacji aktywnej zawodowo. Wskaźnik obejmuje osoby w wieku 20 - 64 lata, które nie pracują, aktywnie poszukują zatrudnienia oraz są gotowe do jego podjęcia,

oraz siedem zmiennych objaśniających. Są to:

- **edukacja** - zmienna określająca odsetek osób w wieku 25 - 64 lat, które posiadają co najmniej wykształcenie średnie, w tym policealne i wyższe. Wskaźnik obejmuje wszystkie poziomy edukacji powyżej podstawowej i gimnazjalnej.
- **inflacja** - zmienna określająca średnioroczną stopę zmian HICP (Harmonised Index of Consumer Prices), obejmująca całość koszyka konsumpcyjnego. Wskaźnik ten pokazuje, o ile przeciętnie wzrosły ceny w danym kraju w porównaniu do roku poprzedniego. Rok 2015 jest w tym przypadku rokiem bazowym.
- **gestosc** - zmienna określająca liczbę osób przypadających na 1 km^2 powierzchni danego kraju.
- **dzietnosc** - zmienna określająca współczynnik dzietności, czyli średnią liczbę dzieci przypadających na jedną kobietę.
- **pkb_pc** - zmienna określająca wartość produktu krajowego brutto (PKB) na mieszkańca, wyrażoną w euro w cenach bieżących. Odpowiada wskaźnikowi PKB per capita.
- **zatrudnienie** - zmienna określająca odsetek osób w wieku 20 - 64 lata, które posiadają wykształcenie średnie lub policealne i są zatrudnione. Wartość wyrażona jest jako procent populacji tej grupy w danym kraju i roku.
- **wydatki_rzadowe** - zmienna określająca udział całkowitych wydatków sektora instytucji rządowych i samorządowych w produkcie krajowym brutto (PKB) danego kraju, wyrażony w procentach.

Zestaw danych wykorzystany w analizie jest kompletny, obejmuje wszystkie obserwacje dla 26 krajów Unii Europejskiej w latach 2015 - 2023 i nie zawiera braków danych.

3.2. Prezentacja danych

W celu lepszego zobrazowania zmian analizowanych zmiennych w czasie, dane zostaną przedstawione na wykresach (Rysunek 1). Umożliwi to uchwycenie ogólnych trendów oraz potencjalnych zależności pomiędzy zmiennymi.

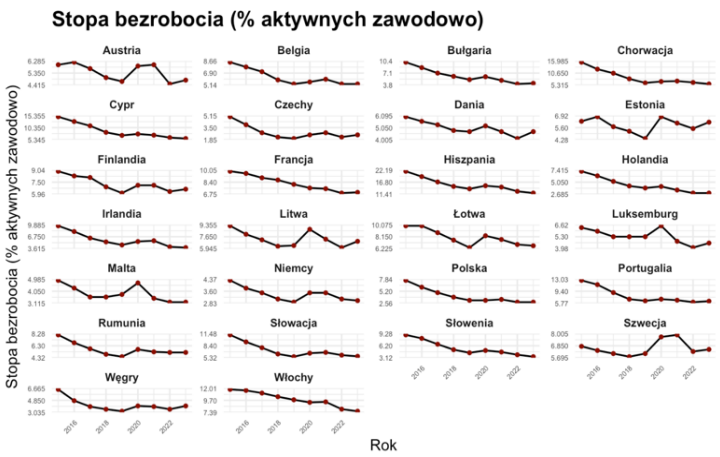

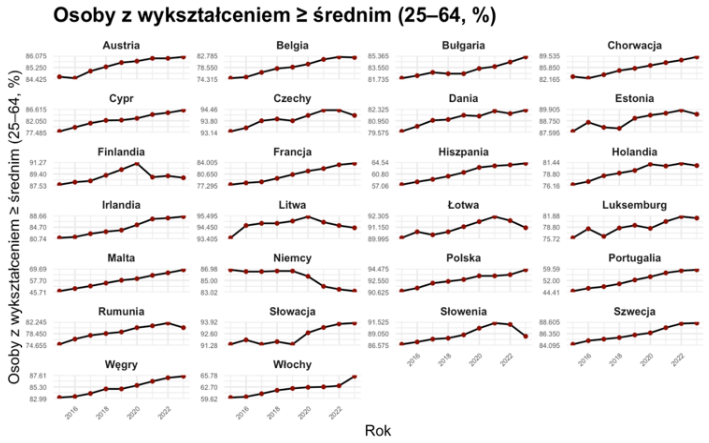

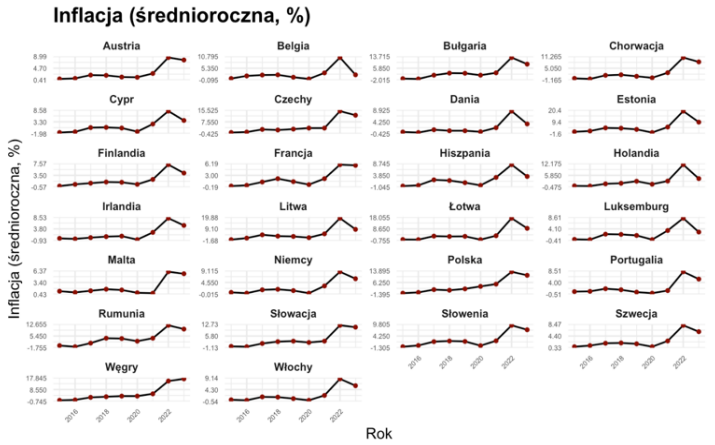

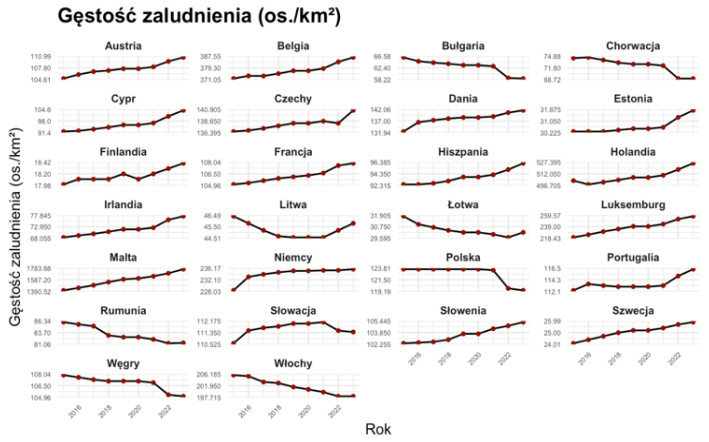

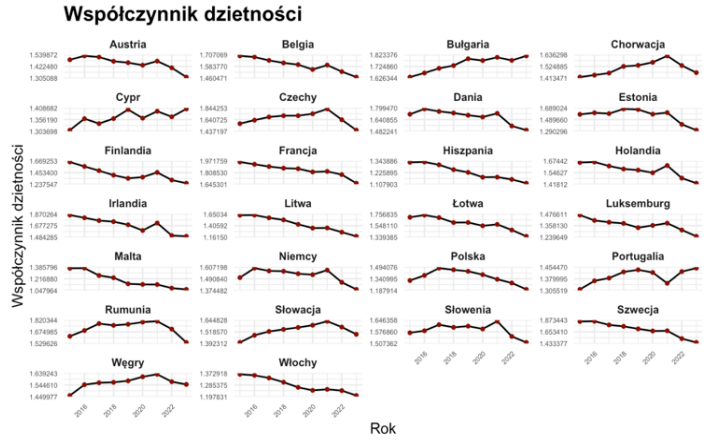

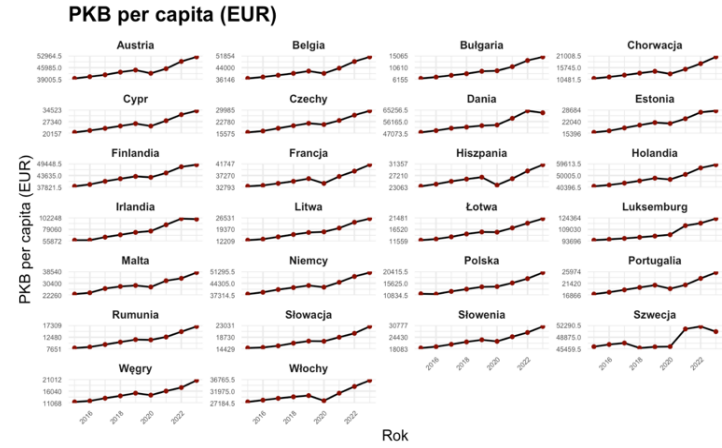

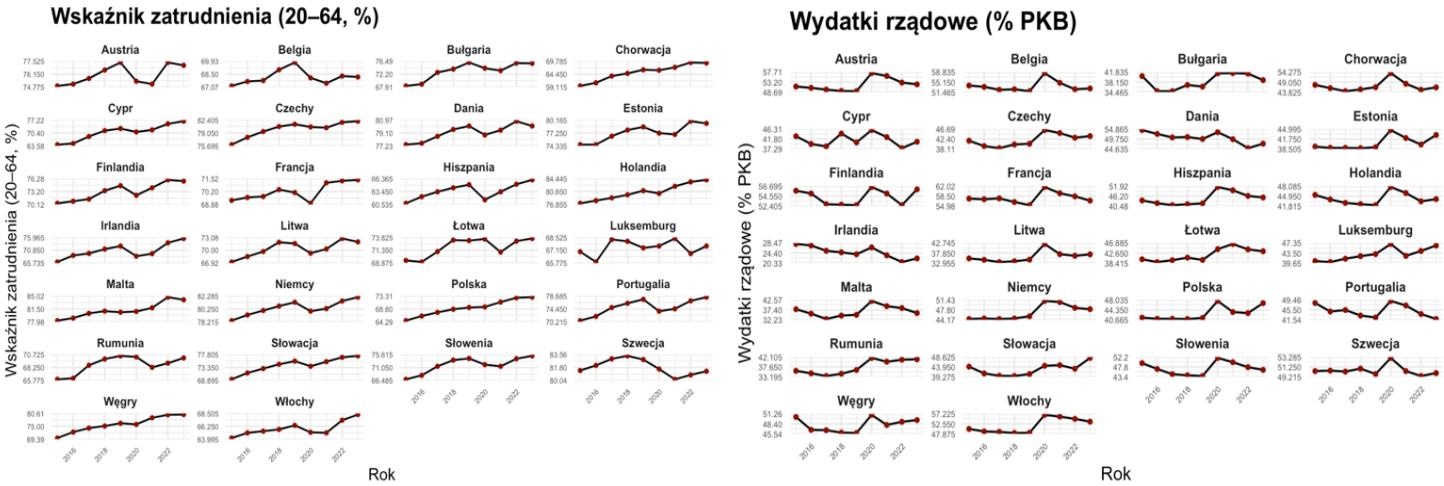

Rysunek 3.1. Zmienność w czasie - wizualizacja danych panelowych.

Analiza wykresów dla poszczególnych krajów UE pokazuje, że stopa bezrobocia w większości państw spadała do 2019 roku, po czym wzrosła w okresie pandemii. Równolegle we wszystkich krajach obserwowany jest systematyczny wzrost udziału osób z co najmniej średnim wykształceniem. Inflacja pozostawała niska i stabilna do 2021 roku, a następnie gwałtownie wzrosła, przy czym skala zmian różni się między państwami. PKB per capita wykazuje stały trend wzrostowy, choć poziom wskaźnika jest bardzo zróżnicowany. Wskaźnik zatrudnienia także wzrasta w czasie, natomiast współczynnik dzietności cechuje się trendem spadkowym. Wydatki rządowe jako procent PKB wykazują niewielką zmienność, z widocznym wzrostem po 2020 roku.

3.3. Statystyki opisowe

Tabela 3.1. Podstawowe statystyki opisowe badanych zmiennych.

Zmienna	min	Q1	średnia	mediana	Q3	max	odch. stand.	skośność	kurtoza	współ. zmien.
dzietnosc	1,06	1,39	1,52	1,54	1,65	1,96	0,18	-0,12	2,52	0,12
edukacja	45,10	79,08	81,56	84,15	88,88	95,4	11,30	-1,38	4,30	0,14
gestosc	18	70,22	185,31	106,2	138,57	1766	300,37	3,96	18,76	1,62
inflacja	-1,5	0,6	3,00	1,75	3,48	19,40	3,87	1,89	6,64	1,29
pkb_pc	6560	17272,5	32892,99	26645	42957,5	122970	21924,85	1,73	6,44	0,67
stopa bezrobocia	2	4,7	6,57	6,10	7,68	21,7	2,99	1,68	7,31	0,46
wydatki rzadowe	20,7	40,45	44,71	44,55	49,8	61,7	7,3	-0,48	3,66	0,16
zatrudnienie	59,6	68,73	73,15	72,95	77,6	84,7	5,61	0,01	2,11	0,08

Analiza danych panelowych obejmujących państwa Unii Europejskiej w latach 2015 - 2023 wskazuje na istotne zróżnicowanie zmiennych uwzględnionych w modelu. Stopa bezrobocia kształtuje się w przedziale od 2% do 21,7%, co potwierdza duże różnice między krajami. Wartość współczynnika zmienności na poziomie 0,46 wskazuje na umiarkowaną zmienność tej zmiennej. Wyraźne zróżnicowanie obserwowane jest również w poziomie zamożności krajów - PKB per capita waha się od 6560 do 122 970 euro, a wysoki współczynnik zmienności (0,67) i dodatnia skośność potwierdzają asymetrię rozkładu. Analizowana populacja charakteryzuje się wysokim średnim odsetkiem osób z co najmniej wykształceniem średnim w postaci 81,56%, przy niskiej zmienności (0,14). W badanym okresie inflacja była bardzo zróżnicowana: minimalna wartość wyniosła - 1,5%, natomiast maksymalna 19,4%. Duże różnice widoczne są również w gęstości zaludnienia, która mieści się w przedziale od 18 (Finlandia) do 1766 (Malta) osób/km², przy silnie prawostronnie skośnym rozkładzie, co wynika z obecności państw o niewielkiej powierzchni terytorialnej i dużej koncentracji ludności. W przypadku wydatków publicznych mediana udziału wydatków rządowych w PKB wynosi 44,6%, a umiarkowana zmienność (0,16) wskazuje na względnie stabilny charakter tej zmiennej.

Stosunkowo niską zmiennością cechuje się wskaźnik zatrudnienia (0,08), którego mediana wynosi 72,9%. Dzietność pozostaje na niskim średnim poziomie (1,52), co jest typowe dla krajów wysoko rozwiniętych.

3.4. Analiza zależności pomiędzy zmiennymi

W celu zbadania zależności między zmiennymi przeprowadzona została analiza korelacji (Rysunek 3.2) oraz sprawdzona została współliniowość za pomocą współczynników VIF (Tabela 3.2). Pozwoliło to ocenić, które zmienne są ze sobą najsilniej powiązane i czy ich zależności nie stanowią potencjalnego problemu w dalszej analizie.

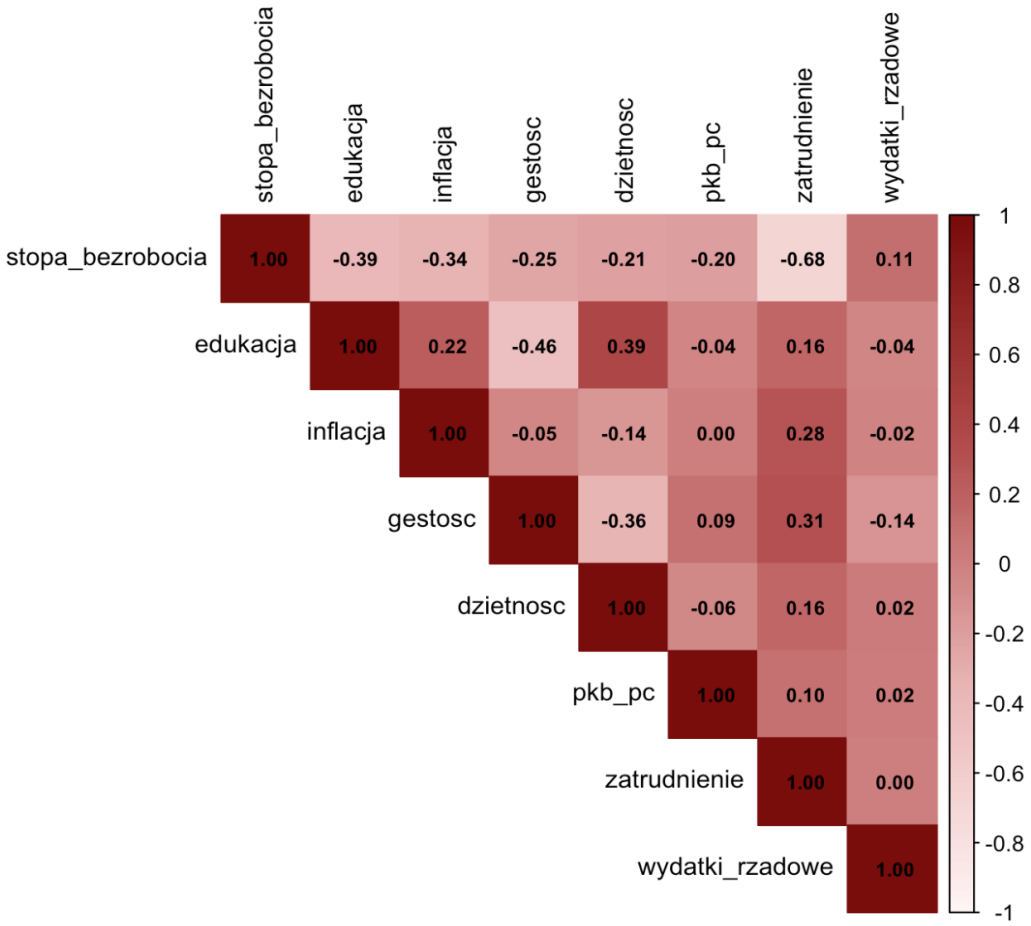

Rysunek 3.2. Macierz korelacji zmiennych.

Macierz korelacji (Rysunek 3.2) wskazuje na kilka wyraźnych zależności między zmiennymi. Najsilniejsze ujemne korelacje dotyczą relacji stopy bezrobocia z zatrudnieniem (-0,68),

gęstości zaludnienia z edukacją (-0,46) oraz stopy bezrobocia z edukacją (-0,39), co oznacza, że wzrost poziomu wykształcenia i wskaźnika zatrudnienia wiąże się ze spadkiem bezrobocia, a w bardziej zurbanizowanych krajach poziom wykształcenia może być niższy. Z kolei stosunkowo silna dodatnia korelacja występuje między edukacją a dzietnością (0,39). Pozostałe zależności są słabsze, co sugeruje brak wyraźnych liniowych powiązań między większością zmiennych.

Tabela 3.2. Współczynniki VIF dla zmiennych.

edukacja	**inflacja**	**gestosc**	**dzietnosc**	**pkb_pc**	**zatrudnienie**	**wydatki rzadowe**
1,591	1,26	1,835	1,461	1,02	1,516	1,047

Współczynnik VIF pozwala ocenić, czy w modelu występuje współliniowość między predykatorami. Wszystkie uzyskane wartości mieszczą się w przedziale 1 - 2, co oznacza niski poziom współliniowości.

4. Budowa modeli

4.1. Model regresji łącznej

W pierwszym etapie estymacji zastosowano model regresji łączonej (pooled OLS), który stanowi podstawowe podejście w modelowaniu danych panelowych. W podejściu tym wszystkie obserwacje traktowane są jako jednorodny zbiór danych, bez rozróżnienia na poszczególne jednostki przekrojowe oraz efekty czasowe.

Model ten ma postać:

$$stopa_bezrobocia_{it} = \beta_0 + \beta_1 edukacja_{it} + \beta_2 inflacja_{it} + \beta_3 gestosc_{it} + \beta_4 dzietnosc_{it} + \beta_5 pkb_pc_{it} + \beta_6 zatrudnienie_{it} + \beta_7 wydatki_rzadowe_{it} + u_{it},$$

gdzie:

β_0 - wspólny dla wszystkich jednostek wyraz wolny,

β_k - parametry strukturalne modelu, określające wpływ zmiennych objaśniających,

u_{it} - składnik losowy.

```
Residuals:
     Min.   1st Qu.    Median   3rd Qu.      Max.
-3.967296 -1.160853  0.021644  0.920622  8.421134

Coefficients:
                     Estimate    Std. Error t-value              Pr(>|t|)
(Intercept)     36.1846213734  1.9517621460 18.5395 < 0.00000000000000022 ***
edukacja        -0.1015128879  0.0132702406 -7.6497 0.0000000000005763789 ***
inflacja        -0.1292632838  0.0345105468 -3.7456             0.0002284 ***
gestosc         -0.0033060729  0.0005360629 -6.1673 0.0000000031682176697 ***
dzietnosc       -2.3821968554  0.7892364054 -3.0184             0.0028331 **
pkb_pc          -0.0000203162  0.0000054755 -3.7104             0.0002605 ***
zatrudnienie    -0.2308219110  0.0261015282 -8.8432 0.0000000000000002697 ***
wydatki_rzadowe  0.0189525110  0.0166549367  1.1380             0.2563456
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Total Sum of Squares:    2088.6
Residual Sum of Squares: 744.18
R-Squared:      0.64369
Adj. R-Squared: 0.63266
F-statistic: 58.3266 on 7 and 226 DF, p-value: < 0.000000000000000222
```

Rysunek 4.1. Podsumowanie wyników dla modelu regresji łącznej.

Model regresji łącznej (Rysunek 4.1) jest statystycznie istotny i wyjaśnia około 64% zmienności zmiennej objaśnianej. Większość zmiennych (edukacja, inflacja, gęstość, dzietność, pkb_pc, zatrudnienie) jest statystycznie istotna w modelu. Zmienną nieistotną statystycznie w modelu okazały się jedynie wydatki rządowe.

4.2. Model z efektami ustalonymi (FE) jednokierunkowy

Model z ustalonymi efektami indywidualnymi służy do analizy zmienności zachodzącej wewnątrz jednostek w czasie. Głównym założeniem modelu jest występowanie nieobserwowalnych cech charakterystycznych dla poszczególnych jednostek (krajów), które są stałe w czasie, lecz mogą wpływać na poziom zmiennej zależnej. Model ten eliminuje nieobserwowalną heterogeniczność poprzez wprowadzenie indywidualnego wyrazu wolnego α_i dla każdej jednostki, a estymowane parametry β_k opierają się wyłącznie na zmianach zachodzących w obrębie kraju, a nie pomiędzy krajami. Dzięki temu model pozwala na identyfikację wpływu zmiennych objaśniających na zmienną zależną z pominięciem wszystkich stałych w czasie czynników.
Model ten ma postać:

$$stopa_bezrobocia_{it} = \alpha_i + \beta_1 edukacja_{it} + \beta_2 inflacja_{it} + \beta_3 gestosc_{it} + \beta_4 dzietnosc_{it} + \beta_5 pkb_pc_{it} + \beta_6 zatrudnienie_{it} + \beta_7 wydatki_rzadowe_{it} + u_{it},$$

gdzie:
α_i - indywidualny efekt ustalony (cechy charakterystyczne dla kraju i stałe w czasie),
β_k - parametry strukturalne modelu, określające wpływ zmiennych objaśniających,
u_{it} - składnik losowy.

```
Residuals:
       Min.     1st Qu.      Median     3rd Qu.        Max.
-1.84241055 -0.40499722  0.00045829  0.32637100  3.50140875

Coefficients:
                     Estimate    Std. Error  t-value              Pr(>|t|)
edukacja        -0.3275731350  0.0375541834  -8.7227  0.000000000000001032 ***
inflacja         0.0541235790  0.0204821273   2.6425              0.008878 **
gestosc          0.0248238550  0.0031903539   7.7809  0.000000000000370598 ***
dzietnosc       -0.0573667920  0.7879643488  -0.0728              0.942035
pkb_pc           0.0000053683  0.0000169538   0.3166              0.751842
zatrudnienie    -0.5417608667  0.0374120059 -14.4809 < 0.00000000000000022 ***
wydatki_rzadowe -0.0009573804  0.0213506720  -0.0448              0.964279
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Total Sum of Squares:    573.89
Residual Sum of Squares: 120.83
R-Squared:      0.78945
Adj. R-Squared: 0.75593
F-statistic: 107.664 on 7 and 201 DF, p-value: < 0.000000000000000222
```

Rysunek 4.2. Podsumowanie wyników dla modelu FE jednokierunkowego.

Model z efektami ustalonymi (FE) jednokierunkowy dla efektów indywidualnych (Rysunek 4.2) jest istotny statystycznie i wyjaśnia około 79% zmienności analizowanej stopy bezrobocia. Zmiennych statystycznie istotnych jest 4 i są to: edukacja, inflacja, gęstość zaludnienia oraz zatrudnienie. Pozostałe zmienne, czyli dzietność, PKB per capita oraz wydatki rządowe okazały się nieistotne statystycznie w tym modelu.

4.3. Model z efektami ustalonymi (FE) dwukierunkowy

Model dwukierunkowy z efektami ustalonymi rozszerza klasyczny model FE o dodatkowy komponent efektów czasowych. Oznacza to, że oprócz indywidualnych efektów krajowych α_i, model uwzględnia także efekty wspólne dla wszystkich krajów w danym czasie λ_t. Dzięki uwzględnieniu zarówno efektów indywidualnych, jak i czasowych, model eliminuje wszelkie nieobserwowalne czynniki stałe w czasie w obrębie jednostki oraz czynniki wspólne, zmienne w czasie, które mogłyby zniekształcać estymację parametrów.

Model ten ma postać:

$$stopa_bezrobocia_{it} = \alpha_i + \lambda_t + \beta_1 edukacja_{it} + \beta_2 inflacja_{it} + \beta_3 gestosc_{it} + \beta_4 dzietnosc_{it} + \beta_5 pkb_pc_{it} + \beta_6 zatrudnienie_{it} + \beta_7 wydatki_rzadowe_{it} + u_{it},$$

gdzie:

α_i - indywidualny efekt ustalony (cechy charakterystyczne dla kraju i stałe w czasie),

λ_t - efekt czasowy (wspólny dla wszystkich krajów w danej jednostce czasu),

β_k - parametry strukturalne modelu, określające wpływ zmiennych objaśniających,

u_{it} - składnik losowy.

```
Residuals:
       Min.     1st Qu.      Median     3rd Qu.        Max.
-1.66829925 -0.35203453 -0.00069372  0.32839115  3.04700633

Coefficients:
                      Estimate     Std. Error t-value             Pr(>|t|)
edukacja        -0.29164615967  0.04172042047 -6.9905 0.000000000043514309 ***
inflacja         0.11785860334  0.03557179715  3.3133             0.001101 **
gestosc          0.02383815440  0.00319815954  7.4537 0.000000000002978892 ***
dzietnosc       -0.90474395614  0.86855860428 -1.0417             0.298872
pkb_pc           0.00000036539  0.00001861572  0.0196             0.984360
zatrudnienie    -0.42255069530  0.04839808572 -8.7307 0.000000000000001194 ***
wydatki_rzadowe -0.06802980406  0.03363309870 -2.0227             0.044484 *
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Total Sum of Squares:    200.71
Residual Sum of Squares: 99.31
R-Squared:      0.50521
Adj. R-Squared: 0.40266
F-statistic: 28.152 on 7 and 193 DF, p-value: < 0.000000000000000222
```

Rysunek 4.3. Podsumowanie wyników dla modelu FE dwukierunkowego.

Model dwukierunkowy z efektami ustalonymi (FE) (Rysunek 4.3) pozostaje statystycznie istotny. W przypadku tego modelu zmiennymi istotnymi statystycznie są: edukacja, inflacja, gęstość zaludnienia, zatrudnienie oraz wydatki rządowe. Podobnie jak we wcześniejszych modelach PKB per capita i dzietnosc pozostają nieistotne statystycznie.

4.4. Model z efektami losowymi (RE) jednokierunkowy

Model jednokierunkowy z efektami losowymi stanowi alternatywę dla modelu z efektami ustalonymi. Zakłada on, że nieobserwowalne cechy indywidualne jednostek panelowych nie są stałymi, odrębnymi poziomami dla każdego kraju, lecz mają charakter losowy i są niezależne od zmiennych objaśniających. Oznacza to, że indywidualny efekt α_i traktowany jest jako składnik przypadkowy, będący częścią składnika losowego modelu. W przeciwieństwie do modelu z efektami ustalonymi, który eliminuje wszystkie cechy stałe w czasie, model z efektami losowymi wykorzystuje zarówno zmienność wewnątrz jednostek, jak i pomiędzy jednostkami.

Model ten ma postać:

$$stopa_bezrobocia_{it} = \beta_0 + \beta_1 edukacja_{it} + \beta_2 inflacja_{it} + \beta_3 gestosc_{it} + \beta_4 dzietnosc_{it} + \beta_5 pkb_pc_{it} + \beta_6 zatrudnienie_{it} + \beta_7 wydatki_rzadowe_{it} + u_{it},$$

gdzie:

β_0 - wspólny dla wszystkich jednostek wyraz wolny,

β_k - parametry strukturalne modelu, określające wpływ zmiennych objaśniających,

$u_{it} = \alpha_i + \epsilon_{it}$ - dwuskładnikowe zaburzenie losowe, α_i - losowy efekt indywidualny (stały w czasie, ale różny dla każdej jednostki), ϵ_{it} - czysto losowy błąd idiosynkratyczny.

```
Effects:
                 var std.dev share
idiosyncratic 0.6012  0.7753 0.182
individual    2.6989  1.6428 0.818
theta: 0.8446

Residuals:
     Min.   1st Qu.    Median   3rd Qu.      Max.
-2.173279 -0.560050 -0.004815  0.508469  4.507558

Coefficients:
                    Estimate   Std. Error  z-value              Pr(>|z|)
(Intercept)     55.630373804  3.048444641  18.2488 < 0.00000000000000022 ***
edukacja        -0.111238829  0.024104321  -4.6149           0.000003933 ***
inflacja         0.015809676  0.022832615   0.6924               0.48868
gestosc          0.000707682  0.001243769   0.5690               0.56937
dzietnosc       -0.962606682  0.821616495  -1.1716               0.24136
pkb_pc          -0.000021483  0.000012976  -1.6556               0.09779 .
zatrudnienie    -0.514759749  0.037904643 -13.5804 < 0.00000000000000022 ***
wydatki_rzadowe -0.007556050  0.022424000  -0.3370               0.73615
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Total Sum of Squares:    610.47
Residual Sum of Squares: 186.8
R-Squared:      0.694
Adj. R-Squared: 0.68452
Chisq: 512.564 on 7 DF, p-value: < 0.000000000000000222
```

Rysunek 4.4. Podsumowanie wyników dla modelu RE jednokierunkowego.

Model jednokierunkowy z efektami losowymi (RE) (Rysunek 4.4) jest istotny statystycznie i wyjaśnia około 69% zmienności zmiennej objaśnianej. W przypadku tego modelu zmiennymi istotnymi statystycznie okazały się jedynie edukacja oraz zatrudnienie. Pozostałe zmienne nie wykazują istotności statystycznej, z wyjątkiem zmiennej pkb_pc, która osiąga istotność dopiero na poziomie 0,1.

4.5. Model z efektami losowymi (RE) dwukierunkowy

Model dwukierunkowy z efektami losowymi jest rozszerzeniem klasycznego modelu jednokierunkowego z efektami losowymi. Pozwala on na jednoczesne uwzględnienie losowych efektów indywidualnych (różnice między krajami) oraz losowych efektów czasowych (szoki lub trendy działające w danym roku na wszystkie jednostki). Model ten zakłada, że zarówno efekt indywidualny α_i, jak i efekt czasowy λ_t są nieskorelowane z regresorami.

Model ten ma postać:

$$stopa_bezrobocia_{it} = \beta_0 + \beta_1 edukacja_{it} + \beta_2 inflacja_{it} + \beta_3 gestosc_{it} + \beta_4 dzietnosc_{it} + \beta_5 pkb_pc_{it} + \beta_6 zatrudnienie_{it} + \beta_7 wydatki_rzadowe_{it} + u_{it},$$

gdzie:

β_0 - wspólny dla wszystkich jednostek wyraz wolny,

β_k - parametry strukturalne modelu, określające wpływ zmiennych objaśniających,

$u_{it} = \alpha_i + \lambda_t + \epsilon_{it}$ - trzyskładnikowe zaburzenie losowe, α_i - losowy efekt indywidualny, λ_t - losowy efekt czasowy, ϵ_{it} - czysto losowy błąd idiosynkratyczny.

```
Effects:
                 var std.dev share
idiosyncratic 0.5146  0.7173  0.16
individual    2.7085  1.6458  0.84
time          0.0000  0.0000  0.00
theta: 0.8562 (id) 0 (time) 0 (total)

Residuals:
      Min.    1st Qu.     Median    3rd Qu.       Max.
-2.1402647 -0.5478969 -0.0044266  0.5099745  4.4550141

Coefficients:
                    Estimate   Std. Error  z-value              Pr(>|z|)
(Intercept)     56.352357347  3.067709578  18.3695 < 0.0000000000000022 ***
edukacja        -0.113365088  0.024609259  -4.6066           0.000004093 ***
inflacja         0.019172189  0.022697913   0.8447                0.3983
gestosc          0.001073371  0.001299988   0.8257                0.4090
dzietnosc       -0.947829022  0.821559746  -1.1537                0.2486
pkb_pc          -0.000021155  0.000013378  -1.5814                0.1138
zatrudnienie    -0.522930685  0.038085812 -13.7303 < 0.0000000000000022 ***
wydatki_rzadowe -0.008943064  0.022458398  -0.3982                0.6905
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Total Sum of Squares:    605.2
Residual Sum of Squares: 182.63
R-Squared:      0.69823
Adj. R-Squared: 0.68888
Chisq: 522.911 on 7 DF, p-value: < 0.000000000000000222
```

Rysunek 4.5. Podsumowanie wyników dla modelu RE dwukierunkowego.

Model dwukierunkowy z efektami losowymi (RE) (Rysunek 4.5) jest statystycznie istotny i wyjaśnia około 70% zmienności zmiennej objaśnianej. W przypadku tego modelu statystycznie istotny wpływ na bezrobocie wykazują jedynie dwie zmienne: edukacja oraz zatrudnienie.

5. Wybór najlepszego modelu poprzez zastosowanie testów

W celu określenia, która postać modelu panelowego najlepiej opisuje analizowane zjawisko, konieczne jest porównanie modelu regresji łącznej (OLS), modeli z efektami ustalonymi (FE) oraz modeli z efektami losowymi (RE), zarówno jednokierunkowych, jak i dwukierunkowych. Aby dokonać obiektywnego wyboru właściwego modelu, zastosowane zostały testy porównawcze wykorzystywane w analizie danych panelowych, takie jak test Breuscha - Pagana pozwalający ocenić, czy model OLS jest odpowiedni, test F dla efektów ustalonych oraz test Hausmana służący do rozróżnienia między modelami FE i RE. Na ich podstawie możliwe jest wskazanie modelu, który najtrafniej opisuje zależność między stopą bezrobocia a zmiennymi objaśniającymi w badanych danych panelowych.

Do testów przyjęty zostaje poziom istotności $\boldsymbol{\alpha = 0,05}$.

5.1. Porównanie regresji łącznej i modelu FE (jednokierunkowego)

Test F dla istotności efektów indywidualnych:

$\boldsymbol{H_0}$: $Model\ regresji$ łącznej $jest\ wystarczający, \alpha_1 = \alpha_2 = \ldots = \alpha_n = 0$
$\boldsymbol{H_1}$: $Model\ z\ efektami\ ustalonymi\ (FE)\ jednokierunkowy\ jest\ lepszym\ wyborem,$
$\exists\ \alpha_i \neq 0$

Hipoteza zerowa zakłada, że indywidualne efekty stałe nie istnieją, czyli wszystkie α_i są równe zero. W takim przypadku model FE nie jest potrzebny, a odpowiednim modelem jest regresja łączona (pooled OLS). Hipoteza alternatywna zakłada, że przynajmniej jeden efekt indywidualny jest różny od zera. Oznacza to, że jednostki różnią się nieobserwowalnymi cechami stałymi w czasie, które wpływają na zmienną zależną, więc należy stosować model FE.

```
        F test for individual effects

data:  stopa_bezrobocia ~ edukacja + inflacja + gestosc + dzietnosc +  ...
F = 41.477, df1 = 25, df2 = 201, p-value < 0.00000000000000022
alternative hypothesis: significant effects
```

Rysunek 5.1. Wyniki testu F (OLS vs FE 1K).

Wniosek: Dla przyjętego poziomu istotności $\alpha = 0{,}05$ odrzucona zostaje hipoteza zerowa, czyli model z efektami ustalonymi (FE) jednokierunkowy jest statystycznie istotnie lepszy od modelu regresji łącznej.

5.2. Porównanie regresji łącznej i modelu RE (jednokierunkowego)

Test Breuscha - Pagana dla efektów losowych:

$\boldsymbol{H_0}$: $Model\ regresji$ łącznej $jest\ wystarczający, \sigma^2 = 0$

$\boldsymbol{H_1}$: $Model\ z\ efektami\ ustalonymi\ (RE)\ jednokierunkowy\ jest\ lepszym\ wyborem,$
$\sigma^2 > 0$

Hipoteza zerowa zakłada, że efekty losowe nie występują, czyli wariancja składnika losowego charakterystycznego dla jednostek jest równa zero. Oznacza to, że poszczególne jednostki nie różnią się między sobą w sposób systematyczny, a więc model regresji łącznej (pooled OLS) jest wystarczający. Hipoteza alternatywna zakłada, że wariancja efektów losowych jest większa od zera. Oznacza to, że jednostki posiadają własne, nieobserwowane cechy, które wpływają na zmienną zależną. W takim przypadku model OLS pomija istotną część struktury danych, dlatego należy stosować model z efektami losowymi (RE).

```
        Lagrange Multiplier Test - (Breusch-Pagan)

data:  stopa_bezrobocia ~ edukacja + inflacja + gestosc + dzietnosc +  ...
chisq = 385.16, df = 1, p-value < 0.00000000000000022
alternative hypothesis: significant effects
```

Rysunek 5.2. Wyniki testy Breuscha-Pagana (OLS vs RE 1K).

Wniosek: Dla przyjętego poziomu istotności $\alpha = 0{,}05$ odrzucona zostaje hipoteza zerowa, czyli model z efektami losowymi (RE) jednokierunkowy jest statystycznie istotnie lepszy od modelu regresji łącznej.

5.3. Porównanie modelu FE jednokierunkowego i modelu FE dwukierunkowego

Test F dla istotności efektów czasowych:

$\boldsymbol{H_0}$: $Model\ z\ efektami\ ustalonymi\ (FE)\ jednokierunkowy\ jest\ wystarczający,$
$\gamma_1 = \gamma_2 = \cdots = \gamma_T = 0$
$\boldsymbol{H_1}$: $Model\ z\ efektami\ ustalonymi\ (FE)\ dwukierunkowy\ jest\ lepszym\ wyborem,$
$\exists\, \gamma_t \neq 0$

Hipoteza zerowa zakłada, że efekty czasowe nie istnieją, czyli wszystkie efekty związane z poszczególnymi latami są równe zero. Oznacza to, że zmienność w czasie nie wpływa na zmienną zależną w sposób systematyczny, a więc model FE jednokierunkowy (z efektami indywidualnymi) jest wystarczający. Hipoteza alternatywna zakłada, że przynajmniej jeden efekt czasowy różni się od zera. Oznacza to, że lata istotnie różnią się między sobą pod względem wpływu na zmienną zależną, dlatego lepszym wyborem jest model FE dwukierunkowy, który uwzględnia zarówno efekty indywidualne, jak i czasowe.

```
        F test for twoways effects

data:  stopa_bezrobocia ~ edukacja + inflacja + gestosc + dzietnosc +  ...
F = 5.2281, df1 = 8, df2 = 193, p-value = 0.00000626
alternative hypothesis: significant effects
```

Rysunek 5.3. Wyniki testu F (FE 1K vs FE 2K).

Wniosek: Dla przyjętego poziomu istotności $\alpha = 0{,}05$ odrzucona zostaje hipoteza zerowa, czyli model z efektami ustalonymi (FE) dwukierunkowy jest statystycznie istotnie lepszy od modelu z efektami ustalonymi (FE) jednokierunkowego.

5.4. Porównanie modelu FE (jednokierunkowego) i modelu RE (jednokierunkowego)

Test Hausmana:

$\boldsymbol{H_0}$: $Model\ z\ efektami\ losowymi\ (RE) jednokierunkowy\ jest\ zgodny, można\ go\ zastosować,$
$\boldsymbol{H_1}$: $Model\ z\ efektami\ losowymi\ (RE) jednokierunkowy\ jest\ niezgodny, lepszym\ wyborem\ będzie\ model\ z\ efektami\ ustalonymi\ (FE)\ jednokierunkowy,$

```
        Hausman Test

data:  stopa_bezrobocia ~ edukacja + inflacja + gestosc + dzietnosc +  ...
chisq = 19.542, df = 7, p-value = 0.006648
alternative hypothesis: one model is inconsistent
```

Rysunek 5.4. Wyniki testu Hausmana (FE 1K vs RE 1K).

Wniosek: Dla przyjętego poziomu istotności $\alpha = 0{,}05$ odrzucona zostaje hipoteza zerowa, czyli model z efektami losowymi (RE) jednokierunkowy jest niezgodny, a więc nie może być uznany za poprawny, więc lepszym wyborem jest model z efektami ustalonymi (FE) jednokierunkowy.

5.5. Porównanie modelu FE (dwukierunkowego) i modelu RE (dwukierunkowego)

Test Hausmana:

$\boldsymbol{H_0}$: $Model\ z\ efektami\ losowymi\ (RE)\ dwukierunkowy\ jest\ zgodny, można\ go\ zastosować.$
$\boldsymbol{H_1}$: $Model\ z\ efektami\ losowymi\ (RE)\ dwukierunkowy\ jest\ niezgodny, lepszym\ wyborem\ będzie\ model\ z\ efektami\ ustalonymi\ (FE)\ dwukierunkowy.$

```
        Hausman Test

data:  stopa_bezrobocia ~ edukacja + inflacja + gestosc + dzietnosc +  ...
chisq = 68.354, df = 7, p-value = 0.000000000003176
alternative hypothesis: one model is inconsistent
```

Rysunek 5.5. Wyniki testu Hausmana (FE 2K vs RE 2K).

Wniosek: Dla przyjętego poziomu istotności $\alpha = 0{,}05$ odrzucona zostaje hipoteza zerowa, czyli model z efektami losowymi (RE) dwukierunkowy jest niezgodny, a więc nie może być uznany za poprawny, więc lepszym wyborem jest model z efektami ustalonymi (FE) dwukierunkowy.

6. Ostateczny wybór modelu i dobór zmiennych

Po przeprowadzeniu testów, najlepszym modelem okazał się model z efektami ustalonymi (FE) dwukierunkowy, dlatego to właśnie on zostanie wykorzystany w dalszej analizie, ponieważ najlepiej opisuje badane zjawisko.

```
Twoways effects Within Model

Call:
plm(formula = stopa_bezrobocia ~ edukacja + inflacja + gestosc +
    dzietnosc + pkb_pc + zatrudnienie + wydatki_rzadowe, data = panel,
    effect = "twoways", model = "within", index = c("kraj", "rok"))

Balanced Panel: n = 26, T = 9, N = 234

Residuals:
       Min.     1st Qu.      Median     3rd Qu.        Max.
-1.66829925 -0.35203453 -0.00069372  0.32839115  3.04700633

Coefficients:
                      Estimate     Std. Error t-value             Pr(>|t|)
edukacja        -0.29164615967  0.04172042047 -6.9905 0.000000000043514309 ***
inflacja         0.11785860334  0.03557179715  3.3133             0.001101 **
gestosc          0.02383815440  0.00319815954  7.4537 0.000000000002978892 ***
dzietnosc       -0.90474395614  0.86855860428 -1.0417             0.298872
pkb_pc           0.00000036539  0.00001861572  0.0196             0.984360
zatrudnienie    -0.42255069530  0.04839808572 -8.7307 0.000000000000001194 ***
wydatki_rzadowe -0.06802980406  0.03363309870 -2.0227             0.044484 *
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Total Sum of Squares:    200.71
Residual Sum of Squares: 99.31
R-Squared:      0.50521
Adj. R-Squared: 0.40266
F-statistic: 28.152 on 7 and 193 DF, p-value: < 0.000000000000000222
```

Rysunek 6.1. Podsumowanie wyników dla modelu FE dwukierunkowego.

Wstępna analiza istotności parametrów wskazuje, że zmienne pkb_pc oraz dzietnosc nie wykazują statystycznie istotnego wpływu na stopę bezrobocia. Dlatego podjęta została próba ich stopniowego usuwania z modelu, tak aby ocenić, jak eliminacja każdej z nich wpływa na istotność pozostałych zmiennych oraz ogólne dopasowanie modelu.

6.1. Usunięcie zmiennej pkb_pc

```
Twoways effects Within Model

Call:
plm(formula = stopa_bezrobocia ~ edukacja + inflacja + gestosc +
    dzietnosc + zatrudnienie + wydatki_rzadowe, data = panel,
    effect = "twoways", model = "within", index = c("kraj", "rok"))

Balanced Panel: n = 26, T = 9, N = 234

Residuals:
       Min.     1st Qu.      Median     3rd Qu.        Max.
-1.66938011 -0.35197614 -0.00093117  0.32878944  3.04770381

Coefficients:
                  Estimate Std. Error t-value              Pr(>|t|)
edukacja        -0.2916746  0.0415876 -7.0135 0.0000000000377011591 ***
inflacja         0.1177962  0.0353381  3.3334              0.001028 **
gestosc          0.0238414  0.0031858  7.4837 0.0000000000024576670 ***
dzietnosc       -0.9080563  0.8498084 -1.0685              0.286604
zatrudnienie    -0.4224799  0.0481391 -8.7762 0.0000000000000008721 ***
wydatki_rzadowe -0.0682563  0.0315096 -2.1662              0.031515 *
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Total Sum of Squares:    200.71
Residual Sum of Squares: 99.31
R-Squared:      0.50521
Adj. R-Squared: 0.40574
F-statistic: 33.014 on 6 and 194 DF, p-value: < 0.000000000000000222
```

Rysunek 6.2. Model po usunięciu zmiennej pkb_pc.

Usunięcie zmiennej pkb_pc w modelu FE dwukierunkowym pozostawia w modelu jedną zmienna statystycznie nieistotną - dzietność. Struktura zależności pozostaje stabilna oraz dopasowanie modelu pozostaje praktycznie niezmienione. Oznacza to, że usunięcie zmiennej pkb_pc jest uzasadnione, ponieważ zmienna ta nie wnosi istotnej informacji do modelu.

6.2. Usunięcie zmiennej dzietnosc

```
Twoways effects Within Model

Call:
plm(formula = stopa_bezrobocia ~ edukacja + inflacja + gestosc +
    pkb_pc + zatrudnienie + wydatki_rzadowe, data = panel, effect = "twoways",
    model = "within", index = c("kraj", "rok"))

Balanced Panel: n = 26, T = 9, N = 234

Residuals:
      Min.    1st Qu.     Median    3rd Qu.       Max.
-1.6436086 -0.3592682  0.0063051  0.3261300  2.9662861

Coefficients:
                     Estimate    Std. Error  t-value              Pr(>|t|)
edukacja        -0.3001122617  0.0409300798  -7.3323   0.00000000000598209 ***
inflacja         0.1204112704  0.0354950645   3.3923             0.0008399 ***
gestosc          0.0248153888  0.0030581364   8.1145   0.00000000000005478 ***
pkb_pc           0.0000041331  0.0000182650   0.2263             0.8212191
zatrudnienie    -0.4464815904  0.0426072285 -10.4790 < 0.00000000000000022 ***
wydatki_rzadowe -0.0709411806  0.0335241137  -2.1161             0.0356095 *
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Total Sum of Squares:    200.71
Residual Sum of Squares: 99.868
R-Squared:      0.50243
Adj. R-Squared: 0.4024
F-statistic: 32.6488 on 6 and 194 DF, p-value: < 0.000000000000000222
```

Rysunek 6.3. Model po usunięciu zmiennej dzietnosc.

Po usunięciu zmiennej dzietnosc z modelu FE dwukierunkowego, zmienna pkb_pc nadal pozostaje statystycznie nieistotna, a jakość dopasowania modelu praktycznie się nie zmienia. Oznacza to, że eliminacja wspominanej zmiennej nie wpływa na strukturę zależności w modelu, a sama zmienna nie wnosiła istotnej informacji wyjaśniającej.

6.3. Usunięcie zmiennych pkb_pc oraz dzietnosc

```
Twoways effects Within Model

Call:
plm(formula = stopa_bezrobocia ~ edukacja + inflacja + gestosc +
    zatrudnienie + wydatki_rzadowe, data = panel, effect = "twoways",
    model = "within", index = c("kraj", "rok"))

Balanced Panel: n = 26, T = 9, N = 234

Residuals:
      Min.    1st Qu.     Median    3rd Qu.       Max.
-1.6552517 -0.3554505  0.0052651  0.3306331  2.9710110

Coefficients:
                  Estimate Std. Error  t-value              Pr(>|t|)
edukacja        -0.3008115  0.0407139  -7.3884   0.00000000000424417 ***
inflacja         0.1197878  0.0353018   3.3933             0.0008365 ***
gestosc          0.0248951  0.0030304   8.2151   0.00000000000002886 ***
zatrudnienie    -0.4466797  0.0424945 -10.5115 < 0.00000000000000022 ***
wydatki_rzadowe -0.0737293  0.0311019  -2.3706             0.0187357 *
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Total Sum of Squares:    200.71
Residual Sum of Squares: 99.894
R-Squared:      0.5023
Adj. R-Squared: 0.40531
F-statistic: 39.3598 on 5 and 195 DF, p-value: < 0.000000000000000222
```

Rysunek 6.4. Model po usunięciu zmiennych pkb_pc oraz dzietnosc.

Po usunięciu obu zmiennych pkb_pc oraz dzietnosc wszystkie pozostałe zmienne w modelu dwukierunkowym FE pozostają statystycznie istotne. Jednocześnie dopasowanie modelu nie ulega poprawie. Oznacza to, że eliminacja tych dwóch zmiennych nie wpływa na jakość wyjaśniania zmiennej zależnej przez model, a zmienne pkb_pc i dzietnosc nie wnosiły istotnej wartości informacyjnej do modelu.

6.4. Ostateczny dobór zmiennych

Najbardziej uzasadnionym wyborem okazało się usunięcie dwóch zmiennych: pkb_pc oraz dzietnosc. W obu przypadkach zmienne te były nieistotne statystycznie, a ich eliminacja nie pogarszała dopasowania modelu. Po ich usunięciu model FE dwukierunkowy zawiera wyłącznie zmienne istotne statystycznie, co oznacza, że pozostawiony zestaw predykatorów najlepiej wyjaśnia zmienność stopy bezrobocia w analizowanym panelu.

7. Weryfikacja modelu

7.1. Testowanie autokorelacji składnika losowego

7.1.1. Autokorelacja czasowa w obrębie jednostki

Test Wooldridge'a:

$\boldsymbol{H_0}$: $Brak\ autokorelacji\ pierwszego\ rzędu\ w\ składniku\ losowym, \rho = 0$

$\boldsymbol{H_1}$: $Występuje\ autokorelacja\ pierwszego\ rzędu\ \big(AR(1)\big), \rho \neq 0$

```
        Wooldridge's test for serial correlation in FE panels

data:  model3
F = 68.631, df1 = 1, df2 = 206, p-value = 1.502e-14
alternative hypothesis: serial correlation
```

Rysunek 7.1. Wynik testu Wooldridge'a.

Test Breuscha-Godfreya/Wooldridge'a:

$\boldsymbol{H_0}$: $Brak\ autokorelacji\ pierwszego\ rzędu\ w\ składniku\ losowym,$

$\rho_1 = \rho_2 = \cdots = \rho_k = 0$

$\boldsymbol{H_1}$: $Występuje\ autokorelacja\ pierwszego\ rzędu\ \big(AR(1)\big), \exists\ \rho_j\ \neq\ 0$

Tabela 7.1. Wyniki testu Breuscha-Godfreya/Wooldridge'a.

df	p-value
1	2,536e-08
2	1,624e-07
3	9,776e-09
4	6,964e-09
5	8,234e-09
6	1,488e-08
7	9,846e-09
8	2,886e-09

Na podstawie przeprowadzonych testów weryfikujących założenie o braku autokorelacji składnika losowego stwierdzono jednoznacznie, że w modelu występuje silna i istotna autokorelacja składnika losowego. W pierwszej kolejności wykonany został test Wooldridge'a, który bada autokorelację pierwszego rzędu. Otrzymana wartość p - value odrzuca hipotezę zerową o braku autokorelacji AR(1). Oznacza to, że w modelu występuje autokorelacja składnika losowego pierwszego rzędu. Następnie przeprowadzony został test Breuscha - Godfreya/Wooldridge'a, który umożliwia sprawdzenie autokorelacji wyższych rzędów. Wyniki testu dla kolejnych rzędów (od 1 do 8) również wskazują na bardzo niskie wartości p - value, co oznacza, że hipoteza zerowa o braku autokorelacji nie została potwierdzona dla żadnego z rzędów, czyli w modelu występuje nie tylko autokorelacja AR(1), lecz także autokorelacja wyższych rzędów. Można byłoby teoretycznie próbować eliminować autokorelację pierwszego rzędu poprzez transformację z indywidualnym współczynnikiem ρ dla każdego kraju. Takie rozwiązanie jest jednak uzasadnione wyłącznie w sytuacji, w której autokorelacja ogranicza się do procesu AR(1). W analizowanym przypadku testy wskazują na istotną autokorelację również dla opóźnień wyższych rzędów (od 2 do 8), co oznacza, że korekta oparta wyłącznie na AR(1) usuwa jedynie część zależności czasowej i pozostawia istotną autokorelację w składniku losowym. Rozszerzanie transformacji na kolejne rzędy wymagałoby estymacji wielu współczynników ρ oraz prowadziłoby do stopniowej utraty obserwacji początkowych, co przy stosunkowo krótkich szeregach czasowych skutkowałoby znacznym zmniejszeniem liczebności próby. Z tego względu, w przypadku występowania autokorelacji wyższych rzędów, bardziej adekwatnym podejściem jest zastosowanie metod wykorzystujących odporne

błędy standardowe, umożliwiających ujęcie złożonej struktury korelacji w danych panelowych bez konieczności wielokrotnej transformacji.

7.1.2. Zależność przekrojowa

W celu weryfikacji występowania zależności przekrojowej w składniku losowym modelu panelowego przeprowadzono dwa powszechnie stosowane testy: test Pesaran CD oraz test Breuscha - Pagana LM. Ich celem jest ocena czy błędy regresji dotyczące różnych jednostek przekroju (krajów) są ze sobą skorelowane w tym samym okresie.

Test Pesaran CD

$\boldsymbol{H_0}$: $Brak\ zależnośći\ przekrojowej, corr(u_{it}, u_{jt}) = 0\ dla\ i \neq j$

$\boldsymbol{H_1}$: $Istnieje\ zależność\ przekrojowa, corr(u_{it}, u_{jt}) \neq 0\ dla\ i \neq j$

```
        Pesaran CD test for cross-sectional dependence in panels

data:  stopa_bezrobocia ~ edukacja + inflacja + gestosc + zatrudnienie +
wydatki_rzadowe
z = -1.0491, p-value = 0.2941
alternative hypothesis: cross-sectional dependence
```

Rysunek 7.2. Wynik testu Pesaran CD.

Test Breush – Pagan LM

$\boldsymbol{H_0}$: $Brak\ zależnośći\ przekrojowej, corr(u_{it}, u_{jt}) = 0\ dla\ i \neq j$

$\boldsymbol{H_1}$: $Istnieje\ zależność\ przekrojowa, corr(u_{it}, u_{jt}) \neq 0\ dla\ i \neq j$

```
        Breusch-Pagan LM test for cross-sectional dependence in panels

data:  stopa_bezrobocia ~ edukacja + inflacja + gestosc + zatrudnienie +
wydatki_rzadowe
chisq = 610.07, df = 325, p-value < 2.2e-16
alternative hypothesis: cross-sectional dependence
```

Rysunek 7.3. Wynik testu Breush - Pagan LM.

Test Pesaran CD nie wykazał istotnej korelacji błędów pomiędzy jednostkami, co oznacza brak podstaw do odrzucenia hipotezy zerowej o braku zależności przekrojowej. Odmienny wynik uzyskano w teście Breuscha - Pagana LM. Rozbieżność wyników wynika z odmiennych własności asymptotycznych obu testów. Test Pesaran CD osiąga największą moc statystyczną w panelach o stosunkowo dużej liczbie jednostek (N) oraz krótkim szeregu czasowym (T), natomiast test Breuscha - Pagana LM charakteryzuje się większą czułością w odwrotnej konfiguracji, tj. przy małej liczbie jednostek i dużej liczbie obserwacji w czasie. W analizowanym zbiorze danych, obejmującym 26 krajów (N = 26) i 9 lat obserwacji (T = 9), spełnione są przesłanki dla stosowania testu Pesaran CD, podczas gdy test LM może wykazywać tendencję do nadmiernego odrzucania hipotezy zerowej ze względu na niewielką długość szeregu czasowego. Z tego względu za bardziej wiarygodny uznano wynik testu Pesaran CD, sugerujący brak zależności przekrojowej w składniku losowym modelu.

7.2. Badanie heteroskedastyczności składnika losowego

Test Breusha-Pagana

$\boldsymbol{H_0}: Występuje\ homoskedastyczność\ składnika\ losowego, var(u_i) = const = \sigma^2$

$\boldsymbol{H_1}: Występuje\ heteroskedastyczność\ składnika\ losowego,, var(u_i) \neq \sigma^2$

Test Breuscha - Pagana, wykorzystywany do badania heteroskedastyczności składnika losowego może być stosowany wyłącznie w przypadku, gdy w modelu nie występuje autokorelacja składnika losowego. W sytuacji, gdy warunek ten nie jest spełniony, test traci swoją poprawność i nie powinien być stosowany. W przypadku analizowanego modelu wykazana została wcześniej istotna autokorelacja składnika losowego zarówno pierwszego, jak

i wyższych rzędów, co oznacza, że główne założenie testu Breuscha - Pagana nie jest spełnione. Z tego powodu uzyskane wyniki testu (odrzucenie hipotezy zerowej o homoskedastyczności składnika losowego) nie mogą być interpretowane w sposób jednoznaczny i nie powinny stanowić podstawy do formułowania wniosków dotyczących badania heteroskedastyczności składnika losowego.

7.3. Badanie normalności rozkładu reszt

W celu zweryfikowania założenia o normalności rozkładu reszt zastosowano dwa testy: test Shapiro - Wilka oraz test Jarque - Bera.

Test Shapiro-Wilka

$\boldsymbol{H_0}$: $Reszty\ mają\ rozkład\ normalny.$
$\boldsymbol{H_1}$: $Reszty\ nie\ mają\ rozkładu\ normalnego.$

```
        Shapiro-Wilk normality test

data:  reszty
W = 0.95564, p-value = 1.297e-06
```

Rysunek 7.4. Wyniki testu Shapiro - Wilka.

Test Jarque Bera

$\boldsymbol{H_0}$: $Reszty\ mają\ rozkład\ normalny.$
$\boldsymbol{H_1}$: $Reszty\ nie\ mają\ rozkładu\ normalnego.$

```
        Jarque Bera Test

data:  reszty
X-squared = 95.443, df = 2, p-value < 2.2e-16
```

Rysunek 7.5. Wynik testu Jarque Bera.

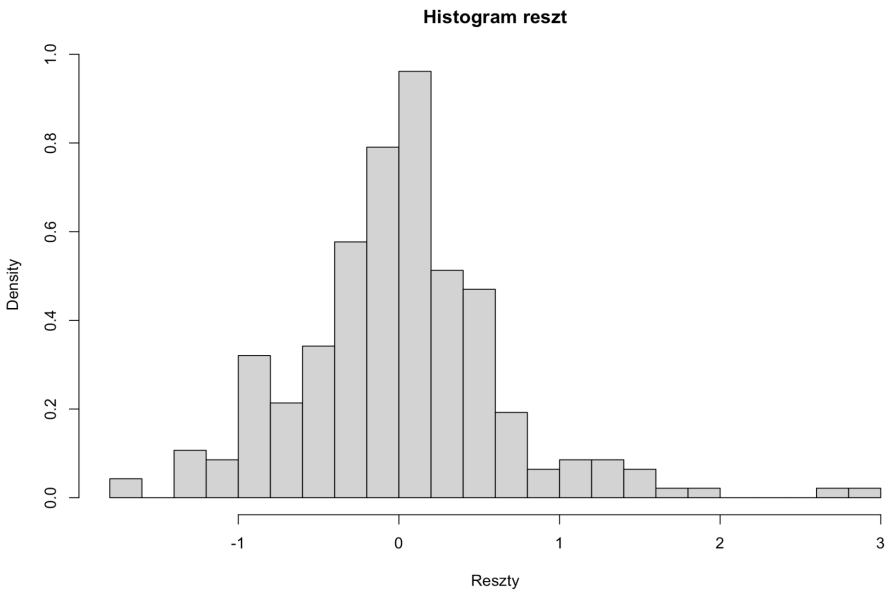

Rysunek 7.6. Histogram reszt.

Wynik testu Shapiro - Wilka prowadzi do odrzucenia hipotezy zerowej, co sugeruje brak normalności reszt. Analogiczny wniosek płynie z testu Jarque - Bera. Oznacza to, że oba zastosowane testy wskazują na istotne odchylenie rozkładu reszt od rozkładu normalnego. Należy jednak podkreślić, że przy większej liczbie obserwacji (w analizie wykorzystano 234 obserwacje) zastosowanie asymptotycznej teorii estymacji pozwala przyjąć, że rozkład estymatorów oraz reszt zbliża się do rozkładu normalnego zgodnie z centralnym twierdzeniem granicznym. W praktyce oznacza to, że pomimo odrzucenia hipotezy normalności w testach formalnych, rozkład reszt można traktować jako asymptotycznie normalny, co potwierdza także wizualna analiza histogramu reszt (Rysunek 7.6), wskazująca na rozkład o kształcie zbliżonym do rozkładu normalnego.

8. Prezentacja ostatecznej postaci modelu i jego ocena

```
Twoways effects Within Model

Call:
plm(formula = stopa_bezrobocia ~ edukacja + inflacja + gestosc +
    zatrudnienie + wydatki_rzadowe, data = panel, effect = "twoways",
    model = "within", index = c("kraj", "rok"))

Balanced Panel: n = 26, T = 9, N = 234

Residuals:
      Min.    1st Qu.     Median    3rd Qu.       Max.
-1.6552517 -0.3554505  0.0052651  0.3306331  2.9710110

Coefficients:
                  Estimate Std. Error  t-value              Pr(>|t|)
edukacja        -0.3008115  0.0407139  -7.3884   0.00000000000424417 ***
inflacja         0.1197878  0.0353018   3.3933             0.0008365 ***
gestosc          0.0248951  0.0030304   8.2151   0.00000000000002886 ***
zatrudnienie    -0.4466797  0.0424945 -10.5115 < 0.00000000000000022 ***
wydatki_rzadowe -0.0737293  0.0311019  -2.3706             0.0187357 *
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Total Sum of Squares:    200.71
Residual Sum of Squares: 99.894
R-Squared:      0.5023
Adj. R-Squared: 0.40531
F-statistic: 39.3598 on 5 and 195 DF, p-value: < 0.000000000000000222
```

Rysunek 8.1. Ostateczny model.

8.1. Odporne błędy standardowe

W przeprowadzonych testach diagnostycznych wykazano, że w analizowanym modelu występuje silna autokorelacja składnika losowego zarówno pierwszego, jak i wyższych rzędów. Z tego powodu nie było możliwe poprawne zweryfikowanie heteroskedastyczności. Głównym problemem w ocenie poprawności modelu jest autokorelacja składnika losowego, której obecność prowadziłaby do zaniżenia błędów standardowych i błędnych wniosków dotyczących istotności współczynników. Aby uzyskać wiarygodne wnioski statystyczne mimo naruszenia założeń, zastosowano odporne błędy standardowe klastrowane po jednostkach panelu, które są jednocześnie odporne na heteroskedastyczność oraz autokorelację dowolnego rzędu wewnątrz krajów. Zastosowane rozwiązanie jest odpowiednie przy strukturze panelu obejmującego dużą

liczbę jednostek (N = 26) i krótką liczbę okresów (T = 9), a także przy braku zależności przekrojowej, co potwierdził test Pesaran CD. Dzięki wykorzystaniu klastrowanych błędów standardowych możliwe było uzyskanie rzetelnych błędów standardowych i poprawnej oceny istotności parametrów modelu pomimo naruszenia założeń dotyczących autokorelacji oraz homoskedastyczności składnika losowego.

```
t test of coefficients:

                  Estimate Std. Error t value  Pr(>|t|)
edukacja        -0.3008115  0.0602984 -4.9887 1.341e-06 ***
inflacja         0.1197878  0.0558880  2.1434   0.03332 *
gestosc          0.0248951  0.0037806  6.5850 4.119e-10 ***
zatrudnienie    -0.4466797  0.0664884 -6.7182 1.970e-10 ***
wydatki_rzadowe -0.0737293  0.0422212 -1.7463   0.08234 .
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

Rysunek 8.2. Odporne błędy standardowe.

8.2. Ocena istotności zmiennych

Po zastosowaniu odpornych błędów standardowych klastrowanych po krajach większość zmiennych objaśniających okazała się statystycznie istotna. Wyniki estymacji wskazują, że cztery spośród pięciu zmiennych objaśniających są istotne statystycznie na poziomie 5%, natomiast wpływ wydatków rządowych nie uzyskał wymaganej istotności (p - value = 0,082). Oznacza to, że dla przyjętego poziomu istotności nie można jednoznacznie potwierdzić wpływu wydatków rządowych na stopę bezrobocia w badanych krajach. Jednocześnie warto zauważyć, że wartość p - value zbliżona do granicy istotności może sugerować potencjalny, lecz słabszy wpływ tej zmiennej na stopę bezrobocia. Z tego względu zmienna została zachowana w modelu ze względów merytorycznych.

8.3. Ocena współczynnika determinacji

Współczynnik determinacji R^2 dla oszacowanego modelu wynosi 0,5023, co oznacza, że około 50% zróżnicowania stopy bezrobocia w analizowanych krajach i latach jest wyjaśniane przez

zmienne uwzględnione w modelu: edukację, inflację, gęstość zaludnienia, zatrudnienie oraz wydatki rządowe.

8.4. Interpretacja parametrów modelu

Oszacowane współczynniki modelu wskazują, że większość zmiennych objaśniających istotnie wpływa na poziom bezrobocia w krajach Unii Europejskiej. Wzrost odsetka osób posiadających co najmniej wykształcenie średnie o 1 punkt procentowy prowadzi średnio do obniżenia stopy bezrobocia o około 0,30 p.p. Wpływ inflacji jest dodatni - wzrost indeksu inflacji o 1 p.p. przekłada się na wzrost bezrobocia o około 0,12 p.p. Gęstość zaludnienia wpływa na stopę bezrobocia dodatnio: zwiększenie liczby mieszkańców o 1 osobę na km² oznacza wzrost bezrobocia o około 0,025 p.p. Zmienna zatrudnienie jest istotną determinantą poziomu bezrobocia - wzrost odsetka osób pracujących o 1 p.p. wiąże się z obniżeniem stopy bezrobocia o około 0,45 p.p. Efekt wydatków rządowych jest słabszy i nieistotny statystycznie na poziomie 5%: zwiększenie udziału wydatków publicznych w PKB o 1 p.p. prowadzi średnio do spadku bezrobocia o około 0,07 p.p.

9. Budowa i ocena modelu dynamicznego

W celu uwzględnienia zależności czasowych w kształtowaniu się stopy bezrobocia zbudowano dynamiczny model panelowy z opóźnioną zmienną zależną. Ujęcie to pozwala odzwierciedlić fakt, że bieżący poziom bezrobocia jest częściowo determinowany wartościami obserwowanymi w okresach poprzednich.

Model ten ma postać:

$$stopa_bezrobocia_{it} = \alpha_i + \lambda_t + \gamma stopa_bezrobocia_{it-1} + \beta_1 edukacja_{it} + \beta_2 inflacja_{it} + \beta_3 gestosc_{it} + \beta_4 zatrudnienie_{it} + \beta_5 wydatki_rzadowe_{it} + u_{it},$$

gdzie:

α_i - indywidualny efekt ustalony (cechy charakterystyczne dla kraju i stałe w czasie),

λ_t - efekt czasowy (wspólny dla wszystkich krajów w danej jednostce czasu),

γ, β_k - parametry strukturalne modelu, określające wpływ zmiennych objaśniających,

u_{it} - składnik losowy.

9.1. Estymator FE

```
Twoways effects Within Model

Call:
plm(formula = stopa_bezrobocia ~ stopa_bezrobocia_lag1 + edukacja +
    inflacja + gestosc + zatrudnienie + wydatki_rzadowe, data = panel_dyn,
    effect = "twoways", model = "within", index = c("kraj", "rok"))

Balanced Panel: n = 26, T = 8, N = 208

Residuals:
      Min.    1st Qu.     Median    3rd Qu.       Max.
-1.2038820 -0.2355614  0.0038601  0.2551279  1.3306677

Coefficients:
                        Estimate Std. Error t-value Pr(>|t|)
stopa_bezrobocia_lag1  0.5988480  0.0464457 12.8935  < 2e-16 ***
edukacja              -0.0414116  0.0326308 -1.2691  0.20615
inflacja               0.0337096  0.0228109  1.4778  0.14133
gestosc                0.0039406  0.0025887  1.5222  0.12982
zatrudnienie          -0.0894208  0.0353407 -2.5303  0.01231 *
wydatki_rzadowe       -0.0137685  0.0209141 -0.6583  0.51122
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Total Sum of Squares:    112.6
Residual Sum of Squares: 32.466
R-Squared:      0.71167
Adj. R-Squared: 0.64683
F-statistic: 69.5209 on 6 and 169 DF, p-value: < 2.22e-16
```

Rysunek 9.1. Model dynamiczny FE.

Dynamiczny model panelowy oszacowany metodą efektów ustalonych z efektami indywidualnymi i czasowymi potwierdza istotną rolę dynamiki procesu bezrobocia. Współczynnik przy opóźnionej stopie bezrobocia jest dodatni (0,60) i istotny statystycznie. Spośród pozostałych zmiennych jedynie wskaźnik zatrudnienia okazał się istotny statystycznie i wpływa ujemnie na stopę bezrobocia. Model jest istotny statystycznie (F - test, $p < 0{,}001$), a współczynnik determinacji $R^2 = 0{,}71$ wskazuje na stosunkowo wysokie dopasowanie modelu do danych. Należy jednak podkreślić, że przy krótkim horyzoncie czasowym ($T = 8$) estymator FE w modelu dynamicznym jest obciążony (obciążenie Nickella). Z tego względu w dalszej

kolejności zastosowano estymator Arellano - Bonda, który minimalizuje wspomniane obciążenie.

9.2. Estymator uogólnionej metody momentów - Arellano, Bond(1991)

```
Twoways effects Two-steps model Difference GMM

Call:
pgmm(formula = stopa_bezrobocia ~ lag(stopa_bezrobocia, 1) +
    edukacja + inflacja + gestosc + zatrudnienie + wydatki_rzadowe |
    lag(stopa_bezrobocia, 2:3), data = panel, model = "twosteps",
    transformation = "d", index = c("kraj", "rok"))

Balanced Panel: n = 26, T = 9, N = 234

Number of Observations Used: 182
Residuals:
     Min.   1st Qu.    Median      Mean   3rd Qu.      Max.
-2.133916 -0.318613  0.045264  0.001515  0.343585  1.701072

Coefficients:
                           Estimate  Std. Error z-value Pr(>|z|)
lag(stopa_bezrobocia, 1)  0.77183520  0.07574309 10.1902   <2e-16 ***
edukacja                  0.03438252  0.07585535  0.4533   0.6504
inflacja                 -0.01643916  0.02206984 -0.7449   0.4564
gestosc                  -0.00064011  0.00405594 -0.1578   0.8746
zatrudnienie             -0.02744959  0.06725919 -0.4081   0.6832
wydatki_rzadowe           0.00107398  0.05371481  0.0200   0.9840
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Sargan test: chisq(12) = 12.79104 (p-value = 0.38441)
Autocorrelation test (1): normal = -3.188519 (p-value = 0.00143)
Autocorrelation test (2): normal = -0.5794087 (p-value = 0.56231)
Wald test for coefficients: chisq(6) = 312.4465 (p-value = < 2.22e-16)
Wald test for time dummies: chisq(7) = 43.19704 (p-value = 3.0558e-07)
```

Rysunek 9.2. Model dynamiczny GMM.

Otrzymane wyniki wskazują, że stopa bezrobocia silnie zależy od swojej przeszłej wartości. Współczynnik przy opóźnionej stopie bezrobocia jest dodatni i istotny statystycznie. Pozostałe zmienne objaśniające, takie jak poziom wykształcenia, inflacja, gęstość zaludnienia, zatrudnienie oraz wydatki rządowe, nie okazały się istotne statystycznie w krótkim okresie.

Wynik ten sugeruje, że w badanym przedziale czasowym zmiany bezrobocia były w największym stopniu kształtowane przez jego wcześniejszy poziom, a wpływ czynników strukturalnych może ujawniać się dopiero w dłuższym okresie. Zastosowane testy diagnostyczne potwierdzają poprawność oszacowania modelu. Test Sargana wskazuje, że wykorzystane instrumenty są prawidłowe i nie ma podstaw do ich odrzucenia ($p = 0,38$). Testy Arellano - Bonda pokazują występowanie autokorelacji pierwszego rzędu ($p = 0,001$), co jest typowe dla modeli dynamicznych, oraz brak autokorelacji drugiego rzędu ($p = 0,56$). Oznacza to, że specyfikacja modelu została dobrana właściwie. Test Walda potwierdza, że model jest statystycznie istotny, a istotność efektów czasowych sugeruje, że wspólne zdarzenia gospodarcze wpływały na zmiany poziomu bezrobocia we wszystkich krajach Unii Europejskiej.

10. Podsumowanie

Celem projektu była identyfikacja czynników wpływających na poziom bezrobocia w krajach Unii Europejskiej z wykorzystaniem danych panelowych oraz ocena, który typ modelu panelowego najlepiej opisuje badane zjawisko. W części empirycznej przeprowadzono wstępną analizę danych, obejmującą opis struktury próby, podstawowe statystyki zmiennych oraz analizę zależności między zmiennymi objaśniającymi a stopą bezrobocia.

Na podstawie zbudowanych modeli: regresji łącznej, modelu z efektami ustalonymi oraz modelu z efektami losowymi w wariantach jednokierunkowych oraz dwukierunkowych, przeprowadzono porównanie ich dopasowania i weryfikację statystyczną. Na podstawie przeprowadzonych testów za najlepiej opisujący analizowane zjawisko uznano model dwukierunkowy z efektami ustalonymi, który został przyjęty jako ostateczna postać modelu. Następnie dokonano selekcji zmiennych oraz weryfikacji jakości modelu przy wykorzystaniu odpowiednich testów diagnostycznych. Badanie autokorelacji składnika losowego wykazało obecność autokorelacji wielu rzędów, co uniemożliwiło prawidłowe przeprowadzenie testów heteroskedastyczności. W związku z tym zastosowano estymatory odporne, co umożliwiło interpretację uzyskanych wyników.

Ostateczny model potwierdził istotny wpływ większości analizowanych zmiennych na poziom stopy bezrobocia. Wzrost odsetka osób posiadających co najmniej wykształcenie średnie oraz wzrost poziomu zatrudnienia prowadzą do obniżenia stopy bezrobocia, natomiast wzrost indeksu inflacji oraz zwiększenie gęstości zaludnienia sprzyjają wzrostowi stopy bezrobocia. Istotność statystyczna wydatków rządowych znajdowała się na granicy przyjętego poziomu, co sugeruje brak jednoznacznego wpływu na badane zjawisko w analizowanym okresie.

Dla porównania zastosowano również model dynamiczny. W tym przypadku jedyną istotną zmienną okazała się stopa bezrobocia z poprzedniego roku, co wskazuje, że bezrobocie zmienia się stopniowo i zależy od sytuacji w poprzednich latach. Pozostałe zmienne nie były istotne w modelu dynamicznym.

Podsumowując, model dwukierunkowy z efektami ustalonymi najlepiej opisuje badane zjawisko i pozwala wyróżnić najważniejsze czynniki wpływające na stopę bezrobocia. Dodatkowo, wynik modelu dynamicznego pokazuje, że bieżący poziom bezrobocia zależy przede wszystkim od sytuacji w poprzednim roku, natomiast pozostałe zmienne nie były istotne w tej specyfikacji. Może to oznaczać, że ich wpływ na rynek pracy pojawia się dopiero po pewnym czasie, a nie w tym samym roku. Dlatego rozszerzenie modelu o opóźnione wartości pozostałych zmiennych mogłoby lepiej pokazać zależności między edukacją, inflacją, zatrudnieniem i wydatkami publicznymi a stopą bezrobocia.

Spis rysunków

Rysunek 3.1. Zmienność w czasie - wizualizacja danych panelowych. 8
Rysunek 3.2. Macierz korelacji zmiennych. 10
Rysunek 4.1. Podsumowanie wyników dla modelu regresji łącznej..... 12
Rysunek 4.2. Podsumowanie wyników dla modelu FE jednokierunkowego. 14
Rysunek 4.3. Podsumowanie wyników dla modelu FE dwukierunkowego. 15
Rysunek 4.4. Podsumowanie wyników dla modelu RE jednokierunkowego. 17
Rysunek 4.5. Podsumowanie wyników dla modelu RE dwukierunkowego. 18
Rysunek 5.1. Wyniki testu F (OLS vs FE 1K). 21
Rysunek 5.2. Wyniki testy Breuscha-Pagana (OLS vs RE 1K). 21
Rysunek 5.3. Wyniki testu F (FE 1K vs FE 2K). 22
Rysunek 5.4. Wyniki testu Hausmana (FE 1K vs RE 1K). 23
Rysunek 5.5. Wyniki testu Hausmana (FE 2K vs RE 2K). 24
Rysunek 6.1. Podsumowanie wyników dla modelu FE dwukierunkowego. 25
Rysunek 6.2. Model po usunięciu zmiennej pkb_pc. 26
Rysunek 6.3. Model po usunięciu zmiennej dzietnosc. 27
Rysunek 6.4. Model po usunięciu zmiennych pkb_pc oraz dzietnosc. 28
Rysunek 7.1. Wynik testu Wooldridge'a. 29
Rysunek 7.2. Wynik testu Pesaran CD. 31
Rysunek 7.3. Wynik testu Breush - Pagan LM. 32
Rysunek 7.4. Wyniki testu Shapiro - Wilka. 33
Rysunek 7.5. Wynik testu Jarque Bera. 34
Rysunek 7.6. Histogram reszt. 34
Rysunek 8.1. Ostateczny model. 35
Rysunek 8.2. Odporne błędy standardowe. 36
Rysunek 9.1. Model dynamiczny FE. 39
Rysunek 9.2. Model dynamiczny GMM. 40

Spis tabel

Tabela 3.1. Podstawowe statystyki opisowe badanych zmiennych..... 9
Tabela 3.2. Współczynniki VIF dla zmiennych. 11
Tabela 7.1. Wyniki testu Breuscha-Godfreya/Wooldridge'a..... 30