AKADEMIA GÓRNICZO-HUTNICZA
IM. STANISŁAWA STASZICA W KRAKOWIE
WYDZIAŁ ZARZĄDZANIA

Projekt zaliczeniowy

Uczenie maszynowe

Predykcja decyzji rekrutacyjnych z wykorzystaniem metod uczenia maszynowego

Kierunek: Informatyka i Ekonometria

Rok: I rok

Autorzy: Julia Matyja, Kinga Kołodziej

Kraków, 2026

Spis treści

1. WSTĘP ... 3

2. OPIS DANYCH ... 3

3. EKSPLORACYJNA ANALIZA DANYCH ... 5

3.1. Braki danych ... 5
3.2. Zbalansowanie zbioru ... 5
3.3. Statystyki opisowe ... 6
3.3.1. Dla zmiennych ilościowych ... 6
3.3.2. Dla zmiennych kategorycznych ... 8
3.4. Wartości odstające ... 9
3.5. Analiza wpływu poszczególnych zmiennych na zmienną prognozowaną ... 10
3.5.1. Wpływ zmiennych kategorycznych na zmienną decyzyjną ... 10
3.5.2. Wpływ zmiennych ilościowych na zmienną decyzyjną ... 11

4. PRZYGOTOWANIE DANYCH DO MODELOWANIA PREDYKCYJNEGO ... 15

4.1. Podział danych na zbiór treningowy oraz testowy ... 15
4.2. Kodowanie zmiennych kategorycznych ... 15
4.3. Walidacja krzyżowa ... 15

5. BUDOWA WYBRANYCH MODELI UCZENIA MASZYNOWEGO ... 16

5.1. Regresja logistyczna ... 16
5.2. Metoda k - najbliższych sąsiadów (kNN) ... 17
5.3. Ważona metoda k - najbliższych sąsiadów (kkNN) ... 18
5.4. Drzewo decyzyjne ... 20
5.5. Las losowy ... 22
5.6. Wzmocnienie gradientowe (XGBoost) ... 23
5.7. Maszyna wektorów nośnych (SVM) ... 25

6. WYBÓR NAJLEPSZEGO MODELU ... 27

7. ANALIZA INTERPRETOWALNOŚCI ... 28

7.1. Analiza ważności zmiennych ... 29
7.2. Profile ceteris – paribus ... 30
7.2.1. Dla zmiennych ilościowych ... 30
7.2.2. Dla zmiennych kategorycznych. ... 34
7.3. Wykresy częściowej zależności (PDP) ... 36
7.3.1. PDP dla zmiennych ilościowych ... 36
7.3.2. PDP dla zmiennych kategorycznych ... 56
7.4. Wykresy Break Down oraz wartości SHAP ... 58
7.4.1. Wykres Break Down – kompetencje ... 58
7.4.2. Wykres Break Down – podstawowe cechy ... 59
7.4.3. Wykres Break Down – odległość od miejsca pracy ... 60
7.4.4. Wykres Break Down – doświadczenie ... 61
7.4.5. Wykres Break Down – strategia rekrutacyjna ... 61
7.4.6. Wykresy Break Down – podsumowanie ... 62
7.4.7. Wartości SHAP ... 63

8. PODSUMOWANIE ... 64

SPIS RYSUNKÓW ... 65

SPIS TABEL ... 67

1. Wstęp

Celem niniejszej pracy jest zbudowanie i porównanie wybranych modeli uczenia maszynowego, w tym regresji logistycznej, metod k-najbliższych sąsiadów (kNN i kKNN), drzew decyzyjnych, lasów losowych, modelu XGBoost oraz maszyn wektorów nośnych (SVM), w zadaniu predykcji decyzji rekrutacyjnych. Na podstawie wybranych miar jakości klasyfikacji dokonano wyboru modelu charakteryzującego się najwyższą skutecznością, który następnie poddano szczegółowej analizie interpretowalności. W tym celu zastosowano metody wyjaśniania predykcji, takie jak profile częściowej zależności (PDP), profile ceteris paribus (PCP) oraz metody typu break-down, umożliwiające ocenę wpływu poszczególnych cech kandydatów na decyzje podejmowane przez model.

2. Opis danych

Wykorzystany zbiór danych zawiera informacje dotyczące procesu rekrutacyjnego oraz czynników wpływających na decyzję o zatrudnieniu kandydata. Każda obserwacja w zbiorze reprezentuje jednego kandydata i opisuje jego cechy demograficzne, wykształcenie, doświadczenie zawodowe oraz wyniki ocen stosowanych w procesie rekrutacji. Zmienna **HiringDecision** reprezentuje końcową decyzję rekrutacyjną. Przyjmuje wartość 0, jeśli kandydat nie został zatrudniony oraz wartość 1, jeśli kandydat został zatrudniony. Jest to zmienna binarna pełniąca rolę zmiennej objaśnianej w analizie i modelach predykcyjnych. Zestaw danych zawiera siedem zmiennych ilościowych: Age, ExperienceYears, PreviousCompanies, DistanceFromCompany, InterviewScore, SkillScore, PersonalityScore oraz trzy zmienne kategoryczne: Gender, EducationLevel, RecruitmentStrategy. Dane zostały pobrane ze strony Kaggle (https://www.kaggle.com/datasets/rabieelkharoua/predicting-hiring-decisions-in-recruitment-data).

Zmienne ilościowe:

- **Age** - zmienna opisuje wiek kandydata wyrażony w latach (Integer). Przyjmuje wartości z zakresu od 20 do 50 lat.

- **ExperienceYears** - zmienna określa liczbę lat doświadczenia zawodowego kandydata. Jej wartości mieszczą się w przedziale od 0 do 15 lat. Jest to zmienna ilościowa dyskretna (Integer).
- **PreviousCompanies** - zmienna informuje o liczbie firm, w których kandydat był wcześniej zatrudniony. Przyjmuje wartości od 1 do 5. Jest to zmienna ilościowa dyskretna (Integer).
- **DistanceFromCompany** - zmienna określa odległość miejsca zamieszkania kandydata od siedziby firmy, wyrażoną w kilometrach. Zakres wartości wynosi od 1 do 50 km. Jest to zmienna ilościowa ciągła (Float).
- **InterviewScore** - zmienna przedstawia wynik uzyskany przez kandydata podczas rozmowy kwalifikacyjnej. Przyjmuje wartości od 0 do 100 punktów. Jest to zmienna ilościowa dyskretna (Integer).
- **SkillScore** - zmienna opisuje ocenę umiejętności technicznych kandydata, również w skali od 0 do 100 punktów. Jest to zmienna ilościowa dyskretna (Integer).
- **PersonalityScore** - zmienna określa ocenę cech osobowości kandydata uzyskaną w trakcie procesu rekrutacyjnego. Przyjmuje wartości od 0 do 100 punktów. Jest to zmienna ilościowa dyskretna (Integer).

Zmienne kategoryczne:

- **Gender** - zmienna opisuje płeć kandydata. Przyjmuje dwie możliwe wartości: 0 oznacza mężczyznę, natomiast 1 oznacza kobietę. Jest to zmienna kategoryczna binarna.
- **EducationLevel** - zmienna opisuje najwyższy poziom wykształcenia osiągnięty przez kandydata. W pierwotnej wersji przyjmowała wartości od 1 do 4, odpowiadające kolejno dwóm typom studiów pierwszego stopnia, studiom magisterskim oraz stopniowi doktora. Jest to zmienna kategoryczna o charakterze porządkowym. Ze względu na brak jednoznacznych informacji dotyczących różnic pomiędzy kategoriami 1 (Bachelor's Type 1) oraz 2 (Bachelor's Type 2), podjęto decyzję o ich połączeniu w jedną kategorię reprezentującą studia pierwszego stopnia. Celem tego zabiegu było uproszczenie struktury zmiennej oraz zwiększenie interpretowalności wyników analizy, przy jednoczesnym zachowaniu logicznej hierarchii poziomów wykształcenia. Ostatecznie zmienna **EducationLevel** została sprowadzona do trzech

poziomów: 1 - studia pierwszego stopnia, 2 - studia magisterskie oraz 3 - stopień doktora.

- **RecruitmentStrategy** - zmienna opisująca strategię rekrutacyjną zastosowaną przez firmę wobec danego kandydata. Przyjmuje wartości od 1 do 3, odpowiadające strategii agresywnej, umiarkowanej oraz zachowawczej. Jest to zmienna kategoryczna.

3. Eksploracyjna analiza danych

3.1. Braki danych

W pierwszym etapie eksploracyjnej analizy danych przeanalizowano występowanie braków danych w zbiorze. W tym celu obliczono liczbę wartości brakujących dla każdej zmiennej. Analiza wykazała, że zbiór danych nie zawiera braków danych, czyli dla wszystkich zmiennych liczba brakujących obserwacji wynosi 0. Dotyczy to zarówno zmiennych ilościowych jak i zmiennych jakościowych.

3.2. Zbalansowanie zbioru

Tabela 1 Zbalansowanie zbioru.

Kategoria (HiringDecision)	0 - brak zatrudnienia	1 - zatrudnienie
Liczność	1035	465
Udział procentowy	69%	31%

Analiza rozkładu zmiennej **HiringDecision** wykazała niezbalansowanie klas, gdzie kategoria 0 (brak zatrudnienia) stanowiła 69% obserwacji, natomiast kategoria 1 (zatrudnienie) 31%. Ze względu na niezbalansowanie danych zastosowana została technika nadpróbkowania klasy mniejszościowej (oversampling). Technika ta polega na zwiększeniu liczebności klasy rzadkiej poprzez wielokrotne losowe powielanie istniejących obserwacji tej klasy. Wybór nadpróbkowania zamiast techniki redukcji próby (undersamplingu) podyktowany był umiarkowaną liczebnością zbioru danych, wynoszącą 1500 obserwacji. Zastosowanie undersamplingu mogłoby prowadzić do istotnej utraty informacji poprzez odrzucenie znacznej

części dostępnych danych, co mogłoby negatywnie wpłynąć na jakość i stabilność trenowanych modeli.

3.3. Statystyki opisowe

3.3.1. Dla zmiennych ilościowych

Tabela 2 Statystyki opisowe dla zmiennych ilościowych.

Zmienna	Średnia	Mediana	Min	Max	Q1	Q3	Odch. stand.	Skośność	Kurtoza	Współ. zmienn.
Age	35,15	35	20	50	27	43	9,25	-0,05	-1,27	0,26
ExperienceYears	7,69	8	0	15	4	12	4,64	-0,05	-1,2	0,6
PreviousCompanies	3	3	1	5	2	4	1,41	0,01	-1,3	0,47
DistanceFromCompany	25,51	25,5	1,03	50,99	12,84	37,74	14,57	0,03	-1,22	0,57
Interview**Score**	50,56	52	0	100	25	75	28,63	-0,06	-1,2	0,57
SkillScore	51,12	53	0	100	25,75	76	29,35	-0,07	-1,21	0,57
PersonalityScore	49,39	49	0	100	23	76	29,35	0,04	-1,23	0,59

Analiza statystyk opisowych wskazuje, że badane zmienne ilościowe charakteryzują się umiarkowanym zróżnicowaniem wartości. Dla wszystkich analizowanych zmiennych ilościowych wartości średniej i mediany są do siebie bardzo zbliżone. Świadczy to o braku wyraźnej asymetrii rozkładów oraz o ich względnej symetrii. Zmienne **InterviewScore**, **SkillScore** oraz **PersonalityScore** cechują się szerokim zakresem wartości (od 0 do 100) oraz stosunkowo wysokim odchyleniem standardowym, co wskazuje na duże zróżnicowanie ocen kandydatów. Wartości skośności bliskie zeru dla wszystkich zmiennych wskazują na rozkłady zbliżone do symetrycznych. Ujemne wartości kurtozy dla każdej zmiennej wskazują na rozkłady spłaszczone w porównaniu do rozkładu normalnego. Wartości współczynnika zmienności wskazują na niską zmienność dla zmiennej **Age** oraz umiarkowaną zmienność dla pozostałych zmiennych ilościowych, co wskazuje na różnorodność informacyjną.

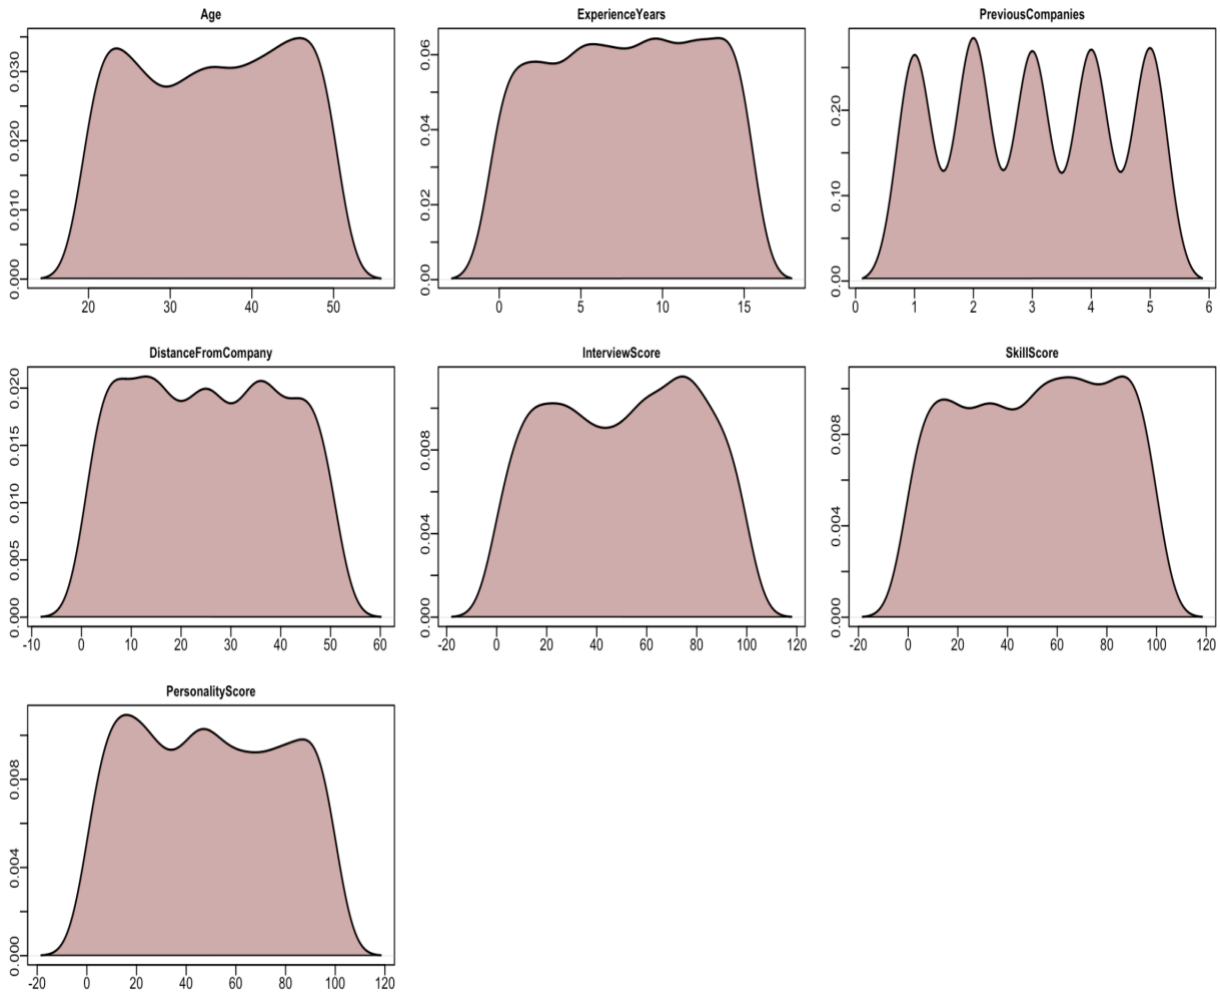

Rysunek 1 Wykresy gęstości dla zmiennych ilościowych.

Analiza wykresów gęstości potwierdza wnioski wynikające ze statystyk opisowych. Dla wszystkich zmiennych ilościowych zaobserwowano umiarkowane zróżnicowanie wartości oraz brak wyraźnej asymetrii rozkładów. Rozkłady są zbliżone do symetrycznych i nie wykazują obecności istotnych wartości odstających.

3.3.2. Dla zmiennych kategorycznych

Tabela 3 Statystyki dla zmiennych kategorycznych.

Zmienna	Kategoria	Udział procentowy
Gender	0 – mężczyzna	50,8%
	1 – kobieta	49,2%
EducationLevel	1 – studia pierwszego stopnia	70%
	2 – studia magisterskie	21%
	3 – stopień doktora	9%
RecruitmentStrategy	1 – strategia agresywna	29%
	2 – strategia umiarkowana	51%
	3 – strategia zachowawcza	19%

Analiza zmiennych kategorycznych wskazuje na zróżnicowaną strukturę w badanym zbiorze danych. W przypadku zmiennej **Gender** udział kobiet i mężczyzn jest niemal równy, co ogranicza ryzyko stronniczości modeli względem płci. Zmienna **EducationLevel** charakteryzuje się dominacją osób z wykształceniem wyższym pierwszego stopnia (70%), natomiast mniejszy udział mają osoby ze stopniem magistra (21%) oraz doktora (9%), co wskazuje na nierównomierny rozkład kategorii wykształcenia. W przypadku zmiennej **RecruitmentStrategy** najczęściej stosowana była strategia umiarkowana (51%), natomiast strategie agresywna (29%) oraz zachowawcza (19%) występowały rzadziej.

3.4. Wartości odstające

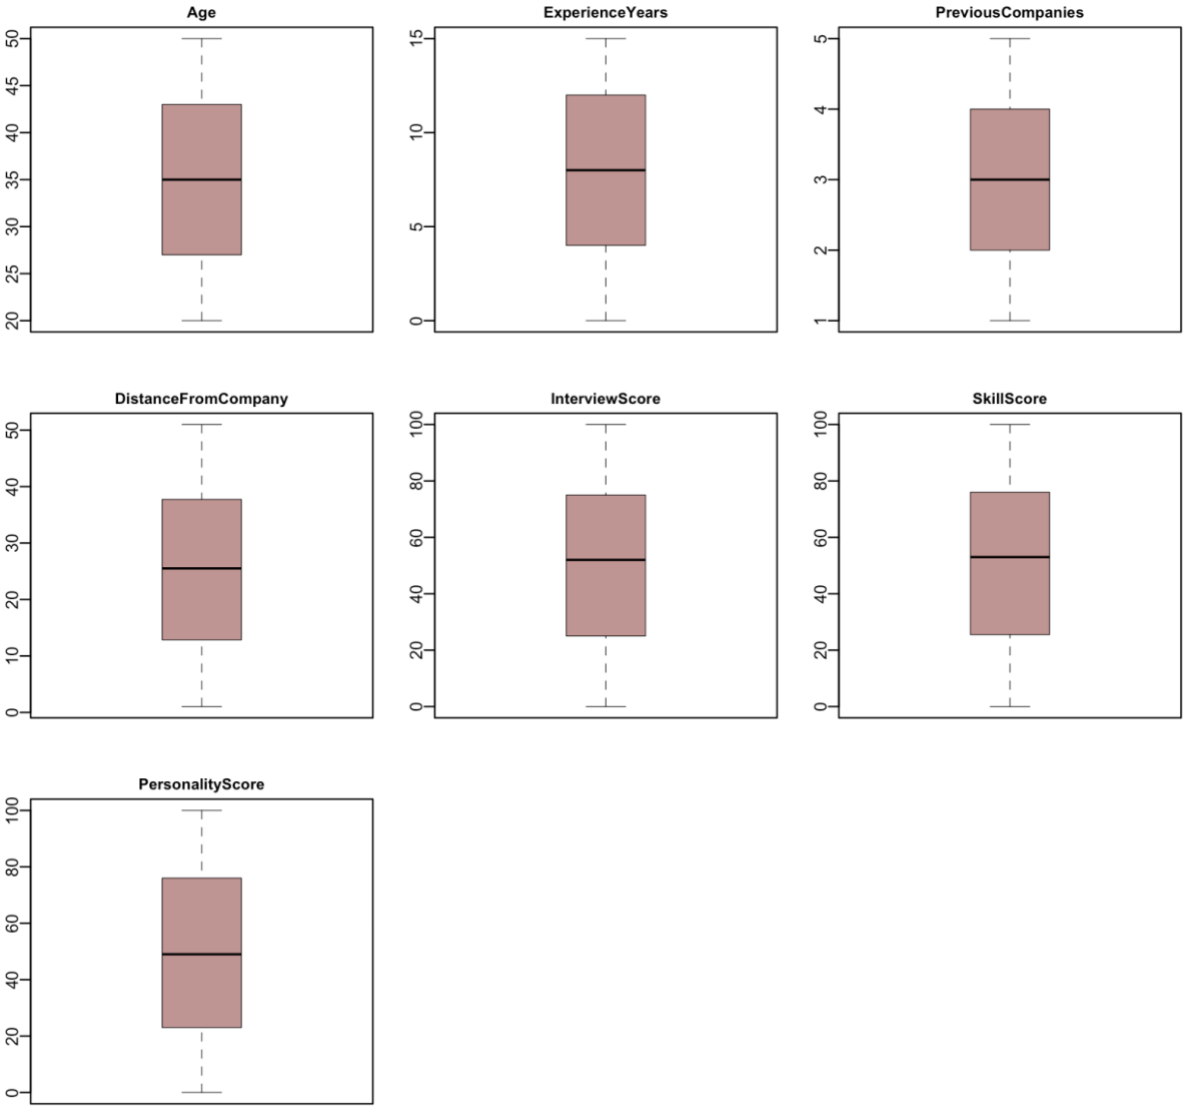

Rysunek 2 Wykresy pudełkowe dla zmiennych ilościowych.

Na podstawie analizy wykresów pudełkowych stwierdzono brak obserwacji odstających we wszystkich analizowanych zmiennych ilościowych. Rozkłady zmiennych są stabilne i nie zawierają wartości skrajnych, które mogłyby w istotny sposób wpłynąć na wyniki dalszej analizy.

3.5. Analiza wpływu poszczególnych zmiennych na zmienną prognozowaną

3.5.1. Wpływ zmiennych kategorycznych na zmienną decyzyjną

W celu stwierdzenia, czy pomiędzy dwiema zmiennymi kategorycznymi istnieje statystycznie istotna zależność wykonano **test niezależności χ^2**. Polega on na porównaniu rzeczywistego rozkładu obserwacji z rozkładem, jaki byłby oczekiwany w przypadku braku zależności między zmiennymi. Jego celem jest sprawdzenie, czy zaobserwowane różnice są wynikiem rzeczywistej zależności, czy jedynie efektem przypadku.

Test niezależności χ^2:

$\mathbf{H_0}$: Zmienne są od siebie niezależne.
$\mathbf{H_1}$: Pomiędzy zmiennymi istnieje istotna zależność.

Współczynnik V-Cramera, również pozwala ocenić siłę zależności pomiędzy zmiennymi kategorycznymi. Przyjmuje on wartości od 0 do 1, gdzie wartości bliskie 0 oznaczają brak zależności, natomiast wartości bliższe 1 wskazują na silną zależność pomiędzy analizowanymi zmiennymi.

Tabela 4 Wyniki testu niezależności chi-kwadrat oraz współczynnika V-Cramera.

Zmienna	Statystyka testowa	Wartość p	Współczynnik V Cramera
Gender	0,0010	0,9751	0,0022
EducationLevel	103,64	0,0000	0,2629
RecruitmentStrategy	489,68	0,0000	0,5713

Przeprowadzona analiza (dla przyjętego poziomu istotności $\alpha = 0{,}05$) wykazała, że płeć (**Gender**) nie ma istotnego wpływu na decyzję o zatrudnieniu. Brak podstaw do odrzucenia hipotezy zerowej o niezależności zmiennych oraz bardzo niska wartość współczynnika V-Cramera wskazują, że decyzja o zatrudnieniu jest niezależna od płci kandydata. Zmienna

określająca stopień wykształcenia (**EducationLevel**) wykazuje statystycznie istotny wpływ na decyzję o zatrudnieniu, jednak siła tej zależności jest umiarkowana. Strategia rekrutacyjna (**RecruitmentStrategy**) w istotnym stopniu wpływa na decyzję o zatrudnieniu i charakteryzuje się silną zależnością ze zmienną decyzyjną.

3.5.2. Wpływ zmiennych ilościowych na zmienną decyzyjną

W celu wstępnej oceny zależności pomiędzy zmiennymi ilościowymi, a binarną zmienną decyzyjną **HiringDecision** przeprowadzono analizę porównawczą rozkładów tych zmiennych w podziale na dwie kategorie decyzyjne. Porównanie wykresów gęstości oraz wykresów pudełkowych dla obu klas zmiennej **HiringDecision** pozwala ocenić, na ile rozkłady tych zmiennych są do siebie podobne, a tym samym określić, czy dana zmienna pomaga rozróżnić obserwacje należące do różnych klas. Zmienne, których rozkłady w dużym stopniu się pokrywają, mają niewielki wpływ na decyzję rekrutacyjną, natomiast zmienne wykazujące wyraźne różnice w rozkładach mogą mieć większe znaczenie w dalszej analizie.

Zmienna Age

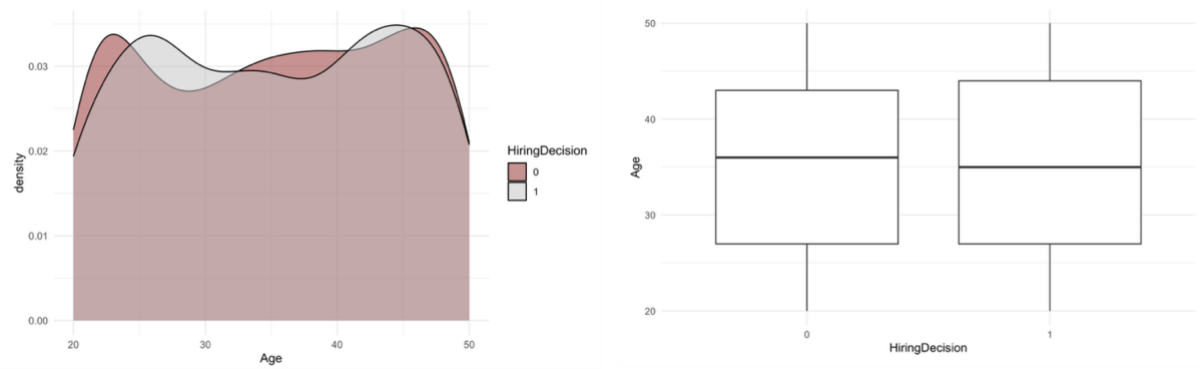

Rysunek 3 Wykres gęstości i pudełkowy zmiennej Age w zależności od decyzji o zatrudnieniu.

Na podstawie analizy rozkładów gęstości można stwierdzić, że wiek kandydata nie stanowi dominującego czynnika determinującego decyzję o zatrudnieniu. Zmienna **Age** wykazuje ograniczoną zdolność rozróżniania pomiędzy kandydatami zatrudnionymi i niezatrudnionymi, co sugeruje, że decyzje rekrutacyjne są w większym stopniu uzależnione od innych cech.

Zmienna ExperienceYears

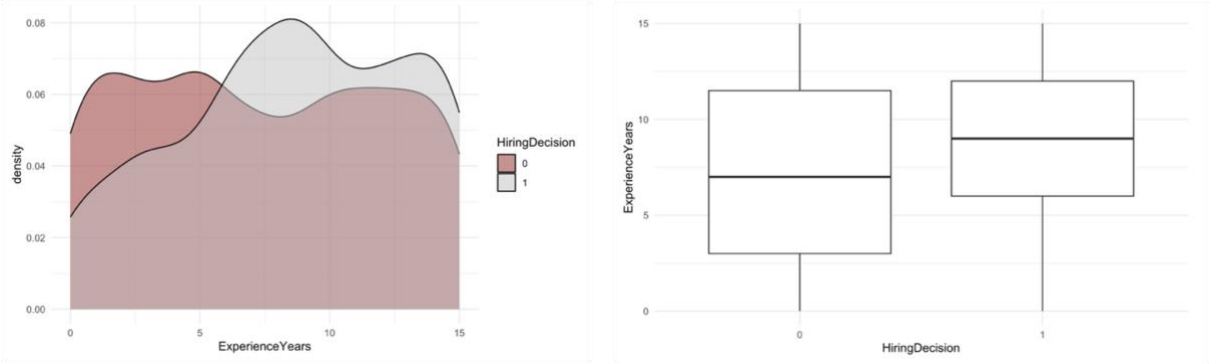

Rysunek 4 Wykres gęstości i pudełkowy zmiennej ExperienceYears w zależności od decyzji o zatrudnieniu.

Rozkłady gęstości zmiennej **ExperienceYears** różnią się pomiędzy klasami zmiennej **HiringDecision**. Kandydaci zatrudnieni (HiringDecision = 1) charakteryzują się wyraźnie większą koncentracją obserwacji w zakresie średniego i wyższego doświadczenia zawodowego, natomiast wśród kandydatów niezatrudnionych częściej występują osoby z niewielkim doświadczeniem. Wskazuje to, że liczba lat doświadczenia ma istotny wpływ na decyzję rekrutacyjną, przy czym wyższe doświadczenie zwiększa prawdopodobieństwo zatrudnienia.

Zmienna InterviewScore

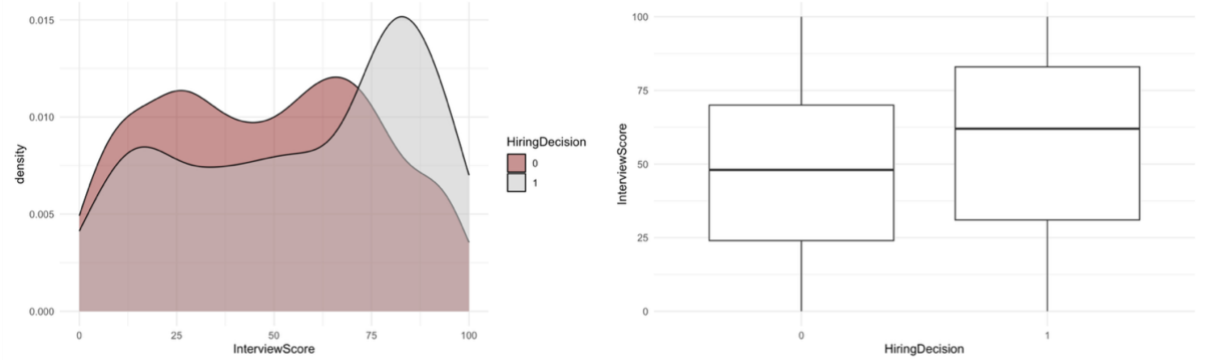

Rysunek 5 Wykres gęstości i pudełkowy zmiennej InterviewScore w zależności od decyzji o zatrudnieniu.

Rozkłady zmiennej **InterviewScore** różnią się wyraźnie w zależności od wartości zmiennej **HiringDecision**. W przypadku kandydatów zatrudnionych obserwuje się przesunięcie rozkładu w stronę wyższych ocen rozmowy kwalifikacyjnej, natomiast kandydaci niezatrudnieni częściej uzyskują niższe wyniki. Oznacza to, że **InterviewScore** w istotnym stopniu wpływa na decyzję o zatrudnieniu i skutecznie różnicuje obie klasy decyzyjne.

Zmienna SkillScore

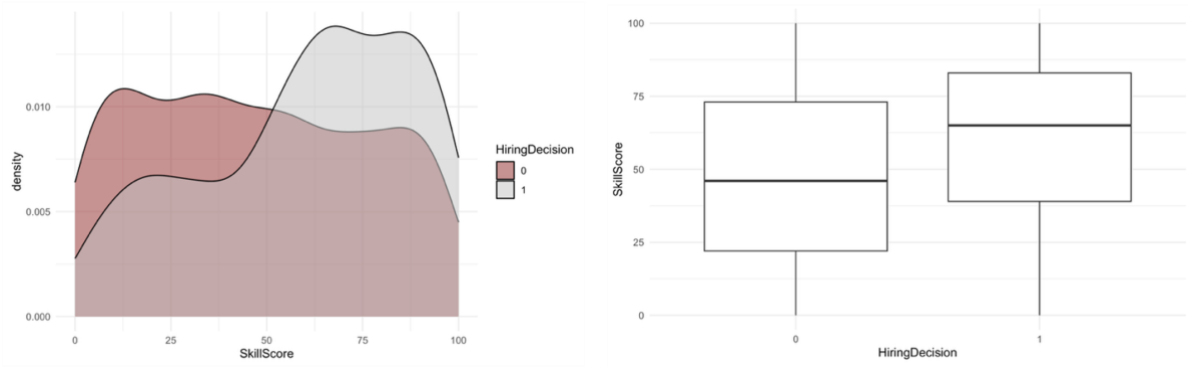

Rysunek 6 Wykres gęstości i pudełkowy zmiennej SkillScore w zależności od decyzji o zatrudnieniu.

Wartości zmiennej **SkillScore** różnicują kandydatów w zależności od decyzji rekrutacyjnej. Kandydaci, którzy zostali zatrudnieni, charakteryzują się zazwyczaj wyższymi ocenami umiejętności, podczas gdy w grupie osób niezatrudnionych częściej występują niższe poziomy tej cechy. Sugeruje to, że poziom umiejętności ma istotne znaczenie w procesie podejmowania decyzji o zatrudnieniu.

Zmienna PersonalityScore

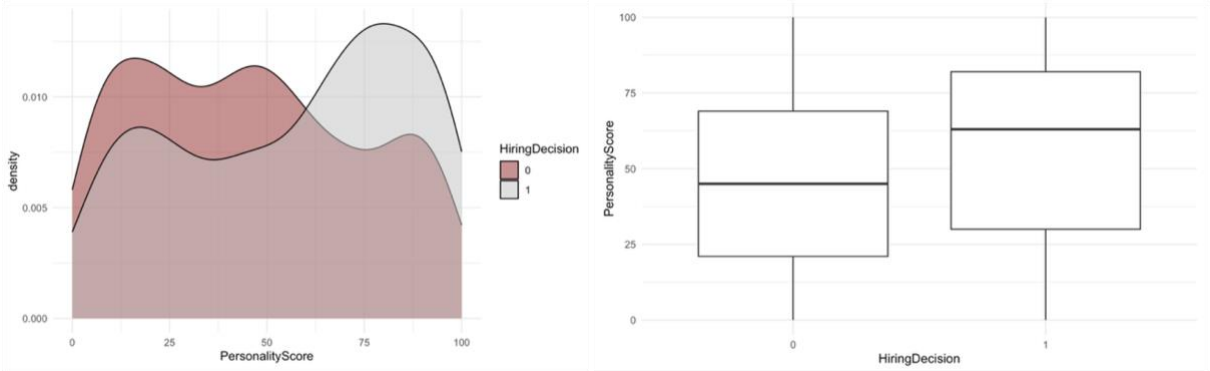

Rysunek 7 Wykres gęstości i pudełkowy zmiennej PersonalityScore w zależności od decyzji o zatrudnieniu.

Rozkłady zmiennej **PersonalityScore** różnią się pomiędzy klasami **HiringDecision**. W przypadku kandydatów zatrudnionych obserwuje się przesunięcie rozkładu w stronę wyższych ocen osobowości, natomiast w grupie kandydatów niezatrudnionych częściej pojawiają się niższe wartości tej zmiennej. Wskazuje to, że ocena cech osobowościowych ma zauważalny wpływ na decyzję rekrutacyjną.

Zmienna PreviousCompanies

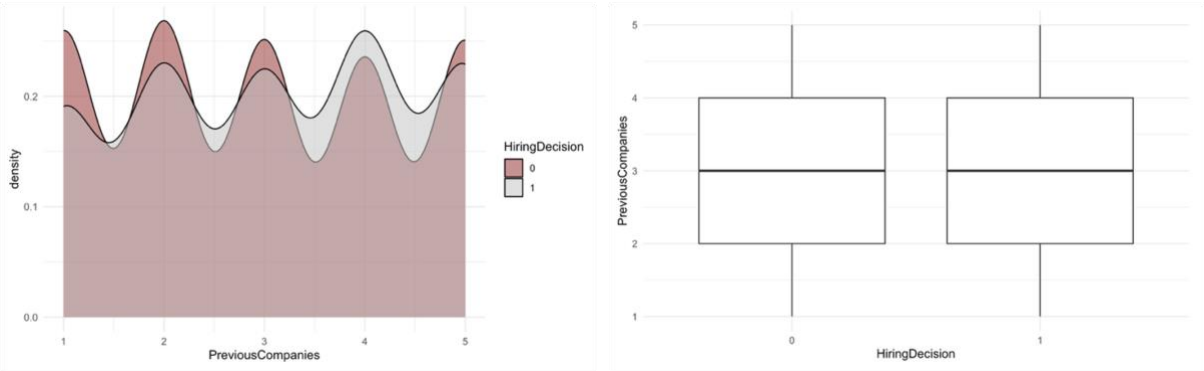

Rysunek 8 Wykres gęstości i pudełkowy zmiennej PreviousCompanies w zależności od decyzji o zatrudnieniu.

Rozkłady gęstości zmiennej **PreviousCompanies** w większości zakresu są do siebie zbliżone, jednak dla wartości 1 widoczna jest wyższa koncentracja kandydatów niezatrudnionych. Oznacza to, że osoby z doświadczeniem ograniczonym do jednego wcześniejszego miejsca pracy rzadziej otrzymują pozytywną decyzję rekrutacyjną. Dla wyższych wartości zmiennej różnice pomiędzy klasami ulegają zatarciu, co wskazuje na ograniczony wpływ tej cechy na decyzję o zatrudnieniu.

Zmienna DistanceFromCompany

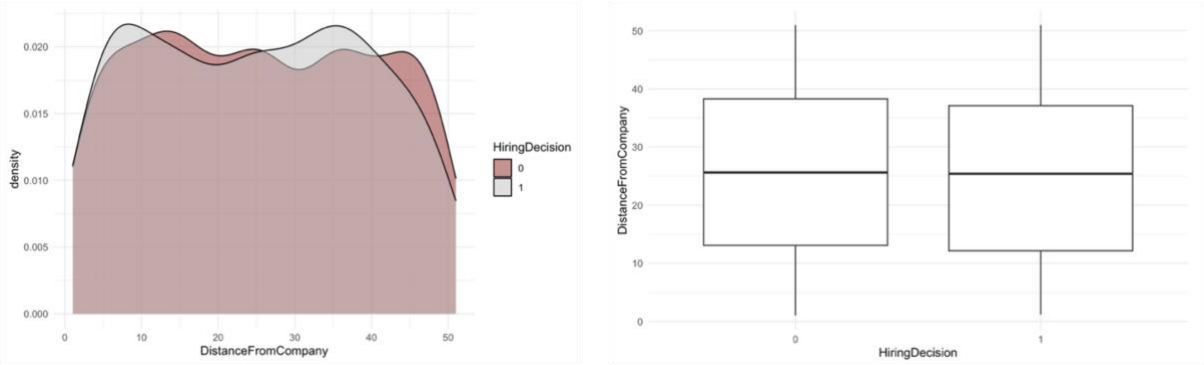

Rysunek 9 Wykres gęstości i pudełkowy zmiennej DistanceFromCompany w zależności od decyzji o zatrudnieniu.

Rozkłady gęstości zmiennej **DistanceFromCompany** dla obu klas zmiennej **HiringDecision** w dużym stopniu się pokrywają, co wskazuje na brak wyraźnej zależności pomiędzy odległością od firmy a decyzją rekrutacyjną. Choć można zauważyć niewielkie różnice w niektórych przedziałach odległości, nie mają one jednoznacznego charakteru. Sugeruje to, że **DistanceFromCompany** ma ograniczony wpływ na prawdopodobieństwo zatrudnienia i nie stanowi kluczowego czynnika decyzyjnego.

4. Przygotowanie danych do modelowania predykcyjnego

4.1. Podział danych na zbiór treningowy oraz testowy

Zbiór danych został podzielony na część uczącą i testową w proporcji 80% do 20%, przy zachowaniu proporcji klas zmiennej decyzyjnej **HiringDecision**. Dzięki temu struktura klas w obu podzbiorach jest zbliżona do struktury w całym zbiorze danych. Następnie zmienna decyzyjna została przekształcona do postaci czynnika z etykietami „No” i „Yes”, co ułatwia interpretację wyników modeli klasyfikacyjnych.

4.2. Kodowanie zmiennych kategorycznych

Po podziale danych na zbiór treningowy i testowy przeprowadzono kodowanie zmiennych kategorycznych metodą one-hot encoding. Proces kodowania został wykonany wyłącznie na zbiorze treningowym, a następnie zastosowany do zbioru testowego, co pozwoliło uniknąć przecieku informacji pomiędzy zbiorami. Zakodowane dane wykorzystano w modelach wymagających numerycznej reprezentacji cech, takich jak regresja logistyczna, k-najbliższych sąsiadów, ważonej k-najbliższych sąsiadów oraz maszyny wektorów nośnych.

4.3. Walidacja krzyżowa

W celu oceny skuteczności modeli predykcyjnych zastosowano 10-krotną walidację krzyżową, powtórzoną trzykrotnie. Metoda ta została wybrana w celu uzyskania stabilnej estymacji jakości modeli przy jednoczesnym ograniczeniu wpływu losowego podziału danych na uzyskiwane wyniki. Dodatkowo, w ramach tej procedury przeprowadzono strojenie hiperparametrów modeli, polegające na przetestowaniu różnych konfiguracji parametrów sterujących złożonością i zachowaniem algorytmów. Najlepsze ustawienia wybierano na podstawie wyników uzyskanych w walidacji krzyżowej, zgodnie z określoną miarą jakości. Ze względu na fakt, że procesie rekrutacyjnym zarówno fałszywe negatywy, jak i fałszywe pozytywy generują koszty, jako główną metrykę przyjęto **dokładność** oraz **próg decyzyjny** na poziomie **0.5**. Zatrudnienie niewłaściwego kandydata może prowadzić do strat finansowych

związanych z onboardingiem, czasem pracy zespołu oraz rotacją pracowników. Jednocześnie odrzucenie potencjalnie dobrego kandydata wiąże się z utratą kapitału ludzkiego, który mógłby przynieść organizacji długoterminową wartość. Ze względu na niezbalansowany rozkład zmiennej objaśnianej **HiringDecision**, w procesie uczenia modeli uwzględniono nadpróbkowanie klasy mniejszościowej (oversampling). Operacja ta była wykonywana wyłącznie na zbiorach treningowych w obrębie poszczególnych foldów walidacji krzyżowej. Takie podejście zapobiega przeciekowi informacji pomiędzy danymi treningowymi i walidacyjnymi.

5. Budowa wybranych modeli uczenia maszynowego

5.1. Regresja logistyczna

Jako pierwszą metodę uczenia maszynowego zastosowano regresję logistyczną, która służy do klasyfikacji binarnej i polega na modelowaniu prawdopodobieństwa wystąpienia danej klasy na podstawie zmiennych objaśniających.

Tabela 5 Wyniki estymacji modelu regresji logistycznej.

Zmienna	Szacowana wartość współczynnika	Odchylenie standardowe	Wartość p
Stała	-3,446	0,475	0
Age	0,008	0,008	0,297
Gender = 1	-0,256	0,148	0,083
EducationLevel = 2	1,692	0,181	0
EducationLevel = 3	2,119	0,257	0
ExperienceYears	0,114	0,017	0
PreviousCompanies	0,121	0,052	0,02
DistanceFromCompany	0,002	0,005	0,766

InterviewScore	0,021	0,003	0
SkillScore	0,028	0,003	0
PersonalityScore	0,02	0,003	0
RecruitmentStrategy = 2	-3,79	0,190	0
RecruitmentStrategy = 3	-3,825	0,237	0

Wyniki regresji logistycznej wskazują, że istotny wpływ na decyzję o zatrudnieniu (dla przyjętego poziomu istotności $\alpha = 0{,}05$) mają poziom wykształcenia, doświadczenie zawodowe, liczba poprzednich firm oraz wyniki ocen rekrutacyjnych (InterviewScore, SkillScore, PersonalityScore). Wyższe wykształcenie oraz lepsze wyniki ocen zwiększają prawdopodobieństwo zatrudnienia kandydata. Zmienna Age, DistanceFromCompany oraz Gender nie wykazują istotnego statystycznie wpływu na decyzję rekrutacyjną. Zastosowana strategia rekrutacyjna (umiarkowana i zachowawcza) istotnie obniża prawdopodobieństwo zatrudnienia w porównaniu do strategii agresywnej.

Tabela 6 Metryki jakości klasyfikacji - regresja logistyczna.

Metryki jakości klasyfikacji					
Zbiór treningowy			**Zbiór testowy**		
Dokładność	**Czułość**	**Specyficzność**	**Dokładność**	**Czułość**	**Specyficzność**
0,8488	0,8487	0,8490	**0,8633**	0,871	0,8599

Model osiąga wysoką dokładność klasyfikacji zarówno na zbiorze treningowym (85%), jak i testowym (86%). Pozostałe metryki, takie jak czułość i specyficzność, również przyjmują zbliżone i wysokie wartości, co potwierdza dobrą równowagę modelu w rozpoznawaniu obu klas. Zbliżone wyniki dla obu zbiorów wskazują na brak przeuczenia oraz stabilność modelu.

5.2. Metoda k - najbliższych sąsiadów (kNN)

Metoda k-najbliższych sąsiadów (k-Nearest Neighbors) polega na obliczeniu odległości pomiędzy analizowaną obserwacją a wszystkimi pozostałymi obiektami w zbiorze danych, z wykorzystaniem wybranej metryki (domyślnie odległości euklidesowej). Następnie

wybieranych jest k najbardziej podobnych obserwacji, czyli tych o najmniejszej odległości. W przypadku klasyfikacji decyzja o przypisaniu obserwacji do danej klasy podejmowana jest na podstawie głosu większości wśród wybranych sąsiadów. Kluczowym hiperparametrem tej metody jest liczba sąsiadów k. Jego wartość została dobrana heurystycznie, przyjmując pierwiastek z liczby obserwacji w zbiorze treningowym jako punkt odniesienia, a następnie przeanalizowana dla nieparzystych wartości k z przedziału od 1 do 35 w celu uniknięcia remisów i wyboru optymalnego modelu.

Tabela 7 Testowane hiperparametry - kNN.

kNN		
Hiperparametr	**Zakres testowanych wartości**	**Wartość optymalna**
k	od 1 do 35 co 2	25

Po wyznaczeniu optymalnej wartości hiperparametru k, dokonano oceny jakości klasyfikacji modelu kNN z wykorzystaniem wybranych metryk na zbiorze treningowym oraz testowym.

Tabela 8 Metryki jakości klasyfikacji - kNN.

Metryki jakości klasyfikacji					
Zbiór treningowy			**Zbiór testowy**		
Dokładność	**Czułość**	**Specyficzność**	**Dokładność**	**Czułość**	**Specyficzność**
0,83	0,83	0,83	**0,82**	0,8172	0,8213

Model kNN uzyskał dobrą jakość klasyfikacji, osiągając dokładność 82% na zbiorze testowym. Zbliżone wartości metryk dla zbioru treningowego i testowego wskazują na brak przeuczenia oraz stabilność modelu. Podobne wartości czułości i specyficzności (82%) oznaczają porównywalną skuteczność w klasyfikacji obu klas.

5.3. Ważona metoda k - najbliższych sąsiadów (kkNN)

Ważona metoda k-najbliższych sąsiadów (kkNN) jest algorytmem klasyfikacyjnym opartym na analizie podobieństwa pomiędzy obserwacjami. Dla każdej nowej obserwacji wyznaczanych

jest k najbliższych sąsiadów, natomiast ich wpływ na decyzję klasyfikacyjną jest zróżnicowany. Obserwacje położone bliżej badanego punktu otrzymują większe wagi, natomiast dalsze mają te wagi mniejsze. W modelu kkNN optymalizacji podlegały trzy hiperparametry:

- **kmax** - określa maksymalną liczbę najbliższych sąsiadów branych pod uwagę przy klasyfikacji i pełni analogiczną rolę do parametru k w klasycznej metodzie kNN.
- **distance** - określa miarę odległości wykorzystywaną do obliczania podobieństwa pomiędzy obserwacjami (np. odległość Manhattan lub euklidesowa), co bezpośrednio wpływa na sposób wyznaczania sąsiadów.
- **kernel** - definiuje funkcję jądra stosowaną do ważenia sąsiadów w zależności od ich odległości od klasyfikowanej obserwacji. Różne funkcje jądra umożliwiają odmienne sposoby nadawania wag.

Tabela 9 Testowane hiperparametry - kkNN.

kkNN		
Hiperparametr	**Zakres testowanych wartości**	**Wartość optymalna**
kmax	od 1 do 35 co 2	29
distance	1 (Manhattan), 2 (odległość euklidesowa)	1
kernel	rectangular, triangular, epanechnikov, gaussian	triangular

Po wyznaczeniu optymalnych wartości dla każdego z hiperparametrów, dokonano oceny jakości klasyfikacji modelu kkNN z wykorzystaniem wybranych metryk na zbiorze treningowym oraz testowym.

Tabela 10 Metryki jakości klasyfikacji - kkNN.

Metryki jakości klasyfikacji					
Zbiór treningowy			**Zbiór testowy**		
Dokładność	**Czułość**	**Specyficzność**	**Dokładność**	**Czułość**	**Specyficzność**
0,8112	0,7143	0,8546	**0,8333**	0,6989	0,8937

Model kkNN uzyskał dobrą jakość klasyfikacji, osiągając dokładność równą 83% na zbiorze testowym. Zbliżone wartości metryk dla zbioru treningowego i testowego wskazują na brak zjawiska przeuczenia oraz dobrą stabilność modelu. Jednocześnie zauważalna jest nierównowaga pomiędzy czułością a specyficznością. Model lepiej identyfikuje kandydatów niezatrudnionych (specyficzność = 89%), natomiast słabiej rozpoznaje kandydatów zatrudnionych (czułość = 70%).

5.4. Drzewo decyzyjne

Drzewa decyzyjne są kolejną, zastosowaną w projekcie metodą uczenia maszynowego. Model ten ma postać struktury drzewiastej, składającej się z korzenia oraz gałęzi prowadzących do kolejnych wierzchołków. Wierzchołki, z których wychodzą dalsze rozgałęzienia, nazywane są węzłami, natomiast wierzchołki końcowe określa się jako liście. W każdym węźle sprawdzany jest określony warunek dotyczący analizowanej obserwacji, a w zależności od jego spełnienia wybierana jest odpowiednia gałąź prowadząca do następnego etapu. Proces klasyfikacji polega na przejściu ścieżki od korzenia do liścia, gdzie obserwacji przypisywana jest klasa odpowiadająca danemu liściowi. W modelu drzewa decyzyjnego optymalizacji podlegał jeden hiperparametr **cp**, czyli parametr złożoności drzewa, który kontroluje stopień przycinania modelu.

Tabela 11 Testowane hiperparametry - drzewo decyzyjne.

Drzewo decyzyjne

Hiperparametr	Zakres testowanych wartości	Wartość optymalna
cp	od 0,001 do 0,05 co 0,001	0,002

Postać drzewa decyzyjnego dla uzyskanej optymalnej wartości hiperparametru cp prezentuje się następująco:

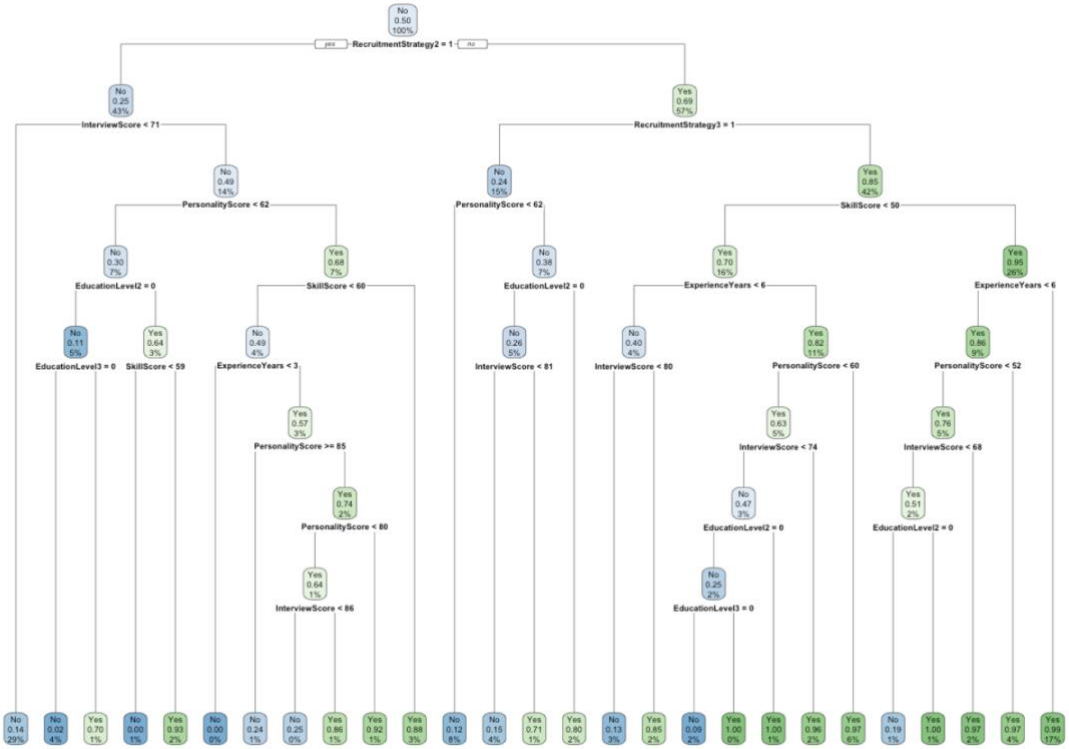

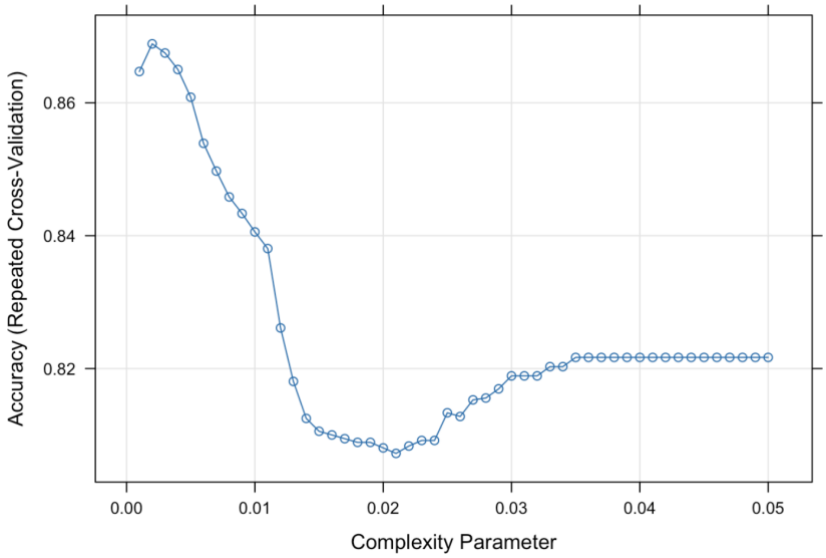

Otrzymane drzewo decyzyjne ma bardzo rozbudowaną strukturę, co wskazuje na dużą złożoność modelu przy niskich wartościach parametru cp. Analiza zależności dokładności od parametru złożoności pokazuje jednak, że dla wartości cp większych niż 0,002 następuje wyraźny spadek dokładności klasyfikacji. W racji tego, że celem analizy jest uzyskanie jak najwyższej dokładności, za optymalną przyjęto wartość cp = 0,002. Po wyznaczeniu optymalnej wartości dokonano oceny jakości klasyfikacji modelu drzewa decyzyjnego na zbiorze treningowym oraz testowym.

Tabela 12 Metryki jakości klasyfikacji – drzewo decyzyjne.

Metryki jakości klasyfikacji					
Zbiór treningowy			**Zbiór testowy**		
Dokładność	**Czułość**	**Specyficzność**	**Dokładność**	**Czułość**	**Specyficzność**
0,8689	0,795	0,9021	**0,88**	0,7849	0,9227

Model drzewa decyzyjnego osiągnął wysoką jakość klasyfikacji, uzyskując dokładność równą 88% na zbiorze testowym. Zbliżone wartości metryk dla zbioru treningowego i testowego wskazują na brak przeuczenia oraz dobrą zdolność modelu do generalizacji. Model cechuje się wysoką specyficznością (92%), co oznacza bardzo dobrą skuteczność w identyfikacji kandydatów niezatrudnionych oraz nieco niższą, lecz nadal wysoką czułością (78%).

5.5. Las losowy

Lasy losowe (Random Forest) są zespołową metodą klasyfikacji opartą na wielu drzewach decyzyjnych budowanych równolegle. Każde drzewo dokonuje niezależnej predykcji, a ostateczna decyzja klasyfikacyjna podejmowana jest na podstawie głosowania większościowego wyników uzyskanych przez wszystkie drzewa wchodzące w skład modelu. Takie podejście pozwala uzyskać bardziej stabilne predykcje niż w przypadku pojedynczego drzewa decyzyjnego. W procesie strojenia modelu optymalizacji podlegały trzy hiperparametry:

- **mtry** - liczba zmiennych losowo wybieranych do podziału w każdym węźle drzewa.
- **splitrule** - reguła podziału węzłów.
- **min.node.size** - minimalna liczba obserwacji w liściu, wpływająca na stopień wygładzenia modelu.

Dodatkowo analizowany był wpływ liczby drzew w lesie, testując modele z 100, 200 oraz 500 drzewami. Po porównaniu wyników dla różnych liczby drzew stwierdzono, że zwiększanie liczby drzew powyżej 100 nie prowadziło do istotnej poprawy metryk jakości klasyfikacji. W związku z tym jako model końcowy wybrano wariant z 100 drzewami.

Tabela 13 Testowane hiperparametry - las losowy.

Las losowy		
Hiperparametr	**Zakres testowanych wartości**	**Wartość optymalna**
mtry	od 1 do 10	1
splitrule	gini, extratrees	gini
min.node.size	1, 5, 10, 20	20

Po wyznaczeniu optymalnych hiperparametrów przeprowadzono ocenę jakości klasyfikacji modelu lasu losowego z wykorzystaniem standardowych metryk na zbiorze treningowym i testowym.

Tabela 14 Metryki jakości klasyfikacji - las losowy.

Metryki jakości klasyfikacji					
Zbiór treningowy			**Zbiór testowy**		
Dokładność	**Czułość**	**Specyficzność**	**Dokładność**	**Czułość**	**Specyficzność**
0,9	0,8344	0,93	**0,9**	0,8602	0,9179

Model lasu losowego osiągnął bardzo dobrą jakość klasyfikacji, uzyskując dokładność równą 90% zarówno na zbiorze treningowym, jak i testowym. Zbliżone wartości metryk wskazują na brak zjawiska przeuczenia oraz wysoką stabilność modelu. Wysoka specyficzność (92%) oznacza skuteczną identyfikację kandydatów niezatrudnionych, a wysoka czułość (86%) wskazuje na równie dobrą skuteczność w rozpoznawaniu kandydatów zatrudnionych.

5.6. Wzmocnienie gradientowe (XGBoost)

XGBoost (Extreme Gradient Boosting) jest zaawansowanym algorytmem uczenia maszynowego opartym na zespołach drzew decyzyjnych, który wykorzystuje ideę wzmacniania gradientowego. Metoda ta polega na sekwencyjnym budowaniu kolejnych drzew, z których każde koncentruje się na poprawie błędów popełnionych przez poprzednie modele.

Hiperparametry:

- **nrounds** - liczba iteracji, określająca, ile drzew decyzyjnych zostaje zbudowanych w modelu.
- **max_depth** - maksymalna głębokość pojedynczego drzewa decyzyjnego.
- **eta -** tempo uczenia (learning rate), które kontroluje, w jakim stopniu kolejne drzewa korygują błędy poprzednich modeli.
- **gamma** - minimalna redukcja funkcji straty wymagana do wykonania podziału w drzewie.
- **colsample_bytree** - odsetek zmiennych losowo wybieranych do budowy każdego drzewa.
- **min_child_weight** - minimalna suma wag obserwacji w węźle potomnym.
- **subsample** - odsetek obserwacji losowo wybieranych do budowy kolejnych drzew.

Tabela 15 Testowane hiperparametry - XGBoost.

XGBoost

Hiperparametr	Zakres testowanych wartości	Wartość optymalna
nrounds	100, 200, 300	300
max_depth	3, 5, 7	5
eta	0,03; 0,05; 0,1	0,05
gamma	0, 1	0
colsample_bytree	0,8; 1	0,8
min_child_weight	1, 5	1
subsample	0,8; 1	1

Metryki jakości klasyfikacji uzyskane dla modelu z optymalnie dobranymi parametrami prezentują się następująco:

Tabela 16 Metryki jakości klasyfikacji - XGBoost.

Metryki jakości klasyfikacji					
Zbiór treningowy			**Zbiór testowy**		
Dokładność	**Czułość**	**Specyficzność**	**Dokładność**	**Czułość**	**Specyficzność**
0,9194	0,8397	0,9553	**0,91**	0,8172	0,9517

Uzyskane wartości metryk jakości klasyfikacji wskazują, że model charakteryzuje się bardzo dobrą skutecznością predykcji. Dokładność na poziomie 91% na zbiorze testowym świadczy o wysokiej ogólnej poprawności klasyfikacji decyzji o zatrudnieniu. Zbliżone wartości metryk dla zbioru treningowego i testowego sugerują brak przeuczenia modelu. Wysoka specyficzność (95%) oznacza, że model dobrze identyfikuje kandydatów, którzy nie powinni zostać zatrudnieni, natomiast nieco niższa, lecz wciąż wysoka czułość (82%) wskazuje na dobrą skuteczność w rozpoznawaniu kandydatów kwalifikujących się do zatrudnienia.

5.7. Maszyna wektorów nośnych (SVM)

Maszyna wektorów nośnych (SVM) jest metodą klasyfikacji polegającą na wyznaczeniu optymalnej granicy decyzyjnej oddzielającej klasy. W modelach SVM zastosowano różne rodzaje jąder, dla których optymalizowane były odpowiednie hiperparametry wpływające na sposób dopasowania modelu do danych.

W przypadku **jądra liniowego (linear)** kluczowym hiperparametrem jest cost (C), który kontroluje kompromis pomiędzy szerokością marginesu a liczbą błędów klasyfikacji. Niskie wartości parametru cost powodują większą tolerancję na błędy i sprzyjają lepszej generalizacji modelu, natomiast wysokie wartości prowadzą do silniejszego dopasowania do danych treningowych, co może zwiększać ryzyko przeuczenia.

Tabela 17 Testowane hiperparametry - SVM (jądro liniowe)

Jądro liniowe		
Hiperparametr	**Zakres testowanych wartości**	**Wartość optymalna**
Cost	0,01; 0,05; 0,1; 0,5; 1; 5; 10	0,1

Dla **jądra radialnego** optymalizacji podlegały dwa hiperparametry: sigma oraz cost. Parametr sigma określa zasięg wpływu pojedynczych obserwacji na kształt granicy decyzyjnej - mniejsze wartości prowadzą do bardziej złożonego, lokalnego dopasowania, natomiast większe wartości skutkują gładszą i bardziej ogólną granicą decyzyjną. Parametr cost pełni analogiczną rolę jak w jądrze liniowym, regulując poziom dopasowania modelu.

Tabela 18 Testowane hiperparametry - SVM (jądro radialne).

Jądro radialne

Hiperparametr	Zakres testowanych wartości	Wartość optymalna
Sigma	0,001; 0,01; 0,1	0,1
Cost	0,01; 0,05; 0,1; 0,5; 1; 5; 10	1

W przypadku **jądra wielomianowego (polynomial)** optymalizowane były hiperparametry degree, scale oraz cost. Parametr degree określa stopień wielomianu i wpływa na złożoność granicy decyzyjnej, natomiast scale reguluje wrażliwość modelu na zmiany w danych. Parametr cost, podobnie jak w pozostałych przypadkach, kontroluje kompromis pomiędzy dokładnością dopasowania a zdolnością modelu do uogólniania wyników.

Tabela 19 Testowane hiperparametry - SVM (jądro wielomianowe).

Jądro wielomianowe

Hiperparametr	Zakres testowanych wartości	Wartość optymalna
Degree	2, 3, 4	2
Scale	0,001; 0,1	0,1
Cost	0,01; 0,05; 0,1; 0,5; 1; 5; 10	5

Wybór optymalnego jądra został dokonany na podstawie porównania metryk jakości klasyfikacji uzyskanych dla poszczególnych modeli SVM.

Tabela 20 Metryki jakości klasyfikacji - SVM.

	Metryki jakości klasyfikacji					
	Zbiór treningowy			Zbiór testowy		
	Dokładność	**Czułość**	**Specyficzność**	**Dokładność**	**Czułość**	**Specyficzność**
Jądro liniowe	**0,8544**	0,8505	0,8562	**0,8567**	0,8602	0,8551
Jądro radialne	**0,8644**	0,804	0,8917	**0,88**	0,8065	0,9130
Jądro wielomianowe	**0,8717**	0,82	0,8949	**0,88**	0,7957	0,9179

Na podstawie porównania metryk jakości klasyfikacji stwierdzono, że najlepsze wartości dokładności (główne kryterium oceny jakości modelu) na zbiorze testowym uzyskano dla modeli SVM z jądrem radialnym oraz wielomianowym. Spośród tych dwóch modeli jądro wielomianowe charakteryzuje się najwyższą specyficznością zarówno na zbiorze treningowym, jak i testowym. W związku z tym jądro wielomianowe zostało wybrane jako optymalne i wykorzystane w dalszej analizie. Zbliżone wartości metryk uzyskane na zbiorze treningowym i testowym wskazują na brak zjawiska przeuczenia.

Model SVM z jądrem wielomianowym osiąga wysoką dokładność klasyfikacji zarówno na zbiorze treningowym, jak i testowym (88%). Zbliżone wartości metryk na obu zbiorach wskazują na brak przeuczenia modelu. Czułość modelu jest umiarkowanie wysoka (80%), co oznacza, że model poprawnie identyfikuje większość kandydatów, którzy powinni zostać zatrudnieni, choć część pozytywnych przypadków może zostać pominięta. Jednocześnie wysoka specyficzność (92%) wskazuje na bardzo dobrą skuteczność w rozpoznawaniu kandydatów, którzy nie powinni zostać zatrudnieni.

6. Wybór najlepszego modelu

W celu wyboru najlepszego modelu przeprowadzono porównanie jakości klasyfikacji uzyskanej za pomocą różnych metod uczenia maszynowego. Analiza obejmowała ocenę podstawowych metryk jakości, takich jak dokładność, czułość oraz specyficzność, obliczonych zarówno dla zbioru treningowego, jak i testowego.

Tabela 21 Zestawienie metryk jakości klasyfikacji.

	Metryki jakości klasyfikacji					
	Zbiór treningowy			**Zbiór testowy**		
	Dokładność	**Czułość**	**Specyficzność**	**Dokładność**	**Czułość**	**Specyficzność**
Regresja logistyczna	0,8488	0,8487	0,8490	0,8633	0,8710	0,8599
KNN	0,83	0,83	0,8301	0,82	0,8172	0,8213
KKNN	0,8112	0,7143	0,8546	0,8333	0,6989	0,8937
Drzewo decyzyjne	0,8689	0,795	0,9021	0,88	0,7849	0,9227
Lasy losowe	0,8998	0,7771	0,9549	0,9033	0,7849	0,9565
XGBoost	**0,9194**	**0,8397**	**0,9553**	**0,91**	**0,8172**	**0,9517**
SVM	0,8717	0,82	0,8949	0,88	0,7957	0,9179

Na podstawie porównania uzyskanych metryk jakości klasyfikacji stwierdzono, że najlepsze wyniki osiągnął model XGBoost. Model ten uzyskał najwyższą dokładność zarówno na zbiorze treningowym (92%), jak i na zbiorze testowym (91%). Model ten ma jednocześnie wysokie wartości czułości (82%) oraz specyficzności (95%), co świadczy o jego dobrej zdolności do poprawnej klasyfikacji obu klas. W analizowanym zadaniu dokładność stanowiła kluczowe kryterium oceny jakości modelu, ponieważ istotne było ogólne poprawne przewidywanie decyzji rekrutacyjnych. Dodatkowo, zbliżone wartości metryk na zbiorze treningowym i testowym wskazują na brak zjawiska przeuczenia oraz dobrą zdolność generalizacji modelu.

7. Analiza interpretowalności

Na podstawie przeprowadzonego porównania jakości predykcyjnej różnych modeli uczenia maszynowego jako najlepszy wybrany został model XGBoost. W związku z tym dalsza część pracy poświęcona jest analizie jego działania oraz interpretacji podejmowanych przez niego decyzji. Celem analizy jest lepsze zrozumienie, które cechy kandydatów mają największy

wpływ na decyzję rekrutacyjną oraz w jaki sposób model XGBoost wykorzystuje dostępne informacje przy podejmowaniu predykcji zmiennej HiringDecision. W tym celu zastosowano wybrane metody interpretowalności, pozwalające zarówno na ocenę ogólnego znaczenia zmiennych, jak i na analizę ich wpływu w odniesieniu do pojedynczych obserwacji.

7.1. Analiza ważności zmiennych

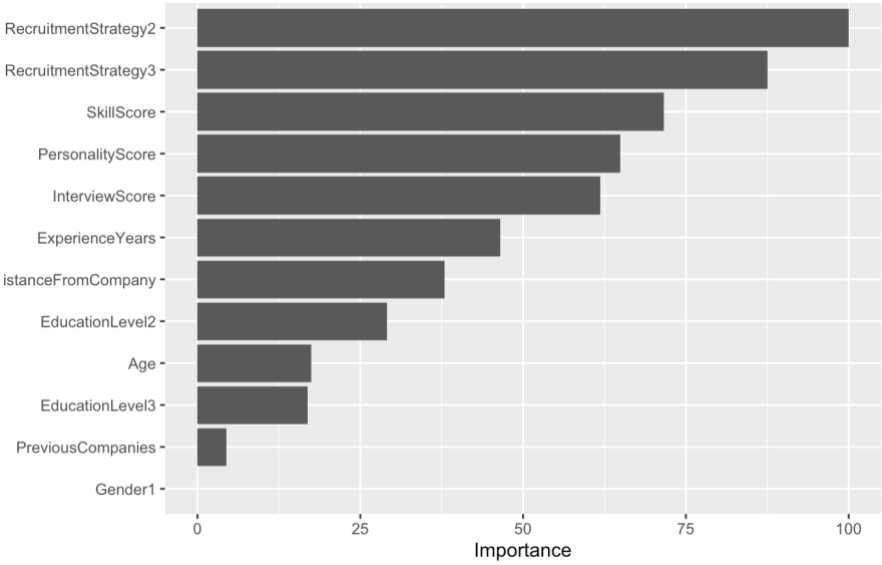

Rysunek 10 Analiza ważności zmiennych.

Wykres VIP przedstawia względną ważność zmiennych w modelu XGBoost, obliczoną na podstawie ich wkładu w proces budowy drzew decyzyjnych. Im wyższa wartość ważności, tym większy wpływ danej zmiennej na końcową predykcję decyzji **HiringDecision**. Największą ważnością charakteryzuje się zmienna związana ze strategią rekrutacji (zakodowane zmienne **RecruitmentStrategy2** oraz **RecruitmentStrategy3**), co wskazuje, że sposób pozyskania kandydata ma istotny wpływ na decyzję podejmowaną przez model. Wysokie znaczenie wykazują również zmienne opisujące kompetencje i ocenę kandydatów, czyli zmienne **SkillScore**, **PersonalityScore** oraz **InterviewScore**, co potwierdza ich kluczową rolę w procesie rekrutacyjnym. Umiarkowaną ważność posiadają lata doświadczenia zawodowego (**ExperienceYears**) oraz odległość od firmy (**DistanceFromCompany**), które pełnią rolę zmiennych wspierających decyzję, lecz nie dominujących. Z kolei wiek (**Age**), liczba firm, w których kandydat uprzednio pracował (**PreviousCompanies**) oraz poziom wykształcenia (zakodowane zmienne **EducationLevel2** i **EducationLevel3**) cechują się relatywnie niską ważnością, co sugeruje ich ograniczony wpływ na predykcję w modelu XGBoost. Zmienna **Gender** ma znikome znaczenie w modelu. Jej ważność jest

praktycznie równa zeru, co wskazuje, że zmiana wartości tej zmiennej nie wpływa w istotny sposób ani na poziom predykcji, ani na ostateczny wynik klasyfikacji.

7.2. Profile ceteris – paribus

7.2.1. Dla zmiennych ilościowych

W dalszej kolejności zastosowano profile ceteris paribus. Metoda ta pozwala na ocenę wpływu pojedynczej cechy na wynik predykcji przy założeniu, że wszystkie pozostałe zmienne pozostają niezmienione. Profile ceteris paribus umożliwiają lokalną interpretację modelu, odnoszącą się do konkretnej obserwacji, dzięki czemu pozwalają zrozumieć, jak zmiana wartości wybranej zmiennej wpływa na przewidywane prawdopodobieństwo pozytywnej decyzji rekrutacyjnej (HiringDecision).

Wybraną obserwacją jest kandydat w wieku 29 lat, płci męskiej, posiadający ukończone studia pierwszego stopnia. Kandydat ten ma 8 lat doświadczenia zawodowego, pracował wcześniej w 3 firmach i mieszka w odległości około 28 km od siedziby firmy. W procesie rekrutacyjnym uzyskał 86 punktów z rozmowy kwalifikacyjnej, 94 punkty z oceny umiejętności oraz 21 punktów z oceny cech osobowości. Kandydat brał udział w rekrutacji prowadzonej zgodnie ze strategią agresywną oraz uzyskał pozytywną decyzję o zatrudnieniu.

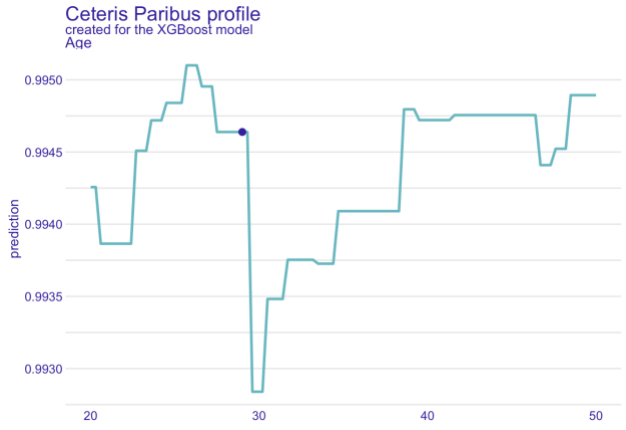

Rysunek 11 Profil ceteris-paribus dla zmiennej Age.

Profil ceteris-paribus wskazuje, że zmiana wieku kandydata w analizowanym zakresie prowadzi jedynie do niewielkich wahań przewidywanego prawdopodobieństwa zatrudnienia, jednak w żadnym z rozpatrywanych wariantów nie dochodzi do zmiany decyzji modelu. Niezależnie od wieku, model XGBoost konsekwentnie klasyfikuje analizowaną obserwację

jako przypadek pozytywny (HiringDecision = 1). Oznacza to, że zmienna **Age** nie ma istotnego wpływu na decyzję rekrutacyjną w odniesieniu do tej konkretnej obserwacji, a ostateczna predykcja jest w głównej mierze determinowana przez inne cechy kandydata.

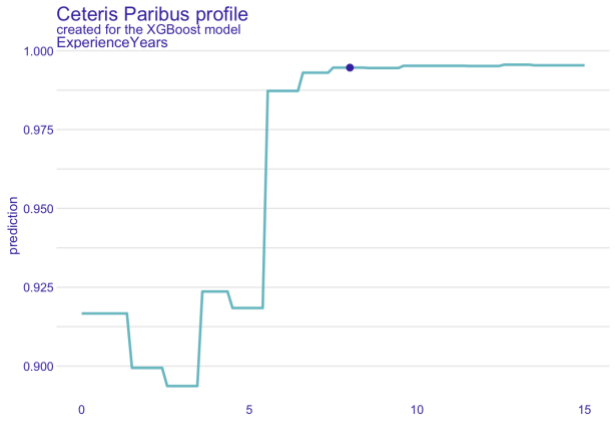

Rysunek 12 Profil ceteris-paribus dla zmiennej ExperienceYears.

Profil ceteris-paribus wskazuje, że liczba lat doświadczenia zawodowego wpływa na przewidywane prawdopodobieństwo zatrudnienia, jednak zmiany te zachodzą w wąskim przedziale wartości predykcji (około 0,85–1). Dla analizowanej obserwacji, niezależnie od poziomu doświadczenia, model XGBoost we wszystkich rozpatrywanych wariantach przewiduje decyzję pozytywną. Można jednak zaobserwować, że przy niskich wartościach zmiennej **ExperienceYears** prawdopodobieństwo zatrudnienia jest relatywnie niższe, natomiast po przekroczeniu około 5–6 lat doświadczenia następuje jego wyraźny wzrost, po którym predykcja stabilizuje się na poziomie bliskim 1.

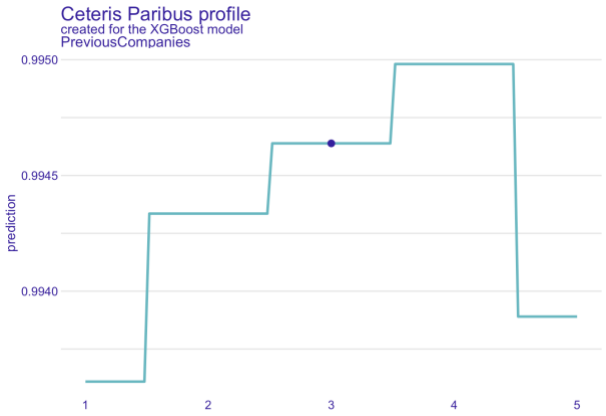

Rysunek 13 Profil ceteris-paribus dla zmiennej PreviousCompanies.

Profil ceteris-paribus wskazuje, że liczba wcześniejszych miejsc pracy (**PreviousCompanies**) wpływa na wartość przewidywanego prawdopodobieństwa zatrudnienia dla analizowanej

obserwacji, jednak zmiany te zachodzą w bardzo wąskim zakresie (około 0,993–0,995). Oznacza to, że niezależnie od liczby poprzednich firm decyzja modelu XGBoost pozostaje niezmienna i pozytywna (HiringDecision = 1). Zaobserwowane niewielkie, skokowe zmiany predykcji wskazują, że zmienna **PreviousCompanies** pełni w tym przypadku rolę drugorzędną wobec innych cech kandydata.

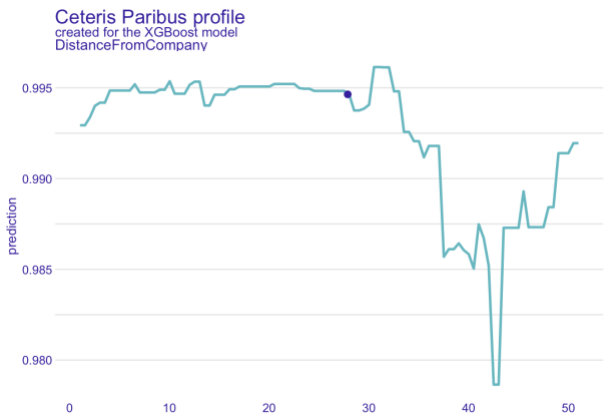

Rysunek 14 Profil ceteris-paribus dla zmiennej DistanceFromCompany.

Profil ceteris-paribus wskazuje, że zmiany odległości kandydata od firmy (**DistanceFromCompany**), przy pozostałych cechach utrzymanych na stałym poziomie, prowadzą do lokalnych wahań przewidywanego prawdopodobieństwa zatrudnienia. Zmiany te zachodzą jednak w bardzo wąskim zakresie wartości predykcji (około 0,978–0,998). Oznacza to, że mimo widocznych lokalnych spadków i wzrostów prawdopodobieństwa, decyzja modelu XGBoost dla tej konkretnej obserwacji pozostaje niezmienna i pozytywna (HiringDecision = 1).

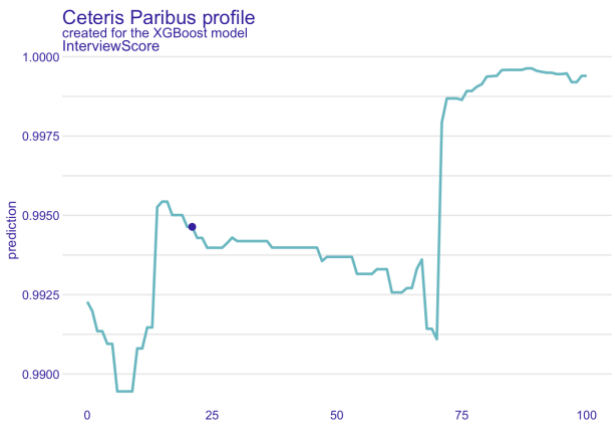

Rysunek 15 Profil ceteris-paribus dla zmiennej InterviewScore.

Profil ceteris-paribus wskazuje, że wynik rozmowy kwalifikacyjnej (**InterviewScore**), przy pozostałych cechach utrzymanych na stałym poziomie, wpływa na przewidywane prawdopodobieństwo zatrudnienia w modelu XGBoost. Zmiany te zachodzą jednak w bardzo wąskim zakresie wartości predykcji (około 0,99–1,00). Oznacza to, że niezależnie od analizowanej wartości **InterviewScore** decyzja modelu dla tej konkretnej obserwacji pozostaje pozytywna (HiringDecision = 1). Można zauważyć, że dla wyższych wyników rozmowy kwalifikacyjnej (powyżej 70 punktów) następuje wzrost przewidywanego prawdopodobieństwa zatrudnienia, po którym predykcja stabilizuje się blisko 1.

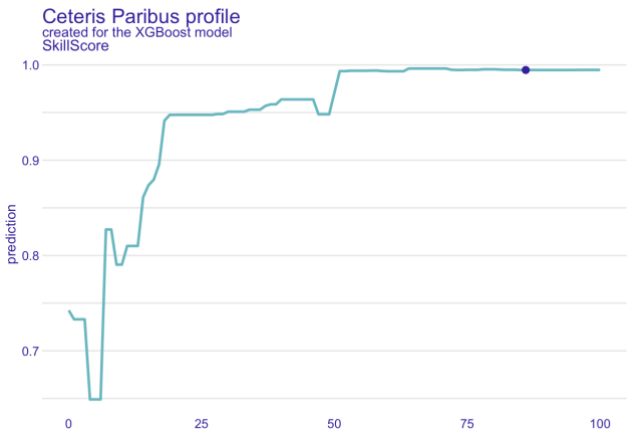

Rysunek 16 Profil ceteris-paribus dla zmiennej SkillScore.

Profil ceteris-paribus wskazuje, że zmienna **SkillScore** ma najbardziej wyraźny wpływ na predykcję modelu XGBoost spośród analizowanych cech. W przeciwieństwie do wcześniej omawianych profili, zmiany przewidywanego prawdopodobieństwa zachodzą w szerokim zakresie wartości (od około 0,65 do blisko 1), co świadczy o istotnym znaczeniu poziomu umiejętności w procesie decyzyjnym modelu. Dla niskich wartości SkillScore przewidywane prawdopodobieństwo zatrudnienia jest wyraźnie niższe, natomiast wraz ze wzrostem oceny umiejętności obserwowany jest gwałtowny wzrost predykcji. Po przekroczeniu około 45–50 punktów następuje stabilizacja przewidywanego prawdopodobieństwa na bardzo wysokim poziomie, bliskim 1. Należy jednak podkreślić, że dla analizowanej obserwacji model XGBoost we wszystkich wariantach zmiennej SkillScore przewiduje decyzję pozytywną (HiringDecision = 1). Zmiany tej cechy wpływają zatem na poziom pewności predykcji, lecz nie prowadzą do zmiany wyniku klasyfikacji.

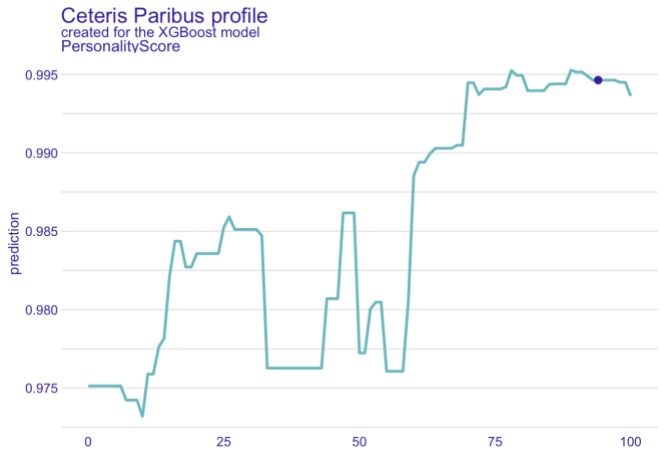

Rysunek 17 Profil ceteris-paribus dla zmiennej PersonalityScore.

Profil ceteris paribus wskazuje, że zmiana wartości **PersonalityScore** wpływa na poziom przewidywanego prawdopodobieństwa zatrudnienia, jednak efekt ten jest umiarkowany i zachodzi w wąskim zakresie skali predykcji (około 0,975 - 0,995). Wraz ze wzrostem oceny cech osobowościowych obserwowany jest stopniowy wzrost pewności predykcji, co sugeruje, że wyższy poziom **PersonalityScore** jest przez model XGBoost oceniany pozytywnie. Jednocześnie, dla analizowanej obserwacji, niezależnie od przyjętej wartości zmiennej PersonalityScore, decyzja modelu pozostaje niezmienna i wskazuje na zatrudnienie (HiringDecision = 1). Oznacza to, że zmienna **PersonalityScore** wpływa na poziom pewności predykcji modelu, lecz nie jest czynnikiem decydującym o zmianie klasyfikacji w przypadku tej konkretnej obserwacji.

7.2.2. Dla zmiennych kategorycznych.

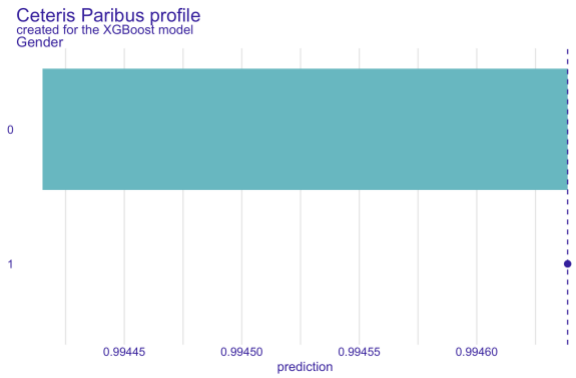

Rysunek 18 Profil ceteris-paribus dla zmiennej Gender.

Profil ceteris-paribus dla zmiennej **Gender** pokazuje, że zmiana płci kandydata praktycznie nie wpływa na przewidywane prawdopodobieństwo zatrudnienia dla analizowanej obserwacji.

Dla obu możliwych wartości zmiennej (0 i 1) predykcja modelu XGBoost pozostaje na niemal identycznym poziomie, a różnice występują dopiero na odległym miejscu po przecinku. Oznacza to, że w kontekście tej konkretnej obserwacji płeć nie ma istotnego znaczenia decyzyjnego. Niezależnie od wartości zmiennej **Gender**, decyzja modelu pozostaje pozytywna (HiringDecision = 1), a ostateczna predykcja jest determinowana przez inne cechy kandydata.

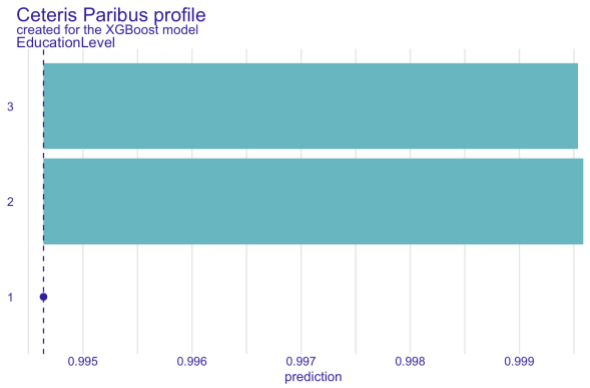

Rysunek 19 Profil ceteris-paribus dla zmiennej EducationLevel.

Profil ceteris-paribus dla zmiennej **EducationLevel** wskazuje, że zmiana poziomu wykształcenia kandydata powoduje jedynie minimalne różnice w przewidywanym prawdopodobieństwie zatrudnienia, widoczne dopiero na trzecim miejscu po przecinku. Oznacza to, że z praktycznego punktu widzenia wpływ tej zmiennej na decyzję modelu w odniesieniu do analizowanej obserwacji jest nieistotny. Niezależnie od wartości zmiennej **EducationLevel**, decyzja modelu pozostaje pozytywna (HiringDecision = 1), a ostateczna predykcja jest determinowana przez inne cechy kandydata.

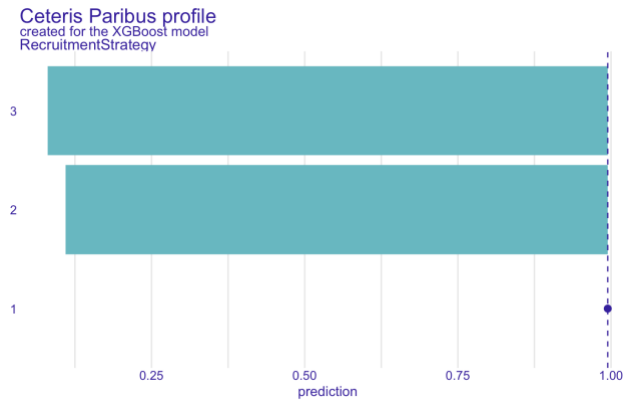

Rysunek 20 Profil ceteris-paribus dla zmiennej RecruitmentStrategy.

Profil ceteris-paribus dla zmiennej **RecruitmentStrategy** wskazuje, że jest to cecha o kluczowym znaczeniu decyzyjnym w tym przypadku. W analizowanej obserwacji strategia rekrutacji o wartości 1 (agresywna) skutkuje bardzo wysokim przewidywanym prawdopodobieństwem zatrudnienia, bliskim 100%. Natomiast zmiana strategii na 2 (umiarkowana) lub 3 (zachowawcza) prowadzi do gwałtownego spadku przewidywanego prawdopodobieństwa, do poziomu poniżej 0,25. Oznacza to, że zmiana strategii rekrutacji z 1 na 2 lub 3 skutkowałaby spadkiem prawdopodobieństwa zatrudnienia o ponad 70 punktów procentowych. Przy ustalonym progu decyzyjnym równym 0,5 zmienna **RecruitmentStrategy** bezpośrednio decyduje o zmianie klasy predykcji dla tej konkretnej obserwacji.

7.3. Wykresy częściowej zależności (PDP)

7.3.1. PDP dla zmiennych ilościowych

7.3.1.1. Interpretacja profilu PDP dla zmiennej Age

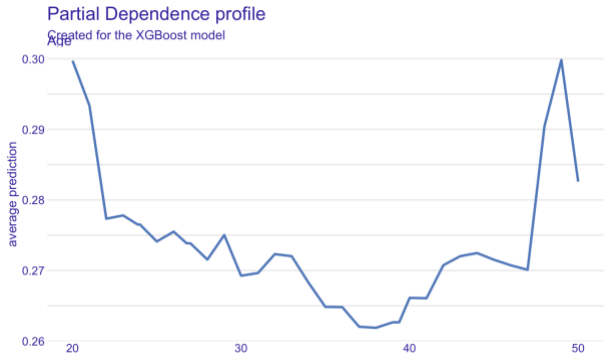

Rysunek 21Profil PDP dla zmiennej Age.

Wykres zależności częściowej ilustruje uśredniony wpływ zmiennej **Age** na wartość predykcji modelu XGBoost, przy założeniu, że pozostałe zmienne objaśniające przyjmują średnie wartości. Zależność ta ma charakter wyraźnie nieliniowy. Dla najmłodszych obserwacji model generuje nieco wyższe wartości prawdopodobieństwa, które następnie stopniowo maleją wraz ze wzrostem wieku, osiągając minimum w okolicach późnych trzydziestych lat. Po tym punkcie widoczny jest ponowny wzrost predykcji, szczególnie zaznaczający się w najwyższych przedziałach wieku. Skala osi Y obejmuje bardzo wąski zakres wartości (około 0,26 - 0,30), co

oznacza, że obserwowane zmiany odpowiadają jedynie subtelnym różnicom w średniej wartości prawdopodobieństwa, lecz nie zmieniają wyniku klasyfikacji.

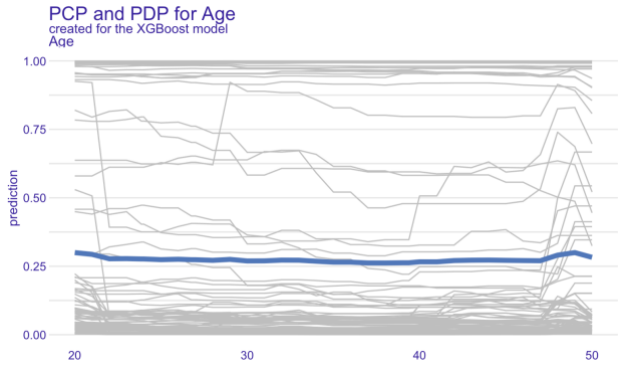

Rysunek 22 Wykres PCP i PDP dla zmiennej Age.

Wykres potwierdza wspomniany wcześniej słaby wpływ zmiennej **Age** na wartość predykcji. Średni wpływ zmiennej Age, widoczny na linii PDP, jest niemal stały w całym analizowanym zakresie i zmienia się tylko nieznacznie. Oznacza to, że wraz ze wzrostem wieku przewidywane prawdopodobieństwo praktycznie się nie zmienia. Pojedyncze krzywe PCP wskazują na różnice pomiędzy poszczególnymi obserwacjami, jednak zmiany te rzadko prowadzą do wyraźnego przesunięcia predykcji dla konkretnego przypadku. W efekcie wiek nie jest zmienną, która samodzielnie decyduje o wyniku klasyfikacji.

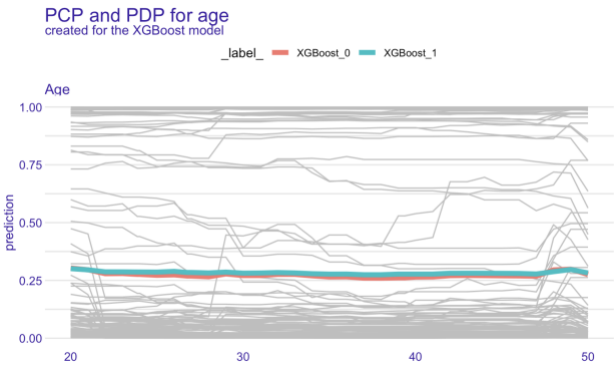

Rysunek 23 PDP i PCP dla zmiennej Age z rozróżnieniem na płeć.

Na wykresie przedstawiono profile zależności cząstkowej (PDP) oraz krzywe PCP dla zmiennej **Age**, z rozróżnieniem na klasy płci, gdzie 0 oznacza mężczyzn, a 1 kobiety. Widoczne linie PDP dla obu grup przebiegają bardzo blisko siebie i pozostają niemal płaskie w całym analizowanym zakresie wieku. Oznacza to, że wpływ wieku na predykcję modelu jest podobny

zarówno dla mężczyzn, jak i kobiet oraz ma niewielką siłę oddziaływania. Różnice pomiędzy średnimi predykcjami dla obu płci są minimalne i nie prowadzą do istotnych zmian wartości predykcji ani do zmiany wyniku klasyfikacji. Model nie różnicuje istotnie swojego zachowania względem wieku w zależności od płci.

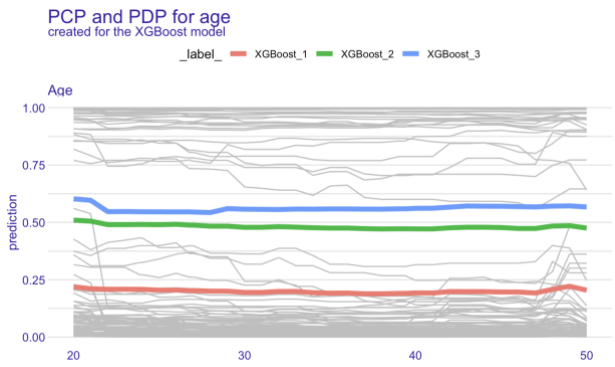

Rysunek 24 PDP i PCP dla zmiennej Age z rozróżnieniem na poziom wykształcenia.

Na wykresie przedstawiono profile zależności częściowej (PDP) oraz krzywe PCP dla zmiennej **Age**, z rozróżnieniem na poziomy wykształcenia: studia pierwszego stopnia, studia magisterskie oraz studia doktoranckie. Widoczne linie PDP dla poszczególnych poziomów wykształcenia przebiegają niemal równolegle i pozostają w dużej mierze płaskie w całym analizowanym zakresie wieku. Oznacza to, że wpływ wieku na predykcję modelu jest stabilny i słaby niezależnie od poziomu wykształcenia.

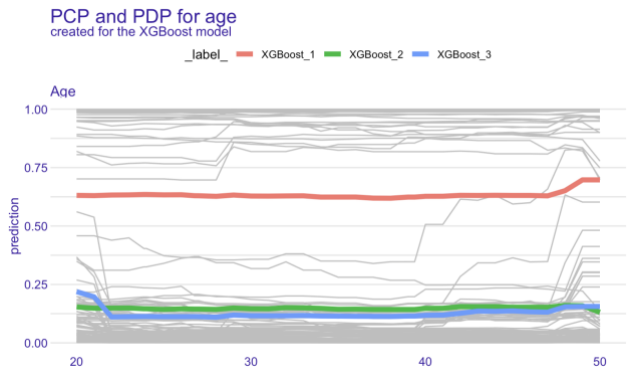

Rysunek 25 PDP i PCP dla zmiennej Age z rozróżnieniem na strategie rekrutacyjne.

Wykres PDP i PCP dla zmiennej **Age**, przedstawiony osobno dla różnych strategii rekrutacyjnych, wskazuje, że wpływ wieku na predykcję modelu XGBoost jest bardzo ograniczony. Linie PDP dla wszystkich strategii przebiegają niemal płasko w całym

analizowanym zakresie wieku, co oznacza, że zmiana wieku nie prowadzi do istotnych zmian wartości predykcji ani do zmiany decyzji klasyfikacyjnej. Niezależnie od tego, czy rozpatrywana jest strategia agresywna, umiarkowana czy zachowawcza, wiek jedynie nieznacznie modyfikuje przewidywane prawdopodobieństwo.

7.3.1.2. Interpretacja profilu PDP dla zmiennej ExperienceYears

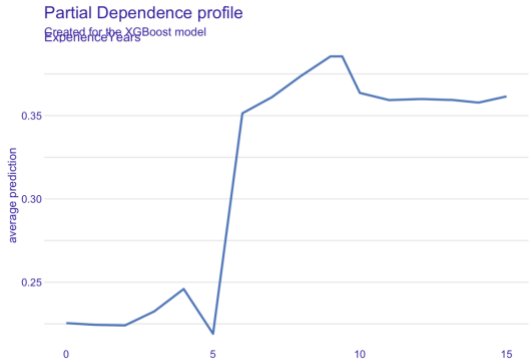

Rysunek 26 Profil PDP dla zmiennej ExperienceYears.

Wykres zależności częściowej dla zmiennej **ExperienceYears** pokazuje, że jej wpływ na predykcję modelu XGBoost jest wyraźny i nieliniowy. Dla niskich wartości doświadczenia zawodowego, obejmujących zakres od 0 do 5 lat, średnia predykcja utrzymuje się na relatywnie niskim i stabilnym poziomie. Następnie obserwowany jest gwałtowny wzrost predykcji pomiędzy 5. a 6. rokiem doświadczenia, wskazujący na istnienie wyraźnego progu, po którego przekroczeniu model znacząco zmienia swoje przewidywania. W dalszym zakresie, wraz z rosnącą liczbą lat doświadczenia, predykcja osiąga maksimum w okolicach 9 - 10 lat, po czym stabilizuje się na nieco niższym, lecz wciąż podwyższonym poziomie. Jednocześnie należy zauważyć, że mimo zmian średnich wartości predykcji, nie prowadzą one do zmiany ostatecznego wyniku klasyfikacji, a jedynie wpływają na poziom przewidywanego prawdopodobieństwa w obrębie tej samej klasy.

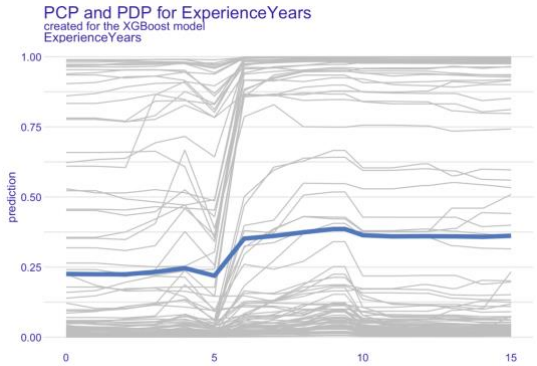

Rysunek 27 Wykres PCP i PDP dla zmiennej ExperienceYears.

Wykres PDP i PCP dla zmiennej **ExperienceYears** potwierdza wyraźny, nieliniowy wpływ doświadczenia na predykcję modelu. Krzywe PCP wskazują na wyraźne zróżnicowanie obserwacji na dwie grupy. Pierwszą, liczniejszą, stanowią przypadki, dla których przejście z 5 na 6 lat doświadczenia nie powoduje zmiany ostatecznego wyniku klasyfikacji. Drugą, mniej liczną, lecz wyraźnie zaznaczoną, tworzą obserwacje, w których przekroczenie tego progu prowadzi do zmiany decyzji rekrutacyjnej z negatywnej na pozytywną.

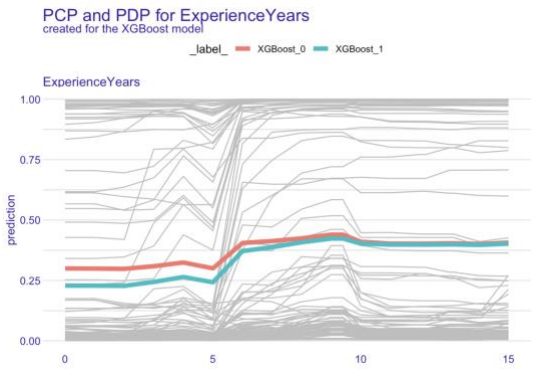

Rysunek 28 PDP i PCP dla zmiennej ExperienceYears z rozróżnieniem na płeć.

Wykres PDP i PCP dla zmiennej **ExperienceYears**, z rozróżnieniem na płeć (0 - mężczyźni, 1 - kobiety), pokazuje, że wpływ doświadczenia zawodowego na predykcję modelu ma podobny charakter w obu grupach. Zarówno dla mężczyzn, jak i kobiet widoczny jest wyraźny próg w okolicach 5 - 6 lat doświadczenia, po którego przekroczeniu średnia predykcja istotnie rośnie. Jednocześnie, mimo zauważalnego wzrostu przewidywanego prawdopodobieństwa po przekroczeniu tego progu, zmiana ta w większości przypadków nie prowadzi do zmiany ostatecznego wyniku klasyfikacji, a jedynie modyfikuje poziom predykcji.

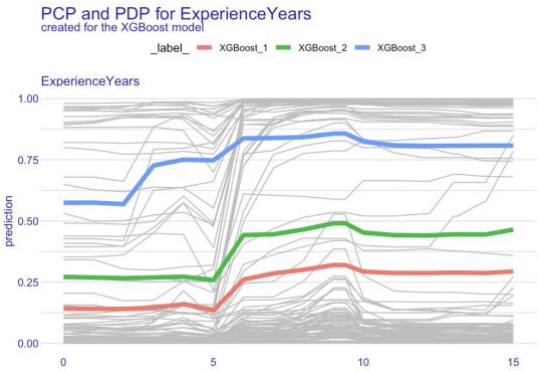

Rysunek 29 PDP i PCP dla zmiennej ExperienceYears z rozróżnieniem na poziom wykształcenia.

Wykres PDP i PCP dla zmiennej **ExperienceYears**, z rozróżnieniem na poziom wykształcenia, pokazuje, że dla osób ze studiami pierwszego stopnia oraz magisterskimi (klasy 1 i 2) wpływ doświadczenia zawodowego na predykcję modelu ma bardzo podobny przebieg. W obu przypadkach widoczny jest wyraźny próg w okolicach 5 - 6 lat doświadczenia, po którego przekroczeniu następuje wzrost predykcji, a następnie jej stabilizacja. Odmienny charakter ma natomiast krzywa odpowiadająca osobom z doktoratem (klasa 3). W tym przypadku predykcja osiąga wyższy poziom już przy mniejszej liczbie lat doświadczenia, a dalszy wzrost ma łagodniejszy przebieg, co sugeruje, że model w mniejszym stopniu uzależnia ocenę tej grupy od liczby lat doświadczenia. Oznacza to, że doświadczenie zawodowe wpływa na predykcję w różny sposób w zależności od poziomu wykształcenia, przy czym różnice te dotyczą głównie intensywności i kształtu reakcji modelu, a nie samego kierunku wpływu.

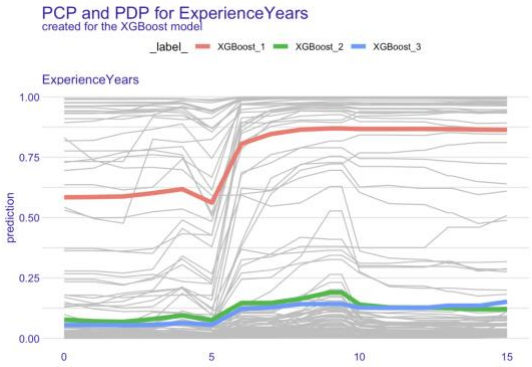

Rysunek 30 PDP i PCP dla zmiennej ExperienceYears z rozróżnieniem na strategie rekrutacyjne.

Wykres PDP i PCP dla zmiennej **ExperienceYears**, z rozróżnieniem na strategie rekrutacyjne, pokazuje, że wpływ doświadczenia zawodowego na predykcję modelu różni się w zależności od przyjętej strategii. Dla strategii 1 (agresywnej) widoczny jest bardzo silny i wyraźny próg w okolicach 5 - 6 lat doświadczenia, po którego przekroczeniu średnia predykcja gwałtownie rośnie i stabilizuje się na wysokim poziomie. W przypadku strategii 2 (umiarkowanej) oraz 3 (zachowawczej) wpływ doświadczenia jest znacznie słabszy. Choć również obserwowany jest wzrost predykcji po przekroczeniu progu 5 - 6 lat doświadczenia, zmiany te są niewielkie i utrzymują się na niskim poziomie.

7.3.1.3. Interpretacja profilu PDP dla zmiennej PreviousCompanies

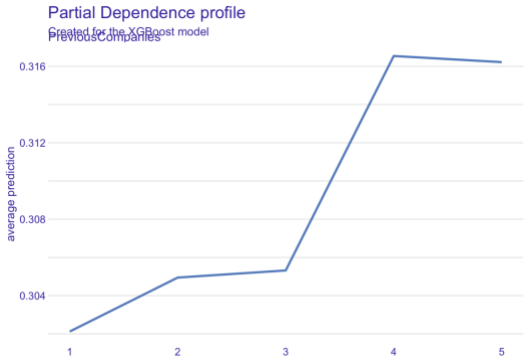

Rysunek 31 Profil PDP dla zmiennej PreviousCompanies.

Wykres zależności częściowej dla zmiennej **PreviousCompanies** wskazuje, że liczba wcześniejszych pracodawców ma bardzo słaby wpływ na predykcję modelu XGBoost. Średnia wartość predykcji rośnie jedynie nieznacznie wraz ze wzrostem liczby poprzednich firm, a obserwowane zmiany mieszczą się w bardzo wąskim zakresie wartości.

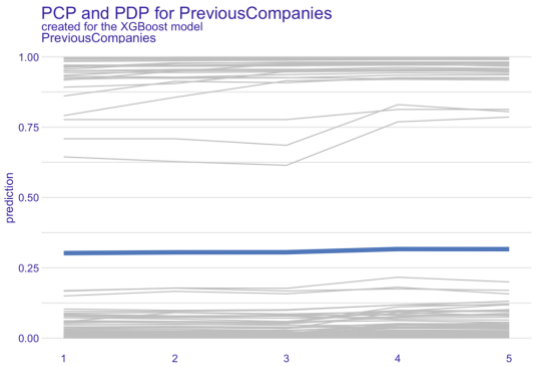

Rysunek 32 Wykres PCP i PDP dla zmiennej PreviousCompanies.

Wykres PDP i PCP dla zmiennej **PreviousCompanies** potwierdza, że liczba wcześniejszych pracodawców ma bardzo ograniczony wpływ na predykcję modelu XGBoost. Uśredniony efekt, reprezentowany przez linię PDP, jest niemal płaski i zmienia się jedynie w minimalnym stopniu wraz ze wzrostem liczby poprzednich firm. Krzywe PCP wskazują, że również na poziomie pojedynczych obserwacji zmiany tej zmiennej rzadko prowadzą do istotnych przesunięć predykcji.

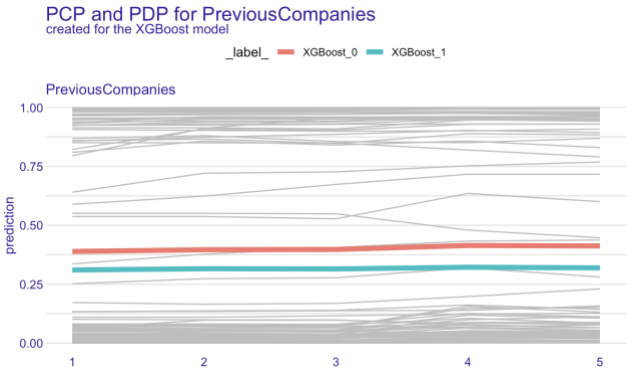

Rysunek 33 PDP i PCP dla zmiennej PreviousCompanies z rozróżnieniem na płeć.

Wykres PDP i PCP dla zmiennej **PreviousCompanies**, z rozróżnieniem na płeć, pokazuje, że liczba wcześniejszych pracodawców ma bardzo podobny wpływ na predykcję modelu zarówno dla mężczyzn, jak i kobiet. Choć widoczna jest niewielka różnica w poziomie bazowej predykcji pomiędzy mężczyznami a kobietami, zmiana liczby wcześniejszych pracodawców nie prowadzi do istotnych przesunięć predykcji ani do zmiany wyniku klasyfikacji w żadnej z grup. W efekcie można stwierdzić, że zmienna PreviousCompanies nie odgrywa roli decyzyjnej niezależnie od płci, a jej wpływ na decyzje modelu jest marginalny.

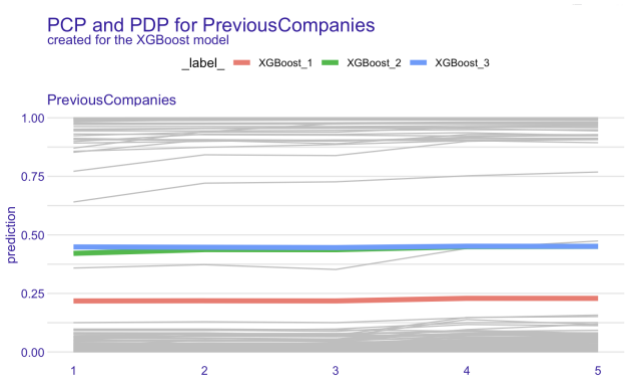

Rysunek 34 PDP i PCP dla zmiennej PreviousCompanies z rozróżnieniem na poziom wykształcenia.

Wykres PDP i PCP dla zmiennej **PreviousCompanies**, z rozróżnieniem na poziom wykształcenia, pokazuje, że liczba wcześniejszych pracodawców ma bardzo ograniczony wpływ na predykcję modelu niezależnie od poziomu wykształcenia. Linie PDP dla wszystkich grup przebiegają niemal płasko, co wskazuje na minimalne zmiany wartości predykcji wraz ze wzrostem liczby poprzednich firm.

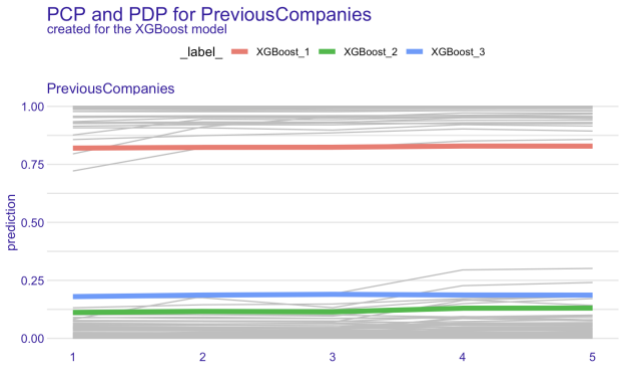

Rysunek 35 PDP i PCP dla zmiennej PreviousCompanies z rozróżnieniem na strategie rekrutacyjne.

Wykres PDP i PCP dla zmiennej **PreviousCompanies**, z rozróżnieniem na strategie rekrutacyjne, pokazuje, że liczba wcześniejszych pracodawców ma bardzo niewielki wpływ na predykcję modelu niezależnie od przyjętej strategii. Linie PDP dla wszystkich strategii przebiegają niemal płasko, co wskazuje na brak istotnych zmian wartości predykcji wraz ze wzrostem liczby poprzednich firm.

7.3.1.4. Interpretacja profilu PDP dla zmiennej DistanceFromCompany

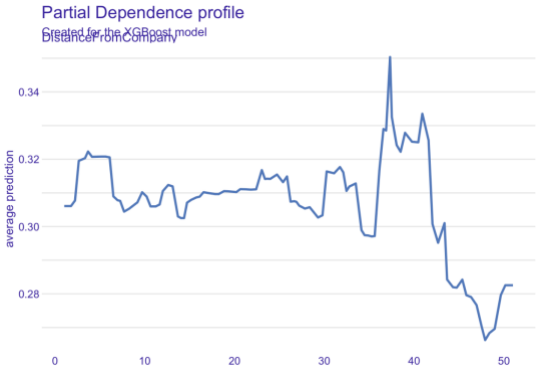

Rysunek 36 Profil PDP dla zmiennej DistanceFromCompany.

Wykres zależności częściowej dla zmiennej **DistanceFromCompany** wskazuje na nieliniowy, lecz umiarkowany wpływ odległości od firmy na predykcję modelu XGBoost. Dla małych i średnich wartości odległości średnia predykcja utrzymuje się na względnie stabilnym poziomie, z niewielkimi wahaniami. W środkowym zakresie widoczne są lokalne wzrosty predykcji, jednak mają one ograniczoną skalę. Wyraźniejsza zmiana pojawia się dopiero dla większych odległości, gdzie obserwowany jest spadek średniej predykcji. Biorąc pod uwagę wąską skalę osi Y, różnice te mają umiarkowany charakter i nie wskazują na silny efekt decyzyjny. Oznacza to, że zmienna DistanceFromCompany wpływa na poziom

przewidywanego prawdopodobieństwa, lecz jej oddziaływanie jest raczej pomocnicze i nie prowadzi samodzielnie do zmiany wyniku klasyfikacji.

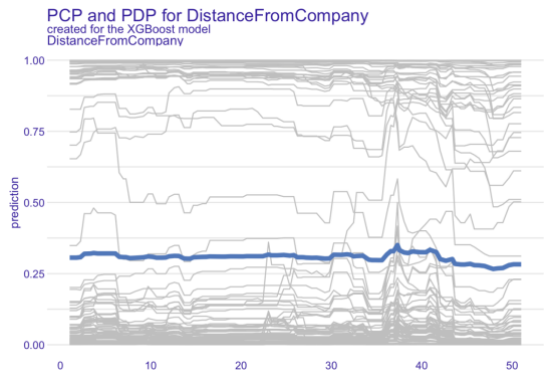

Rysunek 37 Wykres PCP i PDP dla zmiennej DistanceFromCompany.

Wykres PDP i PCP dla zmiennej **DistanceFromCompany** pokazuje, że wpływ odległości kandydata od firmy na predykcję modelu XGBoost jest niewielki i ma głównie charakter lokalnych wahań. Uśredniona krzywa PDP pozostaje w dużej mierze płaska w całym analizowanym zakresie wartości, co wskazuje na brak silnej zależności pomiędzy odległością a przewidywanym wynikiem. Krzywe PCP pokazują zróżnicowanie indywidualnych predykcji, jednak w większości przypadków zmiana odległości nie prowadzi do istotnych przesunięć wartości predykcji ani do zmiany decyzji klasyfikacyjnej. W efekcie zmienna DistanceFromCompany pełni rolę pomocniczą i nie stanowi czynnika decyzyjnego w procesie predykcji.

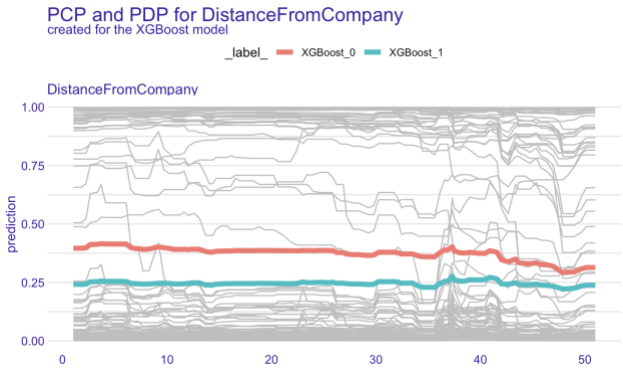

Rysunek 38 PDP i PCP dla zmiennej DistanceFromCompany z rozróżnieniem na płeć.

Wykres PDP i PCP dla zmiennej **DistanceFromCompany**, z rozróżnieniem na płeć, pokazuje bardzo podobny wpływ odległości od firmy na predykcję modelu zarówno dla mężczyzn, jak i kobiet. Linie PDP dla obu grup przebiegają niemal równolegle i pozostają w dużej mierze

płaskie w całym analizowanym zakresie wartości, co wskazuje na niewielkie zmiany przewidywanego prawdopodobieństwa wraz ze zmianą odległości.

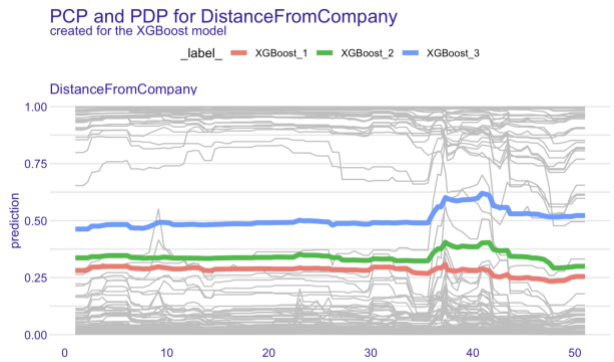

Rysunek 39 PDP i PCP dla zmiennej DistanceFromCompany z rozróżnieniem na poziom wykształcenia.

Wykres PDP i PCP dla zmiennej **DistanceFromCompany**, z rozróżnieniem na poziom wykształcenia, pokazuje, że wpływ odległości od firmy na predykcję modelu ma podobny przebieg we wszystkich analizowanych grupach. Linie PDP dla poszczególnych poziomów wykształcenia są w dużej mierze płaskie, co wskazuje na niewielkie zmiany wartości predykcji wraz ze zmianą odległości. Linie PDP dla osób ze studiami pierwszego stopnia oraz magisterskimi pozostają poniżej progu decyzyjnego i zmieniają się jedynie nieznacznie wraz ze wzrostem odległości. Odmienna sytuacja występuje jednak w przypadku osób z doktoratem. Dla tej grupy, w okolicach odległości około 35 km - 45 km, widoczny jest wzrost średniej predykcji, który przekracza poziom 0,5, co skutkuje zmianą decyzji klasyfikacyjnej.

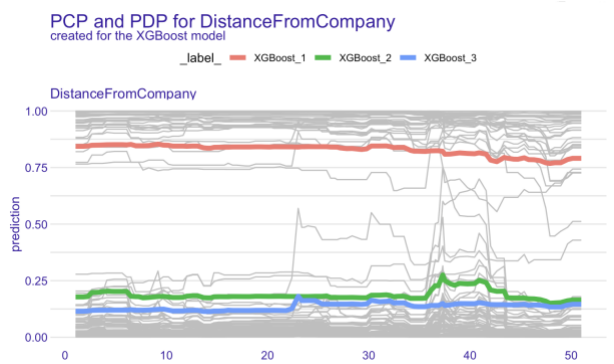

Rysunek 40 PDP i PCP dla zmiennej DistanceFromCompany z rozróżnieniem na strategie rekrutacyjne.

Wykres PDP i PCP dla zmiennej **DistanceFromCompany**, z rozróżnieniem na strategie rekrutacyjne, wskazuje, że wpływ odległości od firmy na predykcję modelu jest ograniczony. Linie PDP dla wszystkich strategii są w większości płaskie, co oznacza, że zmiana odległości nie prowadzi do istotnych zmian wartości predykcji. W przypadku strategii 1 (agresywnej)

predykcja utrzymuje się na wysokim poziomie niezależnie od dystansu, z jedynie niewielkim spadkiem dla większych odległości. Dla strategii umiarkowanej i zachowawczej widoczne są jedynie lokalne, krótkotrwałe wzrosty predykcji w okolicach większych odległości, które nie skutkują trwałą zmianą decyzji klasyfikacyjnej. W konsekwencji zmienna DistanceFromCompany nie odgrywa roli czynnika decyzyjnego w żadnej ze strategii rekrutacyjnych, a jej wpływ ogranicza się do drobnych korekt poziomu przewidywanego prawdopodobieństwa.

7.3.1.5. Interpretacja profilu PDP dla zmiennej InterviewScore

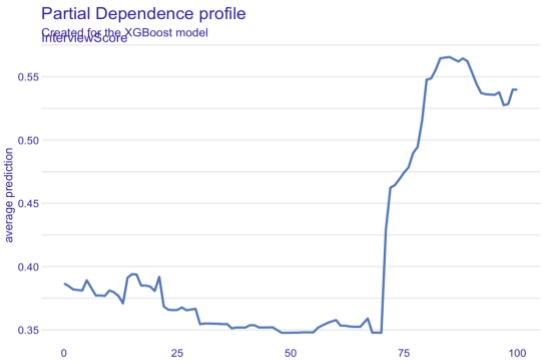

Rysunek 41 Profil PDP dla zmiennej InterviewScore.

Wykres zależności częściowej dla zmiennej **InterviewScore** pokazuje silny i nieliniowy wpływ wyniku rozmowy kwalifikacyjnej na predykcję modelu XGBoost. Dla niskich i średnich wartości InterviewScore średnia predykcja utrzymuje się na względnie stabilnym, umiarkowanym poziomie, z niewielką tendencją spadkową. Wyraźna zmiana następuje w okolicach wartości około 75 punktów, gdzie obserwowany jest gwałtowny wzrost prawdopodobieństwa zatrudnienia. Powyżej tego poziomu predykcja stabilizuje się na wysokim poziomie, przekraczającym próg klasyfikacyjny. Oznacza to, że wynik rozmowy kwalifikacyjnej jest jedną z kluczowych zmiennych w modelu i może samodzielnie prowadzić do zmiany decyzji klasyfikacyjnej.

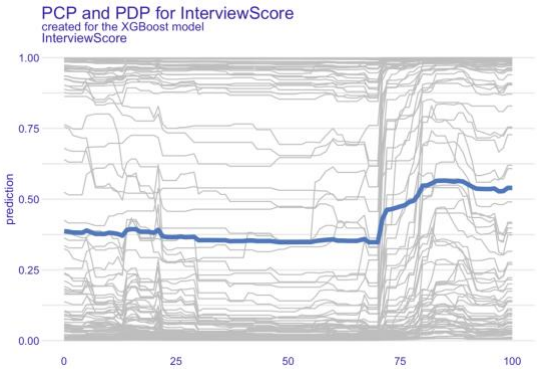

Rysunek 42 Wykres PCP i PDP dla zmiennej InterviewScore.

Wykres PDP i PCP dla zmiennej **InterviewScore** potwierdza, że wynik rozmowy kwalifikacyjnej ma istotny i w dużej mierze decyzyjny wpływ na predykcję modelu XGBoost. Krzywe PCP wskazują, że dla wielu indywidualnych obserwacji przekroczenie tego progu prowadzi do skokowej zmiany przewidywanego prawdopodobieństwa, często skutkującej zmianą decyzji klasyfikacyjnej z negatywnej na pozytywną.

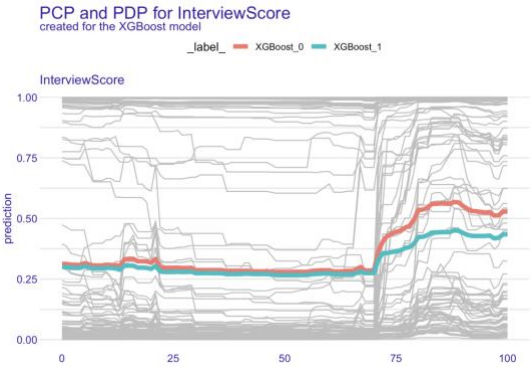

Rysunek 43 PDP i PCP dla zmiennej InterviewScore z rozróżnieniem na płeć.

Wykres PDP i PCP dla zmiennej **InterviewScore**, z rozróżnieniem na płeć, pokazuje wyraźny próg w obu grupach. Zarówno dla kobiet, jak i mężczyzn gwałtowny wzrost prawdopodobieństwa zatrudnienia następuje w okolicach 70 - 75 punktów, co wskazuje na wspólny próg decyzyjny. W przypadku mężczyzn wzrost predykcji po przekroczeniu tego progu jest większy i prowadzi do stabilizacji wartości powyżej poziomu 0,5, co oznacza, że w tej grupie wysoki wynik rozmowy kwalifikacyjnej może skutkować zmianą wyniku klasyfikacji z negatywnego na pozytywny. W przypadku kobiet predykcja również rośnie, jednak stabilizuje się na niższym poziomie, który częściej pozostaje poniżej progu decyzyjnego. W efekcie InterviewScore pełni rolę czynnika decyzyjnego w obu grupach, lecz jego wpływ na ostateczną decyzję jest wyraźniejszy w przypadku mężczyzn.

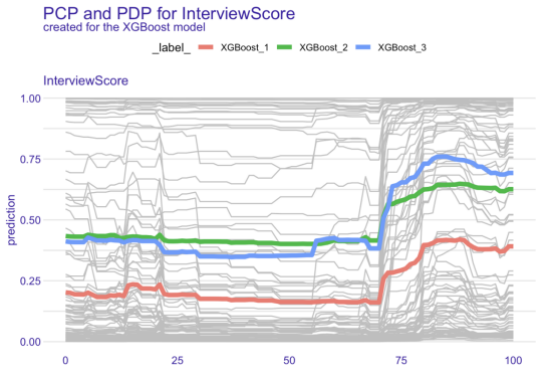

Rysunek 44 PDP i PCP dla zmiennej InterviewScore z rozróżnieniem na poziom wykształcenia.

Wykres PDP i PCP dla zmiennej **InterviewScore**, z rozróżnieniem na poziom wykształcenia, pokazuje wyraźny próg decyzyjny w okolicach 70 - 75 punktów we wszystkich analizowanych grupach. Po jego przekroczeniu następuje gwałtowny wzrost predykcji, jednak zmiana ta ma różne konsekwencje dla poszczególnych poziomów wykształcenia. W przypadku osób z wykształceniem magisterskim (2) oraz doktoratem (3) wzrost predykcji prowadzi do przekroczenia poziomu 0,5, co skutkuje zmianą decyzji klasyfikacyjnej z negatywnej na pozytywną. Dla osób ze studiami pierwszego stopnia (1) predykcja również rośnie, jednak pozostaje poniżej progu decyzyjnego, a więc nie prowadzi do zmiany wyniku klasyfikacji. Oznacza to, że InterviewScore pełni rolę czynnika decyzyjnego we wszystkich grupach, lecz jego wpływ na ostateczny wynik klasyfikacji jest silnie uzależniony od poziomu wykształcenia i najbardziej widoczny w przypadku wykształcenia magisterskiego oraz doktoranckiego.

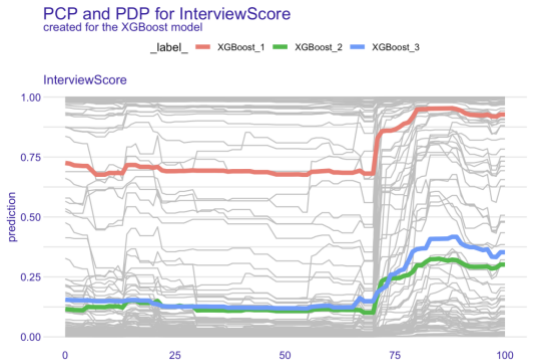

Rysunek 45 PDP i PCP dla zmiennej InterviewScore z rozróżnieniem na strategie rekrutacyjne.

Wykres PDP i PCP dla zmiennej **InterviewScore**, z rozróżnieniem na strategie rekrutacyjne, pokazuje, że wynik rozmowy kwalifikacyjnej ma kluczowe znaczenie w każdej strategii, jednak skutki jego wzrostu są wyraźnie zróżnicowane. We wszystkich strategiach widoczny jest wyraźny wzrost prawdopodobieństwa zatrudnienia po przekroczeniu progu 70 – 75 punktów.

Najsilniejszy efekt obserwowany jest w strategii agresywnej (1), gdzie predykcja już przed przekroczeniem progu utrzymuje się na wysokim poziomie, a po jego przekroczeniu stabilizuje się powyżej 0,85. W strategiach umiarkowanej (2) i zachowawczej (3) wzrost InterviewScore również powoduje istotny wzrost predykcji, jednak wartości te pozostają niższe i nie przekraczają progu decyzyjnego. Oznacza to, że InterviewScore silnie wpływa na poziom przewidywanego prawdopodobieństwa, jednak w kontekście strategii rekrutacyjnej pełni rolę czynnika wzmacniającego ocenę, a nie zmiennej decyzyjnej, ponieważ nie zmienia ostatecznego wyniku klasyfikacji w żadnej z grup.

7.3.1.6. Interpretacja profilu PDP dla zmiennej SkillScore

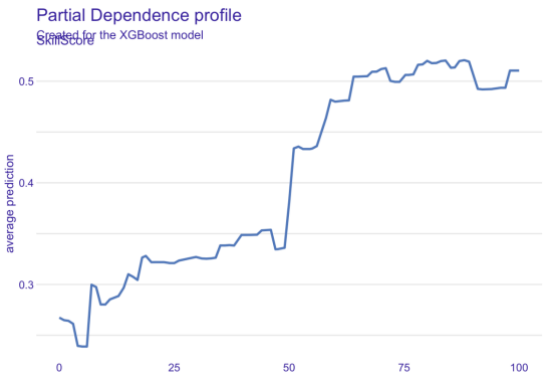

Rysunek 46 Profil PDP dla zmiennej SkillScore.

Wykres zależności częściowej dla zmiennej **SkillScore** pokazuje silny, nieliniowy wpływ poziomu umiejętności na predykcję modelu XGBoost. Dla niskich wartości SkillScore średnia predykcja utrzymuje się na relatywnie niskim poziomie, jednak wraz ze wzrostem wyniku widoczna jest stopniowa tendencja wzrostowa. Kluczowa zmiana następuje w okolicach wartości około 50 punktów, gdzie obserwowany jest wyraźny skok wartości prawdopodobieństwa zatrudnienia. Powyżej tego poziomu predykcja stabilizuje się na wysokim poziomie, oscylując wokół lub powyżej wartości 0,5. Oznacza to, że zmienna SkillScore jest jedną z kluczowych zmiennych w modelu i może samodzielnie wpływać na zmianę wyniku klasyfikacji.

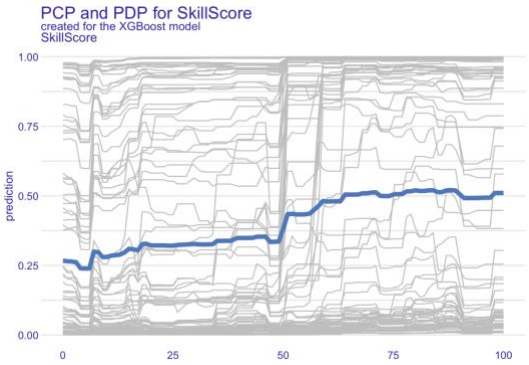

Rysunek 47 Wykres PCP i PDP dla zmiennej SkillScore.

Wykres PDP i PCP dla zmiennej **SkillScore** potwierdza, że poziom umiejętności ma istotny wpływ na predykcję modelu XGBoost. Krzywe PCP wskazują, że dla wielu indywidualnych obserwacji przekroczenie tego progu prowadzi do istotnego wzrostu przewidywanego prawdopodobieństwa, często skutkującego zmianą wyniku klasyfikacji.

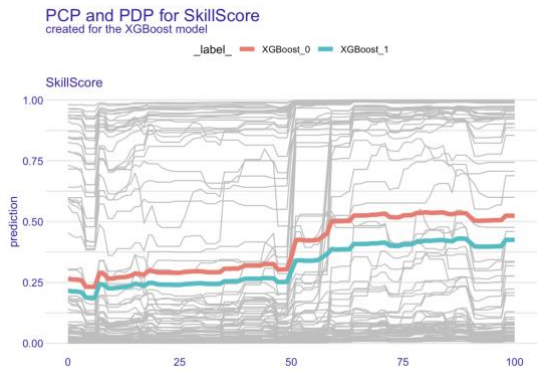

Rysunek 48 PDP i PCP dla zmiennej SkillScore z rozróżnieniem na płeć.

Wykres PDP i PCP dla zmiennej **SkillScore**, z rozróżnieniem na płeć, pokazuje, że poziom umiejętności wpływa na predykcję modelu w obu grupach w bardzo podobny sposób. Zarówno dla mężczyzn, jak i kobiet widoczny jest wyraźny wzrost prawdopodobieństwa zatrudnienia wraz ze wzrostem SkillScore, z szczególnie silnym efektem w okolicach wartości około 50 punktów. Po przekroczeniu tego poziomu średnia predykcja w obu grupach wzrasta i stabilizuje się na wyższym poziomie. Jednocześnie linia PDP dla mężczyzn przebiega powyżej linii dla kobiet, co oznacza, że przy tym samym poziomie SkillScore model przypisuje mężczyznom wyższe przewidywane prawdopodobieństwo pozytywnej decyzji. W rezultacie, po przekroczeniu progu SkillScore, zmiana wyniku klasyfikacji jest bardziej prawdopodobna w przypadku mężczyzn, podczas gdy u kobiet wzrost predykcji pozostaje poniżej progu decyzyjnego. Oznacza to, że choć SkillScore jest istotną zmienną decyzyjną w obu grupach, jego wpływ na ostateczną decyzję jest silniejszy w przypadku mężczyzn.

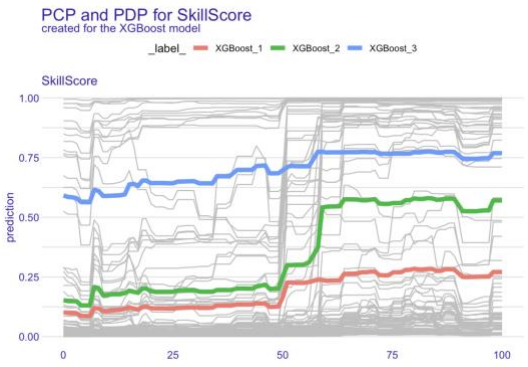

Rysunek 49 PDP i PCP dla zmiennej SkillScore z rozróżnieniem na poziom wykształcenia.

Wykres PDP i PCP dla zmiennej **SkillScore**, z rozróżnieniem na poziom wykształcenia, pokazuje, że wpływ poziomu umiejętności na predykcję modelu jest wyraźny we wszystkich grupach, jednak jego konsekwencje dla wyniku klasyfikacji różnią się w zależności od wykształcenia. We wszystkich przypadkach widoczny jest nieliniowy wzrost predykcji wraz ze wzrostem SkillScore, ze szczególnie wyraźnym skokiem w okolicach wartości około 50 punktów. Dla osób ze studiami pierwszego stopnia (1) wzrost predykcji po przekroczeniu tego progu pozostaje poniżej poziomu 0,5, co oznacza, że nie prowadzi do zmiany decyzji klasyfikacyjnej. W przypadku osób z wykształceniem magisterskim (2) przekroczenie progu SkillScore skutkuje gwałtownym wzrostem predykcji powyżej 0,5, a więc zmianą wyniku klasyfikacji z negatywnego na pozytywny. U kandydatów z doktoratem (3) obserwuje się podobny wpływ jak u osób, które ukończyły studia pierwszego stopnia (1). Oznacza to, że SkillScore pełni rolę czynnika decyzyjnego przede wszystkim w przypadku wykształcenia magisterskiego, natomiast dla osób z wykształceniem pierwszego stopnia oraz tytułem doktora jego wpływ jest wyraźnie słabszy.

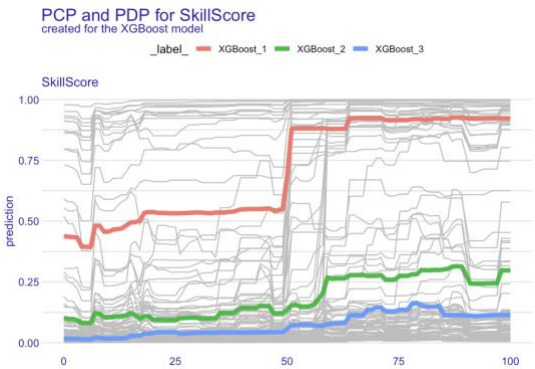

Rysunek 50 PDP i PCP dla zmiennej SkillScore z rozróżnieniem na strategie rekrutacyjne.

Wykres PDP i PCP dla zmiennej **SkillScore**, z rozróżnieniem na strategie rekrutacyjne, pokazuje, że wpływ poziomu umiejętności na predykcję modelu jest wyraźnie zróżnicowany

w zależności od przyjętej strategii. We wszystkich strategiach widoczny jest nieliniowy wzrost predykcji wraz ze wzrostem SkillScore, jednak jego znaczenie decyzyjne nie jest jednakowe. W strategii agresywnej (1) predykcja już dla niskich wartości SkillScore utrzymuje się na relatywnie wysokim poziomie, a w okolicach wartości około 50 punktów następuje gwałtowny wzrost, po którym predykcja stabilizuje się wyraźnie powyżej progu 0,5. Oznacza to, że w tej strategii SkillScore ma charakter silnie decyzyjny i jego wzrost prowadzi do jednoznacznie pozytywnej decyzji rekrutacyjnej. W strategii umiarkowanej (2) widoczny jest wzrost predykcji po przekroczeniu tego samego progu, jednak wartości pozostają poniżej 0,5, co wskazuje, że SkillScore wzmacnia ocenę kandydata, ale nie zmienia ostatecznego wyniku klasyfikacji. Najsłabszy efekt obserwowany jest w strategii zachowawczej (3), gdzie predykcja pozostaje niska w całym zakresie SkillScore, a wzrost umiejętności ma jedynie marginalny wpływ na prawdopodobieństwo zatrudnienia. W konsekwencji SkillScore pełni rolę kluczowego czynnika decyzyjnego przede wszystkim w strategii agresywnej, natomiast w strategiach umiarkowanej i zachowawczej jego wpływ ogranicza się do stopniowej modyfikacji poziomu przewidywanego prawdopodobieństwa.

7.3.1.7. Interpretacja profilu PDP dla zmiennej PersonalityScore

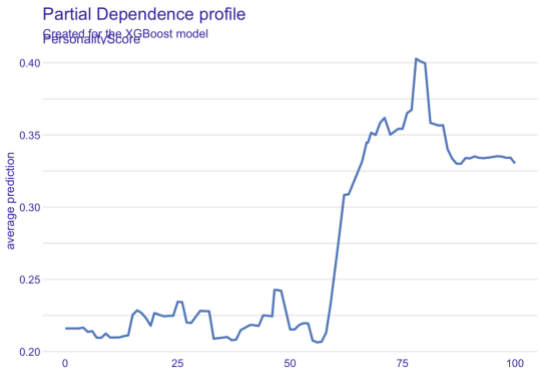

Rysunek 51 Profil PDP dla zmiennej PersonalityScore.

Wykres zależności częściowej dla zmiennej **PersonalityScore** wskazuje na nieliniowy wpływ cech osobowości na predykcję modelu XGBoost. Dla niskich i średnich wartości PersonalityScore średnia predykcja utrzymuje się na relatywnie niskim i stabilnym poziomie, z niewielkimi wahaniami. Wyraźna zmiana następuje w okolicach wartości około 60 punktów, gdzie obserwowany jest gwałtowny wzrost prawdopodobieństwa zatrudnienia. Predykcja osiąga maksimum w przedziale około 70 - 75 punktów, po czym nieznacznie spada i stabilizuje się na podwyższonym poziomie. Uwzględniając skalę osi Y, wzrost predykcji jest zauważalny, jednak zakres wartości pozostaje poniżej progu decyzyjnego 0,5. Oznacza to,

że PersonalityScore istotnie wpływa na poziom przewidywanego prawdopodobieństwa, lecz samodzielnie rzadko prowadzi do zmiany wyniku klasyfikacji.

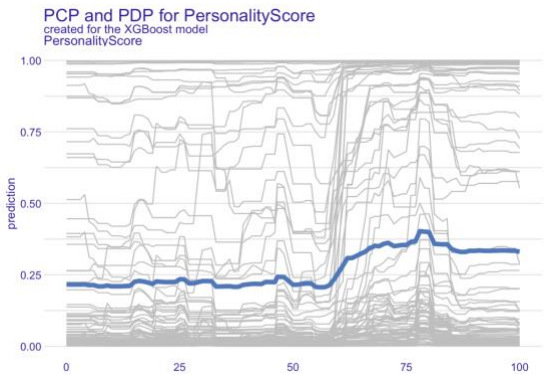

Rysunek 52 Wykres PCP i PDP dla zmiennej PersonalityScore.

Wykres PDP i krzywe PCP dla zmiennej **PersonalityScore** potwierdzają, że wzrost tej cechy podnosi poziom predykcji, jednak efekt ten ma charakter umiarkowany. Krzywe PCP wskazują na duże zróżnicowanie indywidualnych obserwacji, lecz w większości przypadków zmiana PersonalityScore nie prowadzi do przekroczenia progu decyzyjnego, a jedynie nieznacznie modyfikuje wartość predykcji.

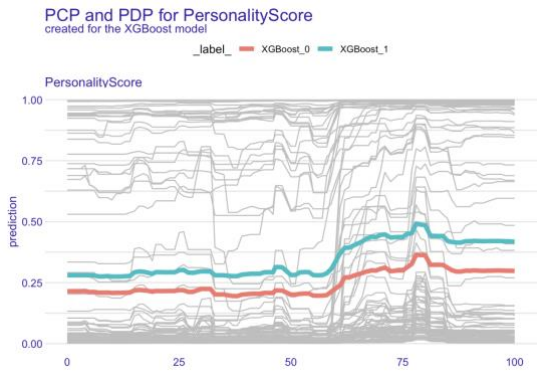

Rysunek 53 PDP i PCP dla zmiennej PersonalityScore z rozróżnieniem na płeć.

Wykres PDP i krzywe PCP dla zmiennej **PersonalityScore** pokazują, że wpływ tej cechy jest bardzo podobny w obu grupach płci. Zarówno dla kobiet, jak i mężczyzn przebieg krzywych PDP ma zbliżony kształt, a krzywe PCP wskazują na analogiczne zróżnicowanie indywidualnych predykcji. W obu grupach wzrost PersonalityScore prowadzi do umiarkowanego zwiększenia poziomu predykcji, jednak w podobnym stopniu i bez wyraźnego wpływu na zmianę wyniku klasyfikacji.

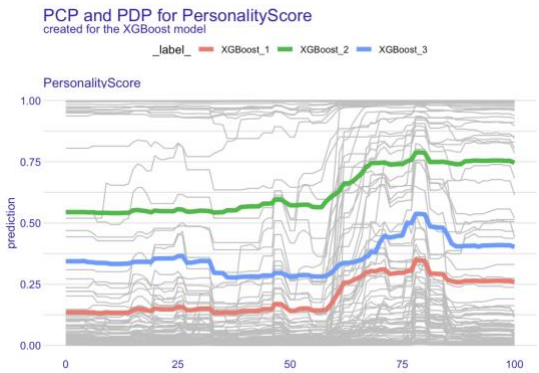

Rysunek 54 PDP i PCP dla zmiennej PersonalityScore z rozróżnieniem na poziom wykształcenia.

Wykres PDP i krzywe PCP dla zmiennej **PersonalityScore**, z rozróżnieniem na poziom wykształcenia, pokazują, że wpływ cech osobowości ma podobny przebieg we wszystkich grupach. Dla każdego poziomu wykształcenia widoczny jest stopniowy wzrost predykcji wraz ze wzrostem PersonalityScore, ze wzmocnieniem efektu w wyższych zakresach wartości. Różnice pomiędzy grupami dotyczą głównie poziomu bazowej predykcji, natomiast sam kształt zależności pozostaje zbliżony i nie prowadzi do istotnych zmian wyniku klasyfikacji.

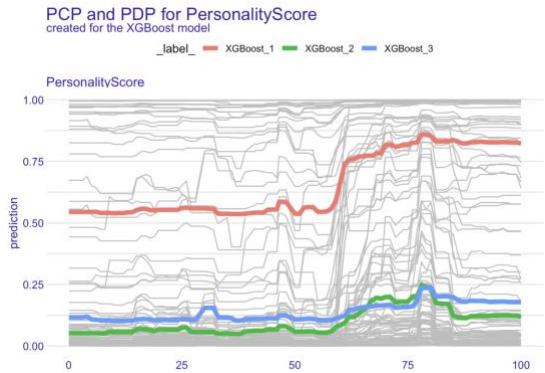

Rysunek 55 PDP i PCP dla zmiennej PersonalityScore z rozróżnieniem na strategie rekrutacyjne.

Wykres PDP i krzywe PCP dla zmiennej **PersonalityScore,** z rozróżnieniem na strategie rekrutacyjne, pokazują zróżnicowany wpływ tej cechy w zależności od strategii. W strategii agresywnej (1) widoczny jest znacznie silniejszy efekt progowy - w wyższych zakresach PersonalityScore następuje wyraźny, skokowy wzrost predykcji, który stabilizuje się na wysokim poziomie. W strategiach umiarkowanej (2) oraz zachowawczej (3) wzrost predykcji jest wyraźnie słabszy i ma bardzo podobny przebieg w obu grupach, bez gwałtownych skoków.

7.3.2. PDP dla zmiennych kategorycznych

7.3.2.1. Interpretacja profilu PDP dla zmiennej Gender

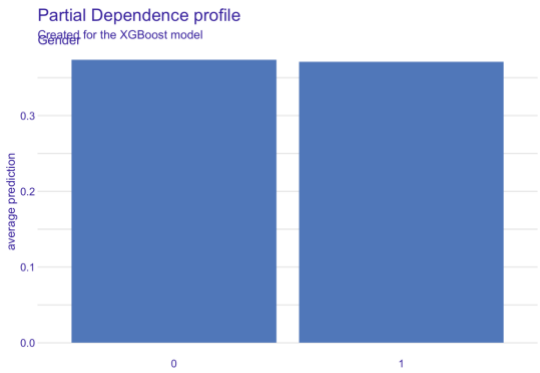

Rysunek 56 Profil PDP dla zmiennej Gender.

Wykres zależności częściowej dla zmiennej **Gender** pokazuje, że średnia predykcja modelu jest praktycznie identyczna dla obu kategorii płci. Brak zauważalnych różnic w poziomie predykcji wskazuje, że płeć nie ma istotnego wpływu na decyzje modelu i nie pełni roli czynnika decyzyjnego. Oznacza to, że zmienna Gender jest przez model traktowana neutralnie, a wynik klasyfikacji zależy od innych cech.

7.3.2.2. Interpretacja profilu PDP dla zmiennej EducationLevel

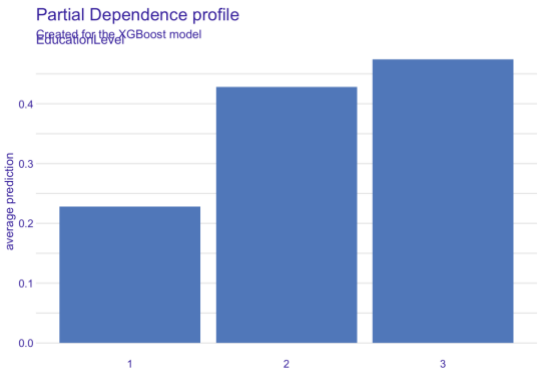

Rysunek 57 Profil PDP dla zmiennej EducationLevel.

Wykres zależności częściowej dla zmiennej **EducationLevel** pokazuje wyraźny wzrost prawdopodobieństwa zatrudnienia wraz z poziomem wykształcenia. Najniższa wartość predykcji występuje dla studiów pierwszego stopnia, wyraźnie wyższa dla studiów magisterskich, natomiast najwyższa dla doktoratu. Warto uwzględnić skalę osi Y, która obejmuje zakres od 0 do 0,4. Oznacza to, że mimo widocznych różnic pomiędzy poziomami

wykształcenia, wartości predykcji pozostają poniżej progu decyzyjnego. W konsekwencji zmienna EducationLevel istotnie różnicuje poziom przewidywanego prawdopodobieństwa, lecz nie prowadzi samodzielnie do zmiany wyniku klasyfikacji, pełniąc rolę czynnika wspierającego decyzję modelu.

7.3.2.3. Interpretacja profilu PDP dla zmiennej RecruitmentStrategy

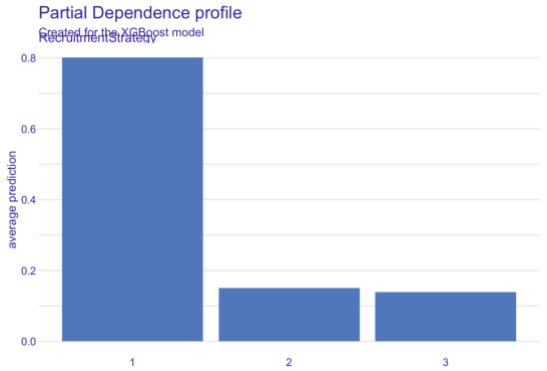

Rysunek 58 Profil PDP dla zmiennej RecruitmentStrategy.

Wykres zależności częściowej dla zmiennej **RecruitmentStrategy** pokazuje bardzo wyraźne zróżnicowanie średniej predykcji pomiędzy poszczególnymi strategiami rekrutacyjnymi. Strategia 1 (agresywna) charakteryzuje się zdecydowanie najwyższą wartością predykcji, wyraźnie przekraczającą próg decyzyjny, co oznacza, że sama zmiana strategii na agresywną może prowadzić do pozytywnej decyzji klasyfikacyjnej. Z kolei strategie 2 (umiarkowana) i 3 (zachowawcza) osiągają znacznie niższe wartości predykcji, mieszczące się poniżej poziomu 0,5. Zmienna RecruitmentStrategy jest jedną z najsilniejszych zmiennych decyzyjnych w modelu. Różnice pomiędzy strategiami mają duży charakter bezwzględny i nie ograniczają się jedynie do korekty prawdopodobieństwa, lecz bezpośrednio wpływają na wynik klasyfikacji.

7.4. Wykresy Break Down oraz wartości SHAP

Wykresy Break-Down (BD) służą do wyjaśniania pojedynczej predykcji modelu poprzez pokazanie, jaki wpływ mają na nią poszczególne zmienne. Metoda ta pozwala krok po kroku prześledzić, jak wartość predykcji zmienia się wraz z uwzględnianiem kolejnych cech, zaczynając od wartości bazowej modelu. Analizę przeprowadzono dla kilku różnych kolejności cech. Każda z nich odzwierciedla inną perspektywę procesu rekrutacyjnego.
W analizie wykorzystano tę samą, losowo wybraną obserwację przedstawiającą kandydata w wieku 29 lat, płci męskiej, posiadającego ukończone studia pierwszego stopnia. Kandydat ten ma 8 lat doświadczenia zawodowego, pracował wcześniej w 3 firmach i mieszka w odległości około 28 km od siedziby firmy. W procesie rekrutacyjnym uzyskał 86 punktów z rozmowy kwalifikacyjnej, 94 punkty z oceny umiejętności oraz 21 punktów z oceny cech osobowości. Kandydat brał udział w rekrutacji prowadzonej zgodnie ze strategią agresywną oraz uzyskał pozytywną decyzję o zatrudnieniu.

7.4.1. Wykres Break Down – kompetencje

W pierwszym wariancie przyjęto kolejność, w której priorytetyzowane są zmienne opisujące kompetencje kandydata oraz wyniki procesu rekrutacyjnego.

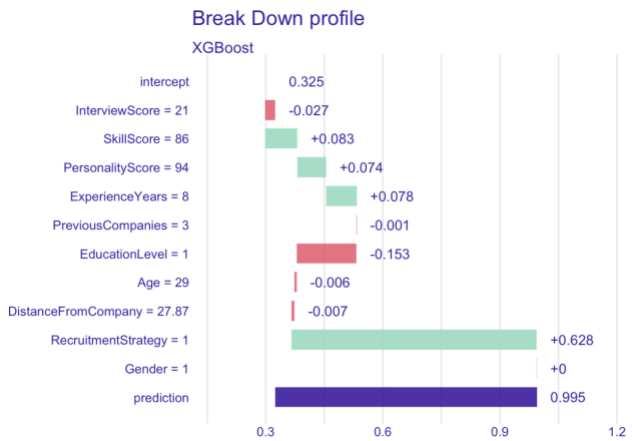

Rysunek 59 Profil Break Down - kompetencje.

Analizowany wykres pokazuje, że kompetencje kandydata, takie jak wynik rozmowy kwalifikacyjnej, ocena umiejętności, cechy osobowości oraz doświadczenie zawodowe, mają w większości dodatni wpływ na wartość predykcji modelu. Ich łączny wkład istotnie zwiększa prawdopodobieństwo pozytywnej decyzji o zatrudnieniu i prowadzi do przekroczenia progu

decyzyjnego modelu, co skutkuje pozytywną decyzją o zatrudnieniu jeszcze przed uwzględnieniem pozostałych zmiennych. Największy wzrost prawdopodobieństwa zatrudnienia następuje po uwzględnieniu strategii rekrutacyjnej, która istotnie wpływa na wynik modelu. Wskazuje to, że w analizowanym przypadku strategia rekrutacyjna odgrywa kluczową rolę w procesie decyzyjnym modelu i znacząco wzmacnia wpływ wcześniej uwzględnionych kompetencji kandydata. Należy podkreślić, że w analizowanym wariancie strategia rekrutacyjna, uwzględniona przy końcu kolejności, samodzielnie powoduje przekroczenie progu decyzyjnego modelu, co oznacza, że nawet bez uwzględnienia pozostałych cech kandydata prowadziłaby do pozytywnej decyzji o zatrudnieniu. Poziom wykształcenia kandydata (studia pierwszego stopnia) obniża wartość prawdopodobieństwa zatrudnienia, co sugeruje, że wyższe wykształcenie zwiększa szanse na pozytywną decyzję rekrutacyjną. Pozostałe zmienne mają marginalny wpływ na końcową predykcję.

7.4.2. Wykres Break Down – podstawowe cechy

W tym wariancie zmienne zostały uporządkowane w taki sposób, aby w pierwszej kolejności uwzględnić podstawowe cechy kandydata, następnie jego wykształcenie i doświadczenie zawodowe, a w dalszej części wyniki procesu rekrutacyjnego. Na końcu dodano strategię rekrutacyjną, co pozwala ocenić jej wpływ na końcową wartość predykcji po uwzględnieniu pozostałych cech.

Rysunek 60 Wykres Break Down - podstawowe cechy.

Analiza wykresu wskazuje, że zmienne takie jak płeć i wiek mają znikomy wpływ na prawdopodobieństwo pozytywnej decyzji o zatrudnieniu. Również odległość od siedziby firmy oraz liczba wcześniejszych miejsc pracy nie wpływają istotnie na wynik predykcji modelu.

Poziom wykształcenia kandydata (studia pierwszego stopnia) obniża przewidywane prawdopodobieństwo zatrudnienia, jednak efekt ten nie jest dominujący. Dodatni wpływ na prawdopodobieństwo zatrudnienia mają doświadczenie zawodowe oraz ocena umiejętności, jednak ich wkład jest umiarkowany. Decydujący wzrost prawdopodobieństwa pozytywnej klasyfikacji następuje dopiero po uwzględnieniu strategii rekrutacyjnej, która prowadzi do wyraźnego przekroczenia progu decyzyjnego modelu. Oznacza to, że podobnie jak w poprzednim wariancie, strategia rekrutacyjna odgrywa kluczową rolę w kształtowaniu decyzji modelu, natomiast podstawowe cechy kandydata nie stanowią istotnego czynnika decyzyjnego.

7.4.3. Wykres Break Down – odległość od miejsca pracy

W tym wariancie analizę rozpoczęto od czynnika związanego z logistyką zatrudnienia, czyli odległości kandydata od siedziby firmy, a następnie uwzględniono strategię rekrutacyjną. W dalszej kolejności dodawano podstawowe cechy kandydata oraz jego doświadczenie zawodowe, natomiast na końcu uwzględniono wyniki uzyskane w procesie rekrutacyjnym.

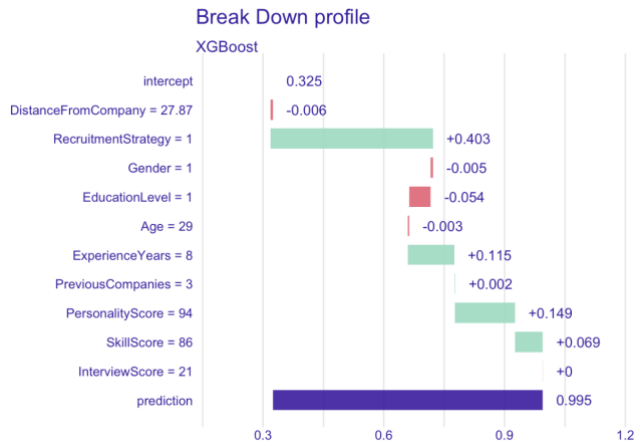

Rysunek 61 Wykres Break Down - odległość od miejsca pracy.

Uwzględnienie odległości miejsca zamieszkania kandydata od siedziby firmy na początkowym miejscu w kolejności nie wpływa istotnie na prawdopodobieństwo pozytywnej decyzji o zatrudnieniu. Dodanie strategii rekrutacyjnej powoduje wyraźny wzrost przewidywanego prawdopodobieństwa zatrudnienia, prowadząc do zmiany decyzji modelu na pozytywną. Pozostałe cechy, takie jak płeć, wiek oraz liczba wcześniejszych miejsc pracy, wykazują jedynie marginalny wpływ na wynik predykcji. Uwzględnienie doświadczenia zawodowego oraz

wyników ocen kompetencyjnych, w szczególności oceny umiejętności i cech osobowości, powoduje dalszy wzrost prawdopodobieństwa zatrudnienia.

7.4.4. Wykres Break Down – doświadczenie

W tym wariancie kolejność rozpoczęto od doświadczenia zawodowego kandydata oraz wyników uzyskanych w procesie rekrutacyjnym. W dalszej kolejności uwzględniono pozostałe cechy formalne i demograficzne, natomiast na końcu dodano strategię rekrutacyjną, aby sprawdzić jej wpływ po uwzględnieniu wszystkich pozostałych zmiennych.

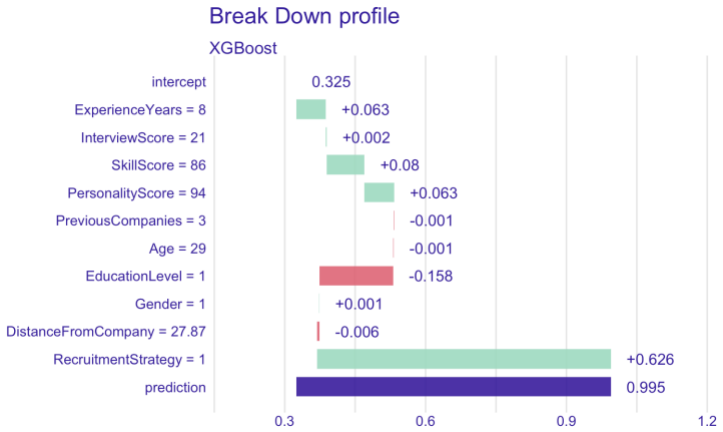

Rysunek 62 Wykres Break Down – doświadczenie.

Doświadczenie zawodowe oraz wyniki ocen kompetencyjnych (rozmowa kwalifikacyjna, ocena umiejętności oraz cechy osobowości) powodują łącznie istotny wzrost przewidywanego prawdopodobieństwa pozytywnej decyzji o zatrudnieniu, który w analizowanym przypadku prowadzi do przekroczenia progu pozytywnej klasyfikacji. Poziom wykształcenia kandydata wywiera zauważalny, ujemny wpływ na prawdopodobieństwo zatrudnienia, obniżając wynik modelu na etapie jego uwzględnienia. Natomiast zmienne, takie jak liczba wcześniejszych firm, wiek, płeć oraz odległość od siedziby firmy, mają jedynie marginalny wpływ na końcowy wynik predykcji. Uwzględnienie strategii rekrutacyjnej na końcu powoduje bardzo silny wzrost prawdopodobieństwa pozytywnej decyzji o zatrudnieniu, prowadząc do jego wysokiej wartości. Wskazuje to, że strategia rekrutacyjna pełni w tym przypadku rolę czynnika, który wzmacnia wcześniej uzyskaną pozytywną decyzję modelu.

7.4.5. Wykres Break Down – strategia rekrutacyjna

W tym wariancie kolejność rozpoczęto od strategii rekrutacyjnej, aby ocenić jej samodzielny wpływ na decyzję modelu, bez uwzględniania informacji o pozostałych cechach kandydata.

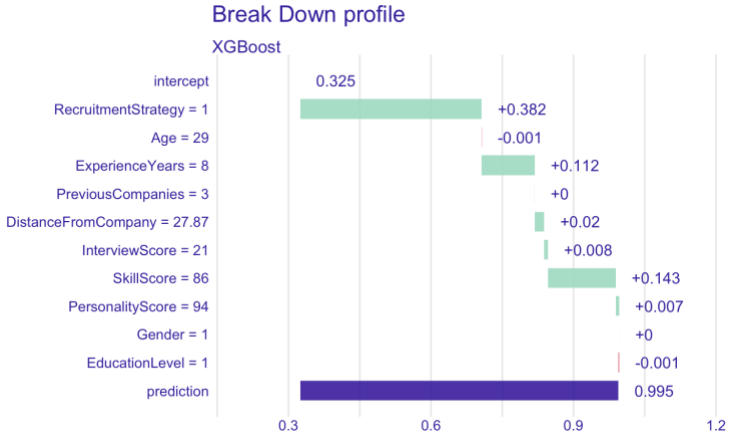

Rysunek 63 Wykres Break Down - strategia rekrutacyjna.

Strategia rekrutacyjna będąca na początku kolejności powoduje istotny wzrost przewidywanego prawdopodobieństwa pozytywnej decyzji o zatrudnieniu, który w analizowanym przypadku prowadzi do przekroczenia progu pozytywnej klasyfikacji i zmiany decyzji modelu na pozytywną. Oznacza to, że już sam wybór strategii rekrutacyjnej, rozpatrywany niezależnie od pozostałych cech kandydata, jest wystarczający do uzyskania pozytywnej decyzji modelu. Kolejne zmienne, takie jak wiek, liczba wcześniejszych firm, odległość od siedziby firmy, płeć oraz poziom wykształcenia, mają nieistotny wpływ na dalszą zmianę prawdopodobieństwa zatrudnienia. Uwzględnienie doświadczenia zawodowego oraz oceny umiejętności powoduje dalszy wzrost prawdopodobieństwa pozytywnej decyzji, dodatkowo wzmacniając pozytywny wynik modelu.

7.4.6. Wykresy Break Down – podsumowanie

Analiza wykresów Break Down dla różnych kolejności zmiennych pokazuje, że końcowa decyzja modelu jest w dużej mierze determinowana przez strategię rekrutacyjną oraz kompetencje kandydata, takie jak doświadczenie zawodowe i wyniki ocen uzyskanych w procesie rekrutacyjnym. W każdym wariancie strategia rekrutacyjna odgrywa kluczową rolę, prowadząc samodzielnie do przekroczenia progu decyzyjnego modelu lub istotnie wzmacniając wcześniej uzyskane prawdopodobieństwo pozytywnej decyzji o zatrudnieniu. Podstawowe cechy kandydata, takie jak płeć, wiek, liczba wcześniejszych miejsc pracy czy odległość od

siedziby firmy, mają marginalny wpływ na prawdopodobieństwo zatrudnienia. Poziom wykształcenia wykazuje zauważalny, lecz ujemny wpływ, jednak nie stanowi czynnika decydującego o końcowej decyzji modelu. Porównanie różnych kolejności zmiennych wskazuje również na względną stabilność uzyskanych wyników oraz na to, że zmiana kolejności wpływa głównie na sposób kształtowania się prawdopodobieństwa pozytywnej decyzji o zatrudnieniu, a nie na jego ostateczną wartość.

7.4.7. Wartości SHAP

Wykresy Break Down umożliwiają szczegółową analizę pojedynczej predykcji modelu, rozumianej jako prawdopodobieństwo pozytywnej decyzji, jednak ich interpretacja zależy od przyjętej kolejności zmiennych. W celu uzyskania bardziej uogólnionego wyjaśnienia wpływu poszczególnych cech na decyzję modelu, w kolejnym etapie zastosowano metodę SHAP, która opiera się na uśrednieniu wartości przypisanych danej zmiennej ze wszystkich możliwych uporządkowań.

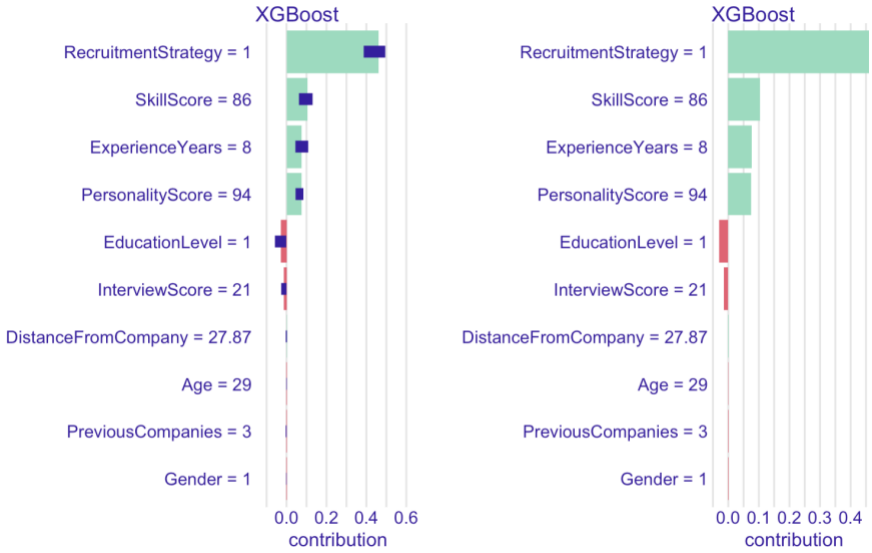

Rysunek 64 Wartości SHAP.

Analiza wartości SHAP potwierdza wnioski uzyskane na podstawie wykresów Break Down. Największy wpływ na prawdopodobieństwo pozytywnej decyzji o zatrudnieniu ma strategia rekrutacyjna. Czynnik ten odgrywa kluczową rolę w procesie decyzyjnym modelu niezależnie od kolejności uwzględniania pozostałych zmiennych. Istotny wpływ na wynik predykcji mają również kompetencje kandydata, w szczególności ocena umiejętności, doświadczenie zawodowe oraz ocena cech osobowości. Poziom wykształcenia także wpływa na proces

decyzyjny, jednak jego znaczenie jest wyraźnie mniejsze w porównaniu z wymienionymi wcześniej cechami. Pozostałe zmienne cechują się bardzo niskimi wartościami SHAP, co wskazuje na ich marginalny wpływ na prawdopodobieństwo zatrudnienia i potwierdza, że nie odgrywają one istotnej roli w decyzjach podejmowanych przez model.

8. Podsumowanie

Celem pracy było zbudowanie skutecznego modelu predykcyjnego wspomagającego decyzje rekrutacyjne oraz przeprowadzenie pogłębionej analizy interpretowalności jego działania. Na podstawie porównania jakości predykcyjnej różnych algorytmów uczenia maszynowego jako najlepszy wybrany został model XGBoost, który charakteryzował się najwyższą skutecznością klasyfikacji oraz stabilnością wyników. Uzyskane wyniki analizy interpretowalności okazały się w pewnym stopniu zaskakujące. Największy wpływ na prawdopodobieństwo pozytywnej decyzji o zatrudnieniu ma strategia rekrutacyjna, która w wielu przypadkach samodzielnie prowadzi do zmiany decyzji modelu na pozytywną. Jest to wynik zaskakujący, ponieważ strategia rekrutacyjna nie jest cechą zależną od kandydata, lecz decyzją podejmowaną po stronie rekrutera. Wśród zmiennych zależnych od kandydata kluczową rolę odgrywają poziom umiejętności (SkillScore) oraz doświadczenie zawodowe (ExperienceYears). Wynik ten jest zgodny z praktyką - im wyższe kompetencje oraz większe doświadczenie posiada kandydat, tym większe są jego szanse na zatrudnienie. Pozostałe cechy, takie jak płeć, wiek, liczba wcześniejszych miejsc pracy oraz odległość od siedziby firmy, wykazują marginalny wpływ na decyzje modelu, co sugeruje, że nie stanowią one istotnych kryteriów w procesie rekrutacyjnym. Poziom wykształcenia wpływa na prawdopodobieństwo zatrudnienia w sposób zauważalny, jednak pełni głównie rolę czynnika wspierającego. Nie prowadzi on samodzielnie do zmiany decyzji rekrutacyjnej, natomiast niższe poziomy wykształcenia obniżają prawdopodobieństwo zatrudnienia, co jest spójne z obserwacjami dotyczącymi wymagań współczesnego rynku pracy, gdzie posiadanie co najmniej wykształcenia magisterskiego często zwiększa szansę na zatrudnienie. Uzyskane wyniki pokazują, że interpretowalność modelu jest równie istotna jak jego skuteczność predykcyjna, ponieważ umożliwia identyfikację czynników rzeczywiście wpływających na decyzje rekrutacyjne oraz ogranicza ryzyko podejmowania decyzji opartych na nieistotnych lub niepożądanych przesłankach.

Spis rysunków

Rysunek 1 Wykresy gęstości dla zmiennych ilościowych. 7
Rysunek 2 Wykresy pudełkowe dla zmiennych ilościowych. 9
Rysunek 3 Wykres gęstości i pudełkowy zmiennej Age w zależności od decyzji o zatrudnieniu. 11
Rysunek 4 Wykres gęstości i pudełkowy zmiennej ExperienceYears w zależności od decyzji o zatrudnieniu. 12
Rysunek 5 Wykres gęstości i pudełkowy zmiennej InterviewScore w zależności od decyzji o zatrudnieniu. 12
Rysunek 6 Wykres gęstości i pudełkowy zmiennej SkillScore w zależności od decyzji o zatrudnieniu. 13
Rysunek 7 Wykres gęstości i pudełkowy zmiennej PersonalityScore w zależności od decyzji o zatrudnieniu. 13
Rysunek 8 Wykres gęstości i pudełkowy zmiennej PreviousCompanies w zależności od decyzji o zatrudnieniu. 14
Rysunek 9 Wykres gęstości i pudełkowy zmiennej DistanceFromCompany w zależności od decyzji o zatrudnieniu. 14
Rysunek 10 Analiza ważności zmiennych. 29
Rysunek 11 Profil ceteris-paribus dla zmiennej Age. 30
Rysunek 12 Profil ceteris-paribus dla zmiennej ExperienceYears. 31
Rysunek 13 Profil ceteris-paribus dla zmiennej PreviousCompanies. 31
Rysunek 14 Profil ceteris-paribus dla zmiennej DistanceFromCompany. 32
Rysunek 15 Profil ceteris-paribus dla zmiennej InterviewScore. 32
Rysunek 16 Profil ceteris-paribus dla zmiennej SkillScore. 33
Rysunek 17 Profil ceteris-paribus dla zmiennej PersonalityScore. 34
Rysunek 18 Profil ceteris-paribus dla zmiennej Gender. 34
Rysunek 19 Profil ceteris-paribus dla zmiennej EducationLevel. 35
Rysunek 20 Profil ceteris-paribus dla zmiennej RecruitmentStrategy. 35
Rysunek 21Profil PDP dla zmiennej Age. 36
Rysunek 22 Wykres PCP i PDP dla zmiennej Age. 37
Rysunek 23 PDP i PCP dla zmiennej Age z rozróżnieniem na płeć. 37
Rysunek 24 PDP i PCP dla zmiennej Age z rozróżnieniem na poziom wykształcenia. 38
Rysunek 25 PDP i PCP dla zmiennej Age z rozróżnieniem na strategie rekrutacyjne. 38
Rysunek 26 Profil PDP dla zmiennej ExperienceYears. 39
Rysunek 27 Wykres PCP i PDP dla zmiennej ExperienceYears. 39
Rysunek 28 PDP i PCP dla zmiennej ExperienceYears z rozróżnieniem na płeć. 40
Rysunek 29 PDP i PCP dla zmiennej ExperienceYears z rozróżnieniem na poziom wykształcenia. 40
Rysunek 30 PDP i PCP dla zmiennej ExperienceYears z rozróżnieniem na strategie rekrutacyjne. 41
Rysunek 31 Profil PDP dla zmiennej PreviousCompanies. 42
Rysunek 32 Wykres PCP i PDP dla zmiennej PreviousCompanies. 42
Rysunek 33 PDP i PCP dla zmiennej PreviousCompanies z rozróżnieniem na płeć. 43
Rysunek 34 PDP i PCP dla zmiennej PreviousCompanies z rozróżnieniem na poziom wykształcenia. 43

Rysunek 35 PDP i PCP dla zmiennej PreviousCompanies z rozróżnieniem na strategie rekrutacyjne. 44
Rysunek 36 Profil PDP dla zmiennej DistanceFromCompany. 44
Rysunek 37 Wykres PCP i PDP dla zmiennej DistanceFromCompany. 45
Rysunek 38 PDP i PCP dla zmiennej DistanceFromCompany z rozróżnieniem na płeć. 45
Rysunek 39 PDP i PCP dla zmiennej DistanceFromCompany z rozróżnieniem na poziom wykształcenia. 46
Rysunek 40 PDP i PCP dla zmiennej DistanceFromCompany z rozróżnieniem na strategie rekrutacyjne. 46
Rysunek 41 Profil PDP dla zmiennej InterviewScore. 47
Rysunek 42 Wykres PCP i PDP dla zmiennej InterviewScore. 48
Rysunek 43 PDP i PCP dla zmiennej InterviewScore z rozróżnieniem na płeć. 48
Rysunek 44 PDP i PCP dla zmiennej InterviewScore z rozróżnieniem na poziom wykształcenia. 49
Rysunek 45 PDP i PCP dla zmiennej InterviewScore z rozróżnieniem na strategie rekrutacyjne. 49
Rysunek 46 Profil PDP dla zmiennej SkillScore. 50
Rysunek 47 Wykres PCP i PDP dla zmiennej SkillScore. 51
Rysunek 48 PDP i PCP dla zmiennej SkillScore z rozróżnieniem na płeć. 51
Rysunek 49 PDP i PCP dla zmiennej SkillScore z rozróżnieniem na poziom wykształcenia. ..52
Rysunek 50 PDP i PCP dla zmiennej SkillScore z rozróżnieniem na strategie rekrutacyjne. .52
Rysunek 51 Profil PDP dla zmiennej PersonalityScore. 53
Rysunek 52 Wykres PCP i PDP dla zmiennej PersonalityScore. 54
Rysunek 53 PDP i PCP dla zmiennej PersonalityScore z rozróżnieniem na płeć. 54
Rysunek 54 PDP i PCP dla zmiennej PersonalityScore z rozróżnieniem na poziom wykształcenia. 55
Rysunek 55 PDP i PCP dla zmiennej PersonalityScore z rozróżnieniem na strategie rekrutacyjne. 55
Rysunek 56 Profil PDP dla zmiennej Gender. 56
Rysunek 57 Profil PDP dla zmiennej EducationLevel. 56
Rysunek 58 Profil PDP dla zmiennej RecruitmentStrategy. 57
Rysunek 59 Profil Break Down - kompetencje. 58
Rysunek 60 Wykres Break Down - podstawowe cechy. 59
Rysunek 61 Wykres Break Down - odległość od miejsca pracy. 60
Rysunek 62 Wykres Break Down – doświadczenie. 61
Rysunek 63 Wykres Break Down - strategia rekrutacyjna. 62
Rysunek 64 Wartości SHAP. 63

Spis tabel

Tabela 1 Zbalansowanie zbioru. 5
Tabela 2 Statystyki opisowe dla zmiennych ilościowych. 6
Tabela 3 Statystyki dla zmiennych kategorycznych. 8
Tabela 4 Wyniki testu niezależności chi-kwadrat oraz współczynnika V-Cramera. 10
Tabela 5 Wyniki estymacji modelu regresji logistycznej. 16
Tabela 6 Metryki jakości klasyfikacji - regresja logistyczna. 17
Tabela 7 Testowane hiperparametry - kNN. 18
Tabela 8 Metryki jakości klasyfikacji - kNN. 18
Tabela 9 Testowane hiperparametry - kkNN. 19
Tabela 10 Metryki jakości klasyfikacji - kkNN. 19
Tabela 11 Testowane hiperparametry - drzewo decyzyjne. 20
Tabela 12 Metryki jakości klasyfikacji – drzewo decyzyjne. 22
Tabela 13 Testowane hiperparametry - las losowy. 23
Tabela 14 Metryki jakości klasyfikacji - las losowy. 23
Tabela 15 Testowane hiperparametry - XGBoost. 24
Tabela 16 Metryki jakości klasyfikacji - XGBoost. 25
Tabela 17 Testowane hiperparametry - SVM (jądro liniowe) 25
Tabela 18 Testowane hiperparametry - SVM (jądro radialne). 26
Tabela 19 Testowane hiperparametry - SVM (jądro wielomianowe). 26
Tabela 20 Metryki jakości klasyfikacji - SVM. 27
Tabela 21 Zestawienie metryk jakości klasyfikacji. 28